

$$Y = f(\beta, X) + \varepsilon$$

$$s_y = s \sqrt{X_0^T (X^T X)^{-1} X_0}$$

$$R_{yX} = \sqrt{1 - \frac{|W|}{|R|}},$$

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_m x_{im} + \varepsilon_i,$$

$$R_{y_1 x_2 \dots x_p} = \frac{r_{y_1}^2 + r_{y_2}^2 - 2r_{y_1 y_2} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2}$$

$$Z^{-1} = (X^T X^{-1})$$

$$h_{ij} = \frac{r_{0j}^2}{1 + \sum_{i=1, i \neq j}^m |r_{ij}|}$$

$$R_{y_1 x_2 \dots x_p}$$

$$\sigma_{\varepsilon_i \varepsilon_j} = \text{Cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} 0, & I \neq j \\ \sigma^2, & I = j \end{cases}$$

$$= \sum_{i=1}^n e_i^2 \rightarrow \min.$$

$$b_j, j=0, m: \sum_{i=1}^n \left(y_i - (b_0 + \sum_{j=1}^m b_j x_{ij}) \right)^2$$

$$\beta_1 = \frac{r_{y_1} - r_{y_2} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2},$$

$$\beta_2 = \frac{r_{y_2} - r_{y_1} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2}.$$

$$Y = f(\beta, X) + \varepsilon$$

$$h_{ij} = \frac{r_{0j}^2}{1 + \sum_{i=1, i \neq j}^m |r_{ij}|}$$

$$R_{yX} = \sqrt{1 - \frac{|W|}{|R|}},$$

$$R_{y_1 x_2 \dots x_p} = \sqrt{\sum \beta_i \cdot r_{y_1 x_i}}$$

$$s_y = s \sqrt{X_0^T (X^T X)^{-1} X_0}$$

$$R_{y_1 x_2 \dots x_p} = \frac{r_{y_1}^2 + r_{y_2}^2 - 2r_{y_1 y_2} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2}$$

$$Z^{-1} = (X^T X^{-1})$$

В.А. АКИНЬШИНА
Г.В. КАЛАЙДИНА

ВВЕДЕНИЕ В ЭКОНОМЕТРИКУ

$$s_e^2 = \frac{\sum e_i^2}{n - m - 1}$$

$$\sigma_{\varepsilon_i \varepsilon_j} = \text{Cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} 0, & I \neq j \\ \sigma^2, & I = j \end{cases}$$

$$= \sum_{i=1}^n e_i^2 \rightarrow \min.$$

$$b_j, j=0, m: \sum_{i=1}^n \left(y_i - (b_0 + \sum_{j=1}^m b_j x_{ij}) \right)^2$$

$$\beta_1 = \frac{r_{y_1} - r_{y_2} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2},$$

$$\beta_2 = \frac{r_{y_2} - r_{y_1} r_{x_1 x_2}}{1 - r_{x_1 x_2}^2}.$$

$$Y = f(\beta, X) + \varepsilon$$

$$h_{ij} = \frac{r_{0j}^2}{1 + \sum_{i=1, i \neq j}^m |r_{ij}|}$$

$$s_e^2 = \frac{\sum e_i^2}{n - m - 1}$$

Министерство науки и высшего образования
Российской Федерации
КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

В.А. АКИНЬШИНА
Г.В. КАЛАЙДИНА

ВВЕДЕНИЕ В ЭКОНОМЕТРИКУ

Учебное пособие

Краснодар
2023

УДК 330.43(075.8)

ББК 65в631я73

А 394

Рецензенты:

Доктор физико-математических наук, профессор

М.Х. Уртенев

Доктор физико-математических наук, профессор

К.А. Лебедев

Акиньшина, В.А., Калайдина, Г.В.

А 394 Введение в эконометрику: учебное пособие / В.А. Акиньшина, Г.В. Калайдина; Министерство науки и высшего образования Российской Федерации, Кубанский государственный университет. – Краснодар: Кубанский гос. ун-т, 2023. – 191 с. – 500 экз.

ISBN 978-5-8209-2348-7

Описаны классы эконометрических моделей, различные типы данных и методы их исследования, даются основные понятия корреляционного анализа, задачи линейной и нелинейной регрессий. Для анализа многомерных данных представлены методы построения регрессионных моделей, рассмотрены проблемы мультиколлинеарности и гетероскедастичности, автокорреляционная функция. Приводятся примеры решения типовых задач.

Адресуется учащимся бакалавриата и магистратуры направлений 09.03.03 Прикладная информатика, 01.04.02 Прикладная математика и информатика, 09.04.02 Информационные системы и технологии.

УДК 330.43(075.8)

ББК 65в631я73

ISBN 978-5-8209-2348-7

© Кубанский государственный университет, 2023

© Акиньшина В.А., Калайдина Г.В., 2023

ВВЕДЕНИЕ

В настоящем пособии излагаются основы эконометрики.

Пособие состоит из четырех глав. В первой главе рассмотрены основные понятия эконометрики, описаны классы эконометрических моделей, различные типы данных и методы их исследования. Во второй главе представлены основные понятия корреляционного анализа: рассмотрена смысловая нагрузка парного, частного и множественного коэффициентов корреляции, приведены методы анализа корреляционной матрицы и показателей информационной емкости, даны примеры решения типовых задач. В третьей главе охарактеризована задача регрессии, линейная и нелинейная регрессии, приведена оценка значимости моделей, сравнение моделей и примеры решения типовых задач. Четвертая глава посвящена множественной регрессии: описан метод наименьших квадратов, работа с фиктивными переменными, рассмотрены проблемы мультиколлинеарности и гетероскедастичности, автокорреляционная функция.

Изложение ведется по принципу от простого к сложному. Приводится обширный теоретический материал. После каждой темы представлены контрольные вопросы для закрепления и разобранные примеры решения типовых задач. Поэтому пособие может быть рекомендовано студентам для самостоятельного изучения основ эконометрики.

1. ПРЕДМЕТ ЭКОНОМЕТРИКИ

Эконометрика – наука, изучающая количественные и качественные экономические взаимосвязи с помощью статистических и других математических методов и моделей.

Основные результаты экономической теории носят качественный характер, например, даются ответы на вопросы:

- какие факторы влияют на совокупный объём инвестиций в частном бизнесе;
- как зависят темпы экономического роста от размеров дефицита государственного бюджета, объёма инвестиций, внешнего долга, уровня инфляции;
- каким образом изменит структуру потребления снижение ставок налогов.

Однако для принятия обоснованных решений часто требуется отвечать на вопросы, начинающиеся словами «на сколько», например:

- на сколько изменится объём потребления электроэнергии, если предположить, что цены на неё возрастут на 30%;
- на сколько увеличится спрос на данную продукцию, если удвоить текущие расходы на её рекламу.

Это количественное содержание и является предметом изучения эконометрики.

Следует отметить, что зачастую не удаётся достичь желаемой степени точности предсказаний. Модели и уравнения, дающие хорошее согласование для одного периода времени, могут оказаться неудовлетворительными для другого. Это связано с большой сложностью экономических процессов.

Но в любом случае анализ в эконометрике производится на основе широкого применения самых разнообразных математических методов и моделей. И, конечно, значимые результаты можно получить лишь путем обработки реальных статистических данных.

1.1. ТИПЫ ДАННЫХ И МЕТОДЫ ИХ ИССЛЕДОВАНИЯ

Статистические данные могут быть представлены в виде временных рядов и пространственных данных. Временные ряды – это тип данных, характеризующий один и тот же объект исследования в различные периоды времени. Примером могут служить помесечные и ежеквартальные данные, а также данные за ряд лет об одном конкретном экономическом показателе. В отличие от временных рядов пространственные данные – это значения экономического показателя, полученные от разных однотипных объектов исследования, но относящиеся к одному и тому же периоду времени. Например, данные о доходах населения по федеральным округам, о численности занятого населения в экономике по муниципальным образованиям.

В эконометрике система одновременных уравнений содержит в себе эндогенные и экзогенные переменные. Эндогенная переменная – это зависимое значение, число которого равняется количеству уравнений в системе. Для их обозначения используют y . Другими словами, эндогенные (внутренние) переменные – это неизвестные переменные, чью динамику (поведение) необходимо изучить и получить данные об их поведении в ходе решения (анализа) модели.

Экзогенные переменные – это predetermined значения, которые влияют на эндогенные, но от них не зависят. Их отображают с помощью x . По-другому экзогенные (внешние) переменные – это известные переменные, которые мы принимаем как заданные (извне по отношению к модели).

Экзогенные и эндогенные переменные, рассматриваемые в разное время с определенным промежутком (лагом), называются лаговыми переменными.

В настоящее время существует три основных класса эконометрических моделей: модели временных рядов, регрессионные модели с одним уравнением и системы одновременных уравнений.

К моделям временных рядов относятся модели тренда и сезонности, адаптивного прогноза и авторегрессии. Тренд представляет собой устойчивое изменение уровня показателя в течение

длительного времени. Сезонность характеризует устойчивые внутригодовые колебания уровня показателя.

Регрессионные модели с одним уравнением по виду функции делятся на линейные и нелинейные. Линейная регрессионная модель показывает зависимость одной переменной от другой или нескольких других.

Нелинейная регрессионная модель использует комбинацию параметров модели, которая зависит от одной и более независимых переменных.

Система одновременных уравнений – это совокупность эконометрических уравнений, в которых одни и те же переменные расположены в правых и левых частях разных уравнений системы.

Эконометрические модели, которые активно применяются в исследованиях в настоящее время, можно объединить в три группы:

- 1) по характеру используемых данных – статические и динамические; статические модели основаны на одновременных данных по совокупности объектов, динамические модели – на временных рядах;
- 2) по составу – комплексные и некомплексные; комплексные модели отражают связи между макроэкономическими показателями на всех стадиях процесса воспроизводства; некомплексные – исследуют конкретные проблемы за выбранный временной промежуток;
- 3) по целям применения – аналитические, имитационные и прогностические.

Построение любой эконометрической модели последовательно проходит ряд этапов:

- 1) постановочный этап включает в себя постановку цели исследования и набор экономических переменных;
- 2) априорный этап выявляет сущность экономического показателя, а также формирование и формализацию априорной (известной до начала моделирования) информации;
- 3) информационный этап: производится регистрация значений, участвующих факторов и показателей в модели;
- 4) этап спецификации модели (подробного описания объекта исследования): обнаруженные связи и соотношения выражаются в

математической форме; устанавливается список экономических переменных и взаимосвязи экзогенных и эндогенных переменных, в том числе лаговых; производится формулировка исходных предпосылок и ограничений модели;

5) этап параметризации модели характеризуется выбором общего вида модели и выявлением входящих в нее связей;

6) этап идентификации модели: проводится статистический анализ модели, дается оценка ее параметров при помощи статистических методов (например, регрессионного анализа);

7) этап верификации модели предполагает проверку адекватности модели и точности расчетов.

Методы эконометрики

1. *Сводка и группировка информации.* Статистическая сводка – это обработка материалов наблюдения, включающая в себя систематизацию, группировку данных, составление таблиц, подсчет итогов, расчет производных показателей (средних и относительных величин).

Статистическая группировка – это процесс образования однородных групп на основе расчленения статистической совокупности на части или объединения изучаемых единиц в частные совокупности по существенным для них признакам. Признаки могут находиться в связи между собой. Связи классифицируют по степени тесноты, направлению, форме, числу факторов. По степени тесноты связи делятся на статистические (стохастические) и функциональные. Статистическая (стохастическая) связь – это такая связь между признаками, при которой для каждого значения признака-фактора X признак-результат Y может в определенных пределах принимать любые значения с некоторыми вероятностями; при этом его статистические (массовые) характеристики (например, среднее значение) изменяются по определенному закону.

Статистическая связь обусловлена:

1) тем, что на результативный признак оказывают влияние не только фактор (факторы), учтенные в модели, но и неучтенные или неконтролируемые факторы;

2) неизбежностью ошибок измерения значений признаков.

Функциональной называется такая связь, когда каждому возможному значению признака-фактора X соответствует одно или несколько строго определенных значений результативного признака Y .

По направлению изменений статистических признаков связи делятся на прямые и обратные. По форме связи (виду функции f) связи делятся на прямолинейные (линейные) и криволинейные (нелинейные).

По количеству факторов в модели связи подразделяются на однофакторные (парные) и многофакторные.

2. *Вариационный и дисперсионный анализ.* Вариация определяет различия в значениях по какому-либо признаку разных единиц данной совокупности в один и тот же период (момент времени). Размах вариации определяется как абсолютная величина разности между максимальными и минимальными значениями (вариантами) признака. Дисперсия признака – это средний квадрат отклонений вариантов от их средней величины. В эконометрических расчетах, как правило, используют общую, межгрупповую и внутригрупповую дисперсии. При этом общая дисперсия характеризует вариацию признака в статистической совокупности в результате влияния всех факторов. Межгрупповая дисперсия показывает размер отклонения групповых средних от общей средней, т. е. характеризует влияние фактора, положенного в основание группировки. Внутригрупповая (остаточная) дисперсия характеризует вариацию признака в середине каждой группы статистической группировки. В эконометрических расчетах используется среднее квадратическое отклонение – обобщающая характеристика размеров вариации признака в совокупности. Оно равно корню квадратному из дисперсии. Для осуществления сравнений изменения одного и того же признака в нескольких совокупностях используется показатель вариации – коэффициент вариации.

3. *Регрессионный и корреляционный анализ.* Корреляционный анализ ставит своей целью проверку наличия и значимости линейной зависимости между переменными без разделения переменных на зависимые и объясняющие. Регрессионный анализ направлен на выражение изучаемой зависимости в виде аналитической

формулы с предварительным выделением зависимых и объясняющих переменных.

4. *Статистические уравнения зависимости и индексы.* Статистические индексы могут быть использованы в качестве меры изменения количества независимо от изменения качественного признака, а также для характеристики качественного признака независимо от изменения количества.

Пример. Модель национального дохода

$$Y = C + I + G + X,$$

где Y – валовой национальный продукт;

C – личные потребительские расходы;

G – государственные закупки товаров и услуг;

I – внутренние инвестиции;

X – чистый экспорт.

Рассматриваемая нами модель содержит две поведенческие связи:

- потребление;
- инвестиции.

Экономическая теория сделала две вещи:

1) установила перечень независимых переменных в правой части уравнения.

2) указала ожидаемые знаки в частных производных.

И здесь экономическая теория остановилась.

Есть вопросы, которые требуют осмысления.

Вопросы, на которые экономическая теория не может ответить:

- функциональная форма;
- определение и измерение данных;
- динамическая (лаговая) структура;
- качественный смысл против количественного;
- выбор между теориями.
- выбор между теориями.

Пример. Эконометрическая зависимость

$$\ln Y = \beta_0 + \beta_1 \ln C + \beta_2 \ln P,$$

где Y – потребление на душу населения пищевого продукта в некотором году (зависимая или объясняемая переменная);

C – реальный доход на душу населения;

P – индекс цен на этот продукт, скорректированный (дефлированный) на общий индекс стоимости жизни.

Задача эконометрики – определить коэффициенты β_i .

Здесь появляются *дополнительные вопросы*.

1. Нет ли переменных, которые следовало бы дополнительно включить в уравнение?

2. Не следует ли исключить из уравнения некоторые переменные?

3. Насколько корректно измерены исходные данные, представляют ли они то, что должны представлять?

4. Верно ли, что модель линейна?

5. Является ли модель полной?

6. Модель статистическая или динамическая?

2. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

Изучение связей между переменными интересует исследователя с точки зрения отражения соответствующих причинно-следственных отношений.

Корреляционная зависимость – это согласованные изменения двух (парная корреляционная связь) или большего количества признаков (множественная корреляционная связь). Суть ее заключается в том, что при изменении значения одной переменной происходит закономерное изменение (уменьшение или увеличение) другой (-их) переменной (-ых). *Корреляционный анализ* – статистический метод, позволяющий с использованием коэффициентов корреляции определить, существует ли зависимость между переменными и насколько она сильна. *Коэффициент корреляции* – двумерная описательная статистика, количественная мера взаимосвязи (совместной изменчивости) двух переменных.

При положительной линейной корреляции более высоким значениям одного признака соответствуют более высокие значения другого, а более низким значениям одного признака – низкие значения другого.

При отрицательной линейной корреляции более высоким значениям одного признака соответствуют более низкие значения другого, а более низким значениям одного признака – высокие значения другого.

Характер связи между переменными представлен на рис. 2.1.




Рис. 2.1. Характер связи между переменными

Различают виды связи между переменными:

1) прямая причинно-следственная связь – переменная X определяет значение переменной Y , (наличие воды ускоряет рост растений; температура воздуха прямо влияет на скорость таяния льда);

2) обратная причинно-следственная связь – переменная Y определяет значение переменной X (исследователь может думать, что чрезмерное потребление кофе вызывает нервозность, но, может быть, нервный человек выпивает кофе, чтобы успокоить свои нервы);

3) связь, вызванная третьей (скрытой) переменной (существует зависимость между числом утонувших людей и числом выпитых безалкогольных напитков в летнее время, однако, обе переменные связаны с жарой и потребностью людей во влаге);

4) связь, вызванная несколькими скрытыми переменными (исследователь может обнаружить значимую связь между оценками студентов в университете и оценками в школе, но действуют и другие переменные: IQ, количество часов занятий, влияние родителей, мотивация, возраст, авторитет преподавателей);

5) связи нет, наблюдаемая зависимость случайна (исследователь может найти связь между увеличением количества людей, которые занимаются спортом и увеличением количества людей, которые совершают преступления, но здравый смысл говорит, что любая связь между этими двумя переменными является случайной).

Различают парную (простую) и множественную корреляции (рис. 2.2). Парная корреляция характеризует тип, форму и плотность связи между двумя признаками, множественная – между несколькими. Корреляционная зависимость возникает чаще всего там, где одно явление находится под воздействием большого числа факторов, действующих с разной силой, поэтому существуют специальные меры корреляционной связи, называемые коэффициентами корреляции.



Рис. 2.2. Виды связи между переменными

Изучение связей между переменными, интересует исследователя с точки зрения отражения соответствующих причинно-следственных отношений.

2.1. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ ВЗАИМОСВЯЗИ КОЛИЧЕСТВЕННЫХ ПРИЗНАКОВ

При построении корреляционных моделей исходят из условия нормальности многомерного закона распределения генеральной совокупности. Эти условия обеспечивают линейный характер связи между изучаемыми признаками и позволяют для исследования взаимосвязи между переменными использовать линейные коэффициенты корреляции. На практике в качестве показателей тесноты связи рассчитывают три линейных коэффициента корреляции: *парный*, *частный* и *множественный*, каждый из которых несет свою смысловую нагрузку.

Парный коэффициент корреляции (коэффициент корреляции Пирсона) характеризует степень линейной зависимости между двумя переменными на фоне действия всех остальных переменных, отобранных для анализа. Так, парный коэффициент корреляции ρ_{12} характеризует степень линейной зависимости между переменными x_1 и x_2 на фоне влияния остальных переменных $x_3, x_4, \dots, x_p$.

Пусть на основе статистической информации составлены вектор y (с обозначением $y = x_0$) наблюдаемых значений эндогенной переменной и матрица X наблюдаемых значений потенциальных факторов $x_1, x_2, \dots, x_p$ в виде

$$y = \begin{pmatrix} y_1 \\ \dots \\ y_i \\ \dots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_{11} & \dots & x_{1j} & \dots & x_{1p} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{ij} & \dots & x_{ip} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & \dots & x_{nj} & \dots & x_{np} \end{pmatrix} \quad (2.1)$$

размерности $n \times p$, в которой i -я строка характеризует i -е наблюдение (объект) по всем p показателям ($j = 1, 2, \dots, p$).

Ковариационная матрица Σ содержит сведения о степени случайного разброса анализируемых переменных, а также о характере и структуре статистических взаимосвязей между ними; она является симметричной и неотрицательно определенной. В статистическом анализе используется ее статистическая оценка – выборочная ковариационная матрица $\hat{\Sigma} = (\hat{\sigma}_{ij})$ $i = 0, \dots, p, j = 1, 2, \dots, p$, где

$$\hat{\sigma}_{ij} = \frac{1}{n} \sum_{k=0}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j).$$

Парный коэффициент корреляции r_{ij} между случайными переменными x_i и x_j измеряет степень тесноты линейной связи между этими переменными и определяется через ковариации по формуле

$$r_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii} \cdot \sigma_{jj}}}.$$

Статистическая оценка – выборочный парный коэффициент корреляции между двумя количественными признаками x_i и y – определяется по формулам

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}; \quad (2.2)$$

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{S_x \cdot S_y}, \text{ или } r = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{S_x \cdot S_y}, \quad (2.3)$$

где $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$, $\overline{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i$, – средние арифметиче-

ские признаков и произведения, а $S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$,

$S_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$ – дисперсии признаков.

По знаку коэффициента корреляции можно судить о направлении связи между переменными. Так, положительное значение коэффициента корреляции соответствует прямой связи, а отрицательное значение – обратной. Однако величина r_{xy} ничего не говорит о причинно-следственных связях. Эти вопросы должны решаться, исходя из содержательного анализа задачи. Следует избегать и так называемых ложных корреляций, т.е. нельзя пытаться связать явления, между которыми отсутствуют реальные причинно-следственные связи.

Корреляционная матрица W – это матрица размера $(p + 1)$ на $(p + 1)$, составленная из парных коэффициентов корреляции r_{ij} , $i, j = 0, 1, \dots, p$, имеющая следующий блочный вид

$$W = \begin{pmatrix} 1 & R_0^T \\ R_0 & R \end{pmatrix}, \quad R_0 = \begin{pmatrix} r_{01} \\ r_{02} \\ \dots \\ r_{0p} \end{pmatrix}, \quad R = \begin{pmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \dots & \dots & \dots & \dots \\ r_{p1} & r_{p2} & \dots & 1 \end{pmatrix}, \quad (2.4)$$

где $r_{jl} = \frac{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{il} - \bar{x}_l)}{s_j \cdot s_l}$ – выборочный парный коэффициент

корреляции, характеризующий тесноту линейной связи между

показателями x_j и x_l ; x_{ij} – значение i -го наблюдения j -го фактора; а

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}; \quad s_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}.$$

Матрица R является симметричной ($r_{jl} = r_{lj}$) и положительно определенной.

Теснота корреляционной взаимосвязи между переменными может быть качественно охарактеризована с помощью рекомендаций, представленных в табл. 2.1.

Таблица 2.1

Значение коэффициента корреляции	Теснота линейной взаимосвязи
$0,8 \leq r \leq 1,0$	Сильная взаимосвязь, близкая к функциональной
$0,5 \leq r < 0,8$	Взаимосвязь средней силы
$0,3 \leq r < 0,5$	Умеренная взаимосвязь
$0,2 \leq r < 0,3$	Слабая взаимосвязь
$0,0 \leq r < 0,2$	Очень слабая взаимосвязь

Для значимого коэффициента корреляции можно построить доверительный интервал, который с заданной надежностью $\gamma = 1 - \alpha$ содержит неизвестный генеральный коэффициент ρ . Для построения такого интервала рассчитываем распределение Фишера

$$z = \frac{1}{2} \ln \frac{1+r}{1-r} \text{ для значимых коэффициентов корреляции (имеются}$$

специальные таблицы, в которых приведены значения при соответствующих значений r_{xy} , либо можно воспользоваться встроенными функциями в Excel (см. прил. 1). Распределение Фишера при больших значениях n является приблизительно нормальным. Строим сначала доверительный интервал для математического ожидания $E(z)$:

$$Z_i - u_{\text{кр}(1 - \alpha/2)} \cdot s_Z \leq E(Z) \leq Z_i + u_{\text{кр}(1 - \alpha/2)} \cdot s_Z, \quad (2.5)$$

где $s_z = \frac{1}{\sqrt{n - p - 1}}$ стандартное отклонение, $u_{\text{кр}(1 - \alpha/2)}$ – нормиро-

ванное отклонение z и определяется с помощью функции Лапласа $\Phi(u_{кр}) = 1 - \alpha/2$. Далее, используя обратное преобразование Фишера, получим доверительный интервал для коэффициента корреляции:

$$r_1 \leq \rho \leq r_2. \quad (2.6)$$

Частные коэффициенты корреляции характеризуют тесноту связи между двумя переменными при фиксированном значении остальных факторов. С помощью частных коэффициентов корреляции проводится ранжирование факторов по степени их влияния на результат. Кроме того, данные показатели используются при решении целесообразности включения того или иного фактора в модель.

Если парный коэффициент корреляции между двумя случайными величинами оказался больше соответствующего частного коэффициента, то можно сделать вывод о том, что фиксирование всех других переменных приводит к усилению взаимосвязи между изучаемыми величинами, т.е. более высокое значение парного коэффициента обусловлено присутствием «третьей величины». Более низкое значение парного коэффициента корреляции в сравнении с соответствующими частными свидетельствует об ослаблении связи между изучаемыми величинами действием фиксируемых величин.

Частный коэффициент корреляции $r(ij|k_1, k_2, \dots, k_m)$ измеряет степень тесноты линейной связи между переменными x_i и x_j при анализе множественных статистических связей компонент случайного вектора $(x_0 = y, x_1, \dots, x_p)$ в ситуации, когда значения переменных зафиксированы на их средних уровнях и тем самым исключено опосредованное влияние этих переменных на взаимосвязь между x_i и x_j . Если исследуемые переменные подчиняются $(p + 1)$ -мерному нормальному закону распределения, то подсчитать частый коэффициент корреляции можно по формуле

$$r(ij|k_1, k_2, \dots, k_m) = -\frac{W_{ij}}{\sqrt{W_{ii} \cdot W_{jj}}}, \quad (2.7)$$

где W_{ls} – алгебраическое дополнение элемента r_{ls} в корреляционной матрице W .

Частный коэффициент корреляции r_{yx_1/x_2} характеризует степень линейной зависимости между двумя величинами y и x_1 при исключенном влиянии третьей величины x_2 . Для двухфакторной модели частные коэффициенты корреляции определяются по формулам:

$$\begin{aligned} r_{yx_1/x_2} &= \frac{r_{yx_1} - r_{yx_2} r_{x_1x_2}}{\sqrt{(1 - r_{yx_2}^2)(1 - r_{x_1x_2}^2)}}, \\ r_{yx_2/x_1} &= \frac{r_{yx_2} - r_{yx_1} r_{x_1x_2}}{\sqrt{(1 - r_{yx_1}^2)(1 - r_{x_1x_2}^2)}}, \\ r_{x_1x_2/y} &= \frac{r_{x_1x_2} - r_{yx_1} r_{yx_2}}{\sqrt{(1 - r_{yx_1}^2)(1 - r_{yx_2}^2)}}. \end{aligned} \quad (2.8)$$

Проверка значимости парного и частного коэффициентов корреляции. Для проверки значимости парного и частного коэффициентов корреляции выдвигаются следующие гипотезы.

Нулевая гипотеза $H_0: r = 0$ означает отсутствие линейной взаимосвязи между признаками, их некоррелированность и независимость.

Конкурирующая гипотеза $H_1: r \neq 0$ свидетельствует о наличии линейной взаимосвязи между признаками.

Для проверки гипотезы H_0 используется критерий Стьюдента (t -критерий). Наблюдаемое значение статистики критерия рассчитывается по формуле

$$t_{\text{наб}} = \frac{r_{ij} \sqrt{n - l - 2}}{\sqrt{1 - r_{ij}^2}}, \quad (2.9)$$

которая при справедливости нулевой гипотезы имеет распределение Стьюдента (t -распределение) с $n - l - 2$ степенями свободы.

Здесь r_{ij} – соответственно оценка парного или частного коэффициента корреляции; n – количество наблюдений; l – порядок частного коэффициента корреляции, т.е. число фиксируемых факторов (для парного коэффициента корреляции $l = 0$).

Затем по таблице распределения Стьюдента находится критическое значение статистики $t_{кр}$ для заданного уровня значимости α и числа степеней свободы $\nu = n - l - 2$.

Коэффициент корреляции считается значимым, т.е. гипотеза $H_0: r = 0$ отвергается с вероятностью ошибки α , если $|t_{наб}| > t_{кр}(\alpha, \nu)$ и между исследуемыми переменными есть тесная статистическая значимость. Заданный уровень значимости α обычно принимается равным 0,05 или 0,01 (значения распределения Стьюдента можно найти в прил. 2). Если же $|t_{наб}| < t_{кр}(\alpha, \nu)$, то гипотеза H_0 не отвергается, т.е. гипотеза об отсутствии зависимости между признаками с вероятностью ошибки α не противоречит выборочным наблюдениям.

Множественный коэффициент корреляции $R_{y.X}$ показывает степень тесноты статистической связи между результирующим показателем y и набором объясняющих переменных $X = (x_1, x_2, \dots, x_p)$ при линейной форме зависимости и может быть вычислен по матрице $(p + 1)$ на $(p + 1)$ парных коэффициентов корреляции, составленной для исследуемого набора переменных $(x_0 = y, x_1, \dots, x_p)$

$$R_{y.X} = \sqrt{1 - \frac{|W|}{|R|}}, \quad (2.10)$$

где $|W|$ – определитель корреляционной матрицы; $|R|$ – определитель матрицы R , который остаётся после вычеркивания из матрицы коэффициентов парной корреляции первого столбца и первой строки.

Коэффициент множественной корреляции для двухфакторной модели рассчитывается по формуле:

$$R_{yx_1x_2} = \sqrt{\frac{r_{yx_1}^2 + r_{yx_2}^2 - 2r_{yx_1}^2 r_{yx_2}^2 r_{x_1x_2}^2}{1 - r_{x_1x_2}^2}}. \quad (2.11)$$

Множественный коэффициент корреляции изменяется от 0 до 1. Чем ближе его значение к единице, тем теснее связь результативного признака со всем набором исследуемых факторов.

Квадрат множественного коэффициента корреляции называется *коэффициентом детерминации*.

Проверка гипотезы $H_0: R_{y.X} = 0$ об отсутствии линейной связи между y , с одной стороны, и совокупностью переменных $X = (x_1, x_2, \dots, x_p)$ – с другой, осуществляется с помощью критической статистики

$$F_{\text{набл}} = \frac{R_{y.X}^2}{1 - R_{y.X}^2} \cdot \frac{n - p - 1}{p}, \quad (2.12)$$

которая имеет F -распределение со степенями свободы p и $n - p - 1$ и уровнем значимости α .

Если $F_{\text{набл}} > F_{\text{кр}}(\alpha; p; n - p - 1)$, то гипотеза H_0 отвергается и множественный коэффициент корреляции отличается от нуля, т.е. существует статистическая связь между переменными. В противном случае H_0 принимается и связь между переменными отсутствует.

2.2. МЕТОД АНАЛИЗА КОРРЕЛЯЦИОННОЙ МАТРИЦЫ

Идея метода сводится к выбору таких экзогенных переменных (факторов), которые сильно коррелируют с эндогенной переменной и одновременно слабо коррелируют между собой. Пусть имеется исходная статистическая информация в виде (2.1) (с обозначением $y = x_0$), на основе которой вычисляются матрицы R и R_0 по формуле (2.3).

Из формулы (2.5) с заменой $t_{\text{набл}}$ на $t_{\text{кр}}(\alpha, n - 2)$ можно найти критическое значение коэффициента корреляции

$$r^* = \sqrt{\frac{t_{kp}^2}{t_{kp}^2 + (n-2)}}. \quad (2.13)$$

Критическое значение коэффициента корреляции также может априорно задаваться аналитиком.

Процедура подбора объясняющих переменных состоит из следующих этапов:

1) из множества потенциальных экзогенных переменных исключаются все элементы, которые удовлетворяют неравенству $|r_{ij}| \leq r^*$, поскольку они несущественно коррелируют с эндогенной переменной;

2) из оставшихся переменных фактором, включенным в модель, признается такая переменная x_k , для которой $|r_k| = \max \{|r_{0j}|\}$, поскольку x_k является носителем наибольшего количества информации о зависимой переменной;

3) из множества потенциальных экзогенных переменных исключаются все элементы, которые удовлетворяют неравенству $|r_{kj}| > r^*$, поскольку эти переменные слишком сильно коррелируют с фактором x_k и, следовательно, только воспроизводят представляемую им информацию.

Этапы 2–3 повторяются вплоть до момента опустошения множества потенциальных экзогенных переменных.

2.3. МЕТОД ПОКАЗАТЕЛЕЙ ИНФОРМАЦИОННОЙ ЕМКОСТИ

Идея метода и исходные статистические данные аналогичны предыдущему методу.

Рассмотрим все комбинации потенциальных экзогенных переменных, общее количество которых составляет $L = 2^P - 1$. Для каждой комбинации потенциальных экзогенных переменных рассчитываются индивидуальные и интегральные показатели информационной емкости.

Индивидуальный показатель информационной емкости

$$h_{lj} = \frac{r_{0j}^2}{1 + \sum_{i=1, i \neq j}^{m_l} |r_{ij}|}, l = 1, 2, \dots, L; j = 1, 2, \dots, m_l, \quad (2.14)$$

где l – номер комбинации; m_l – количество переменных в рассматриваемой комбинации.

Интегральный показатель информационной емкости

$$H_l = \sum_{j=1}^{m_l} h_{lj}, l = 1, 2, \dots, L. \quad (2.15)$$

Индивидуальные и интегральные показатели информационной емкости нормируются в интервале $[0; 1]$. Их значения оказываются тем больше, чем сильнее объясняющие показатели коррелируют с объясняемой переменной.

В качестве объясняющих выбирается такая комбинация переменных, которой соответствует максимальное значение интегрального показателя информационной емкости.

В роли критерия выбора наилучшей комбинации экзогенных переменных, имеющих одинаковую размерность, может выступать коэффициент множественной корреляции.

2.4. ПРИМЕРЫ РЕШЕНИЯ ТИПОВЫХ ЗАДАЧ

Пример 2.1. Исследуется зависимость между чистой прибылью компании y (млн р.), числом оборотов оборотных средств x_1 (раз) и трудоемкость продаж x_2 (чел./1 млн р.) по 20 компаниям. Исходные данные приведены в табл. 2.2.

Таблица 2.2

№	y	x_1	x_2	№	y	x_1	x_2	№	y	x_1	x_2
1	6,00	3,20	9,00	8	6,00	5,10	20,00	15	12,30	7,90	27,00
2	6,30	3,70	10,00	9	9,00	5,60	17,00	16	13,00	8,10	30,00
3	6,50	3,90	11,00	10	9,80	6,10	21,00	17	13,20	8,40	31,00
4	7,00	4,10	15,00	11	10,00	6,30	22,00	18	13,80	8,60	32,00
5	7,20	4,20	14,00	12	11,00	6,40	22,00	19	14,00	9,50	35,00
6	7,80	4,90	19,00	13	11,50	7,20	23,00	20	14,90	9,70	36,00
7	8,00	5,30	26,00	14	12,00	7,50	25,00				

Определить парные и частные коэффициенты корреляции, проверить их на значимость. Рассчитать множественный коэффициент корреляции и коэффициент детерминации.

Решение. Для определения парных и частных коэффициентов корреляции построим вспомогательную таблицу (рис. 2.3).

Тогда, парные коэффициенты корреляции формуле (2.2) будут равны:

$$r_{x_1y} = \frac{68,20 - 9,97 \cdot 6,29}{\sqrt{(107,84 - 9,97^2)(43,29 - 6,29^2)}} = 0,978,$$

$$r_{x_2y} = \frac{242,76 - 9,97 \cdot 22,25}{\sqrt{(107,84 - 9,97^2)(557,35 - 22,25^2)}} = 0,912,$$

$$r_{x_1x_2} = \frac{154,57 - 6,25 \cdot 22,25}{\sqrt{(557,35 - 22,25^2)(43,29 - 6,29^2)}} = 0,958.$$

B22										
	A	B	C	D	E	F	G	H	I	J
1		y	x ₁	x ₂	y ²	x ₁ ²	x ₂ ²	yx ₁	yx ₂	x ₁ x ₂
2	1	6,00	3,20	9,00	36,00	10,24	81,00	19,20	54,00	28,80
3	2	6,30	3,70	10,00	39,69	13,69	100,00	23,31	63,00	37,00
4	3	6,50	3,90	11,00	42,25	15,21	121,00	25,35	71,50	42,90
5	4	7,00	4,10	15,00	49,00	16,81	225,00	28,70	105,00	61,50
6	5	7,20	4,20	14,00	51,84	17,64	196,00	30,24	100,80	58,80
7	6	7,80	4,90	19,00	60,84	24,01	361,00	38,22	148,20	93,10
8	7	8,00	5,30	26,00	64,00	28,09	676,00	42,40	208,00	137,80
20	19	14,00	9,50	35,00	196,00	90,25	1225,00	133,00	490,00	332,50
21	20	14,90	9,70	36,00	222,01	94,09	1296,00	144,53	536,40	349,20
22	Ср. знач.	9,97	6,29	22,25	107,84	43,29	557,35	68,20	242,76	154,57
23										

Рис. 2.3. Вспомогательная таблица расчетов

Парные коэффициенты корреляции можно также найти, используя функцию КОРРЕЛ (прил. 1).

Матрица парных коэффициентов корреляции (2.3):

$$\begin{Bmatrix} 1 & 0,978 & 0,912 \\ 0,978 & 1 & 0,958 \\ 0,912 & 0,958 & 1 \end{Bmatrix}.$$

Проверим парные коэффициенты корреляции на значимость по формуле (2.9) $H_0: \rho = 0$ при $H_1: \rho \neq 0$.

Рассчитаем критическое значение критерия Стьюдента (t -критерий) $t_{кр}(0,05; 18) = 2,1$ и сравним $|t_{наб}|$ и $t_{кр}(\alpha, \nu)$.

Наблюдаемое значение статистики критерия получим

$$t_{yx_1} = \frac{0,978}{\sqrt{1-0,978^2}} \sqrt{18} = 19,93;$$

$$t_{yx_2} = \frac{0,912}{\sqrt{1-0,912^2}} \sqrt{18} = 9,42;$$

$$t_{x_1x_2} = \frac{0,958}{\sqrt{1-0,958^2}} \sqrt{18} = 14,16.$$

В всех случаях $|t_{наб}| > t_{кр}(\alpha, \nu)$, гипотеза H_0 отвергается, коэффициенты корреляции статистически значимы.

На основе матрицы корреляции найдем множественный коэффициент корреляции и коэффициент детерминации (2.10): $|W| = 0,003$; $|R| = 0,082$

$$R_{y..X} = \sqrt{1 - \frac{0,003}{0,082}} = 0,98; R^2 = 0,964.$$

Величина множественного коэффициента детерминации свидетельствует о сильной взаимосвязи чистой прибыли с числом оборотов оборотных средств и трудоемкостью продаж.

Множественный коэффициент корреляции можно рассчитать и по формуле (2.11):

$$R_{yx_1x_2} = \sqrt{\frac{0,978^2 + 0,912^2 - 2 \cdot 0,978^2 \cdot 0,912^2 \cdot 0,958^2}{1 - 0,958^2}} = 0,98.$$

Частные коэффициенты корреляции по формуле (2.7):

$$r_{yx_1/x_2} = \frac{0,978 - 0,912 \cdot 0,958}{\sqrt{(1 - 0,912^2)(1 - 0,958^2)}} = 0,89;$$

$$r_{yx_2/x_1} = \frac{0,912 - 0,978 \cdot 0,958}{\sqrt{(1 - 0,978^2)(1 - 0,958^2)}} = -0,42;$$

$$r_{x_1x_2/y} = \frac{0,125 - 0,9708 \cdot 0,912}{\sqrt{(1 - 0,9708^2)(1 - 0,912^2)}} = 0,77.$$

Связь между чистой прибылью и числом оборотов оборотных средств прямая и тесная, между числом оборотов оборотных средств и трудоемкостью продаж прямая и тесная, между чистой прибылью и трудоемкостью продаж обратная и средняя.

Проверим их на значимость $H_0: \rho = 0$ при $H_1: \rho \neq 0$.

Рассчитаем критическое значение критерия Стьюдента (t -критерий) $t_{кр}(0,05; 17) = 2,11$ и сравним если $|t_{наб}|$ и $t_{кр}(\alpha, \nu)$:

$$t_{yx_1/x_2} = \frac{0,89}{\sqrt{1 - 0,89^2}} \sqrt{17} = 7,96 > t_{кр} \text{ — гипотеза } H_0 \text{ отвергается, коэффициент корреляции статистически значим;}$$

коэффициент корреляции статистически значим;

$$t_{yx_2/x_1} = \frac{-0,42}{\sqrt{1 - (-0,42)^2}} \sqrt{17} = -1,91 < t_{кр} \text{ — гипотеза } H_0 \text{ принимается, коэффициент корреляции статистически не значим;}$$

коэффициент корреляции статистически не значим;

$$t_{x_1x_2/y} = \frac{0,77}{\sqrt{1 - 0,77^2}} \sqrt{17} = 6,02 > t_{кр} \text{ — гипотеза } H_0 \text{ отвергается, коэффициент корреляции статистически значим.}$$

коэффициент корреляции статистически значим.

Проведем проверку гипотезы $H_0: R_{y.X} = 0$ об отсутствии линейной связи между y , с одной стороны, и совокупностью переменных $X = (x_1, x_2)$ — с другой (2.11).

$$F_{набл} = \frac{0,964}{1 - 0,964} \cdot \frac{20 - 2 - 1}{2} = 229,49 > F_{кр}(0,05; 2; 17) = 3,59,$$

следовательно, гипотеза H_0 отвергается и множественный коэффициент корреляции отличается от нуля, т.е. существует статистическая связь между переменными.

Пример 2.2. Используя данные об активности коммерческих организаций, требуется сделать оценку связи прибыли Y (млн р.) и затрат X (млн р.), используемых для разработки продукции (приведены на рис. 2.4).

Схема решения таких задач выглядит следующим образом:

1) рассчитывается линейный коэффициент корреляции r_{xy} (2.2);

2) проверяется значимость линейного коэффициента корреляции на основе t -критерия Стьюдента (2.8); при этом выдвигается и проверяется гипотеза о равенстве коэффициента корреляции нулю; при проверке этой гипотезы используется t -статистика; если гипотеза подтверждается, t -статистика имеет распределение Стьюдента; если расчетное значение $t_{\text{набл}} > t_{\text{кр}}$, то гипотеза отвергается, что свидетельствует о значимости линейного коэффициента корреляции, а следовательно, и о статистической существенности зависимости между X и Y ;

3) определяется интервальная оценка для статистически значимого линейного коэффициента корреляции (2.6);

4) определяется интервальная оценка для линейного коэффициента корреляции на основе обратного z -преобразования Фишера (2.5);

5) рассчитывается стандартная ошибка линейного коэффициента корреляции.

	A	B	C	D	E
1	№	X	Y		
2	1	210	95		
3	2	1068	76		
4	3	1005	78		
5	4	610	89		
6	5	768	77		
7	6	799	85		
8	Коэффициент корреляции		-0,9118	<--	=КОРРЕЛ(B2:B7;C2:C7)
9	Расчетное (наблюдаемое) значение t -критерия $t_{\text{набл}}$		4,4421	<--	=ABS(C8)/КОРЕНЬ(1-СТЕПЕНЬ(C8;2))*КОРЕНЬ(6-2)
10	Табличное значение t -критерия $t_{\text{кр}}$		2,7764	<--	=СТЬЮДЕНТ.ОБР.2X(0,05;4)
11	Табличное значение стандартн. норм. распр. z_y		1,9600	<--	=НОРМ.СТ.ОБР(1-0,05/2)
12	Значение преобразования Фишера Zr		-1,5383	<--	=ФИШЕР(C8)
13	Левая интервальная оценка для Zr		-2,6699	<--	=C12-C11*КОРЕНЬ(1/(6-3))
14	Правая интервальная оценка для Zr		-0,4068	<--	=C12+C11*КОРЕНЬ(1/(6-3))
15	Левая интервальная оценка для g_{xy}		-0,9905	<--	=ФИШЕРОБР(C13)
16	Правая интервальная оценка для g_{xy}		-0,3857	<--	=ФИШЕРОБР(C14)
17	Стандартное отклонение для g_{xy}		0,2053	<--	=КОРЕНЬ((1-C8^2)/4)

Рис. 2.4. Схема решения задачи

На рис. 2.4. в ячейках B2:C7 представлены данные об активности коммерческих организаций, в A8:A17 – показатели, необходимые для расчета, а в ячейках E8:E17 – формулы для расчета этих показателей.

Значение $t_{\text{набл}} = 4,44 > t_{\text{кр}} = 2,78$, т.е. гипотеза $H_0: r = 0$ отвергается, что свидетельствует о значимости линейного коэффициента корреляции, а следовательно, и о статистической существенной зависимости между X и Y .

Таким образом, с вероятностью 0,95 линейный коэффициент корреляции заключен в интервале от $(-0,386)$ до $(-0,990)$ со стандартной ошибкой 0,205.

Рассчитаем доверительные интервалы для примера 2.1 (рис. 2.5).

	гyx1	гyx2	гx1x2
Коэффициент корреляции	0,978	0,912	0,9579
Расчетное (наблюдаемое) значение t-критерия $t_{\text{набл}}$	19,93	9,42	14,15
Табличное значение t-критерия $t_{\text{кр}}$	2,10	2,10	2,10
Табличное значение стандарт. норм. распр. z_y	1,96	1,96	1,96
Значение преобразования Фишера Z_r	2,25	1,54	1,92
Левая интервальная оценка для Z_r	1,78	1,06	1,44
Правая интервальная оценка для Z_r	2,73	2,01	2,39
Левая интервальная оценка для g_{xy}	0,94	0,79	0,89
Правая интервальная оценка для g_{xy}	0,99	0,96	0,98
Стандартное отклонение для g_{xy}	0,05	0,10	0,07
Количество наблюдений	20		

Рис. 2.5. Расчет параметров для примера 2.1

Пример. 2.3. В табл. 2.3 представлены данные о продаже квартир на рынке жилья в г. Краснодаре в 2021 г. y – цена квартиры (тыс. р.), x_1 – общая площадь квартиры (м^2), x_2 – жилая площадь квартиры (м^2), x_3 – площадь кухни (м^2), x_4 – этаж.

Требуется:

- 1) оценить матрицу парных коэффициентов корреляции W ;
- 2) вычислить выборочный частный коэффициент корреляции $r(01|234)$;
- 3) проверить гипотезы (при уровне значимости критерия $\alpha = 0,05$) о статистически незначимом отличии от нуля выборочных парных и частных коэффициентов корреляции, соответственно, r_{01} , r_{04} и $r(01|234)$;
- 4) найти оценку $R_{y.X}$, где $X = (x_1, x_2, x_3, x_4)$, множественного коэффициента корреляции и проверить гипотезу (при уровне

значимости критерия $\alpha = 0,05$) о его статистически незначимом отличии от нуля.

Таблица 2.3

№	y	x_1	x_2	x_3	x_4
1	3000	40	23,0	13,0	2
2	8500	107	80,0	15,0	5
3	11500	138	90,0	20,0	2
4	8000	120	80,0	18,0	14
5	5200	46	21,5	12,5	6
6	3500	40	20,0	10,0	13
7	3700	41	19,0	10,0	9
8	4600	64	32,0	10,5	8
9	4700	60	38,0	11,0	6
10	4500	65	35,0	13,0	2
11	5600	73	50,0	14,0	2
12	3300	58	32,0	11,5	6
13	6100	87	55,0	15,0	4
14	5400	78	41,5	19,0	14
15	6000	76	45,0	8,0	2

Решение. 1. В табл. 2.4 представлена матрица коэффициентов парной корреляции для всех переменных.

Таблица 2.4

	y	x_1	x_2	x_3	x_4
y	1				
x_1	0,945	1			
x_2	0,933	0,982	1		
x_3	0,687	0,742	0,706	1	
x_4	-0,135	-0,054	-0,105	0,153	1

Матрица получена с помощью инструмента *Корреляция* из пакета *Анализ данных* в Excel (прил. 1).

Заполнив пустые ячейки, получаем выборочную корреляционную матрицу

$$W = \begin{pmatrix} 1 & 0,94 & 0,93 & 0,69 & -0,13 \\ 0,94 & 1 & 0,98 & 0,74 & -0,05 \\ 0,93 & 0,98 & 1 & 0,71 & -0,11 \\ 0,69 & 0,74 & 0,71 & 1 & 0,15 \\ -0,13 & -0,05 & -0,11 & 0,15 & 1 \end{pmatrix}.$$

2. Рассчитаем выборочный частный коэффициент корреляции по формуле (2.4). Подробно разберем вычисление выборочного частного коэффициента между факторами цены и общей площади, исключая влияние факторов жилой площади, площади кухни и этаж

$$r(01|234) = -\frac{W_{01}}{\sqrt{W_{00} \cdot W_{11}}} = -\frac{-0,0122}{\sqrt{0,0133 \cdot 0,0559}} = 0,449,$$

где

$$W_{00} = (-1)^0 \begin{pmatrix} 1 & 0,98 & 0,74 & -0,05 \\ 0,98 & 1 & 0,71 & -0,11 \\ 0,74 & 0,71 & 1 & 0,15 \\ -0,05 & -0,11 & 0,15 & 1 \end{pmatrix} = 0,0133,$$

$$W_{11} = (-1)^2 \begin{pmatrix} 1 & 0,93 & 0,69 & -0,13 \\ 0,93 & 1 & 0,71 & -0,11 \\ 0,69 & 0,71 & 1 & 0,15 \\ -0,13 & -0,11 & 0,15 & 1 \end{pmatrix} = 0,0559,$$

$$W_{01} = (-1)^1 \begin{pmatrix} 0,94 & 0,98 & 0,74 & -0,05 \\ 0,93 & 1 & 0,71 & -0,11 \\ 0,69 & 0,71 & 1 & 0,15 \\ -0,13 & -0,11 & 0,15 & 1 \end{pmatrix} = -0,0122.$$

Для вычисления определителей можно использовать функцию *МОПРЕД* (прил. 1).

3. Для проверки статистически незначимого отличия от нуля коэффициентов корреляции, т.е. для проверки гипотез $H_0: r = 0$, найдем по формуле (2.9) наблюдаемые значения t -статистики и представим их в табл. 2.5

Таблица 2.5

	y	x_1	x_2	x_3	x_4
y	–				
x_1	10,38	–			
x_2	9,32	18,77	–		
x_3	3,41	3,99	3,59	–	
x_4	–0,49	–0,19	–0,38	0,56	–

При $\alpha = 0,05$ и степенях свободы $n - 2 = 13$, находим $t_{кр}(0,05; 13) = 2,16$.

Для выборочных парных коэффициентов корреляции $r_{01} = 0,94$, $r_{04} = -0,13$ наблюдаемые значения t -статистики соответственно 10,38 и –0,49. Поскольку $10,38 > 2,16$, а $|-0,49| < 2,16$, то гипотеза H_0 для $r_{01} = 0,94$ отвергается с вероятностью ошибки 0,05, а гипотеза H_0 для $r_{04} = -0,13$ не отвергается. Другими словами, между ценой квартиры и общей площадью существует статистически значимая положительная линейная корреляционная связь, а предположение об отсутствии линейной корреляционной связи между ценой квартиры и этажом не противоречит наблюдениям.

Для проверки статистически незначимого отличия от нуля коэффициента $r(01|234)$ используем формулу (2.5), где $l = 3$. В результате

$$\text{получаем } t_{\text{набл}} = \frac{0,449}{\sqrt{1 - 0,449^2}} \cdot \sqrt{15 - 3 - 2} = 1,59, \quad \text{а}$$

$$t_{кр}(0,05; 10) = 2,23.$$

Поскольку $1,59 < 2,23$, то гипотеза H_0 не отвергается, т.е. линейная связь между ценой квартиры и общей площадью при исключении влияния остальных факторов является статистически незначимой.

4. Найдем точечную оценку множественного коэффициента корреляции по формуле (2.6):

$$R_{y.X} = \sqrt{1 - \frac{0,00134}{0,0133}} = 0,948.$$

Для проверки гипотезы $H_0: R_{y.X} = 0$ используем F -статистику, в нашем примере она равна $F_{\text{набл}} = \frac{0,948^2}{1 - 0,948^2} \cdot \frac{15 - 4 - 1}{4} = 22,37$, а

$F_{\text{кр}}(0,05; 4; 10) = 3,48$ (используется функция $F.OБР.ПХ$). Поскольку $22,37 > 3,48$, то гипотеза об отсутствии линейной корреляционной связи между ценой квартиры и остальными факторами отвергается.

Пример. 2.4. Используя результаты, полученные в примере 2.1, провести выбор факторов:

1) методом анализа корреляционной матрицы при уровне значимости $\alpha = 0,05$;

2) методом показателей информационной емкости;

3) с помощью критерия множественного коэффициента корреляции при выборе двух факторов из трех x_1, x_2, x_3 .

Решение. 1. В примере 2.1 были найдены парные коэффициенты корреляции. Имеем вектор коэффициентов корреляции эндогенной переменной с потенциальными экзогенными переменными

$$R_0^T = (0,94; 0,93; 0,69; -0,13)$$

и матрицу коэффициентов корреляции между потенциальными экзогенными переменными

$$R = \begin{pmatrix} 1 & 0,98 & 0,74 & -0,05 \\ 0,98 & 1 & 0,71 & -0,11 \\ 0,74 & 0,71 & 1 & 0,15 \\ -0,05 & -0,11 & 0,15 & 1 \end{pmatrix}.$$

По найденному значению $t_{\text{кр}}(0,05; 13) = 2,16$ рассчитываем критическое значение коэффициента корреляции по формуле (2.8)

$r^* = 0,51$. В первую очередь из множества потенциальных экзогенных переменных исключаем все переменные, которые коррелируют с эндогенной переменной на уровне, меньшем по модулю, чем 0,51. Это переменная x_4 , для которой $r_{04} = -0,13$. Из оставшихся переменных выбираем ту переменную, которая сильнее всего коррелирует с эндогенной переменной, т.е. x_1 , поскольку $r_{01} = 0,94$. Переменная x_1 признается первым фактором, включенным в модель. Теперь исключаем все переменные, для которых выполняется неравенство $|r_{1j}| > 0,51$. Имеются две такие переменные x_2 и x_3 ($r_{12} = 0,98$; $r_{13} = 0,74$). В результате множество факторов, включенных в модель, состоит из одной переменной x_1 – общая площадь квартиры.

2. Поскольку рассматриваются четыре потенциальные переменные, необходимо проанализировать $L = 2^4 - 1 = 15$ комбинаций переменных. Перечислим все эти комбинации.

Однофакторные

$$C_1 = x_1, \quad C_2 = x_2, \quad C_3 = x_3, \quad C_4 = x_4.$$

Двухфакторные

$$\begin{aligned} C_5 &= (x_1, x_2), \quad C_6 = (x_1, x_3), \quad C_7 = (x_1, x_4), \\ C_8 &= (x_2, x_3), \quad C_9 = (x_2, x_4), \quad C_{10} = (x_3, x_4). \end{aligned}$$

Трехфакторные

$$\begin{aligned} C_{11} &= (x_1, x_2, x_3), \quad C_{12} = (x_1, x_2, x_4), \quad C_{13} = (x_1, x_3, x_4), \\ C_{14} &= (x_2, x_3, x_4). \end{aligned}$$

Четырехфакторная

$$C_{15} = (x_1, x_2, x_3, x_4).$$

Рассчитаем индивидуальные и интегральные показатели информационной емкости по формулам (2.14) и (2.15). Интегральные показатели одноэлементных комбинаций равны индивидуальным показателям, которые в свою очередь равны квадратам коэффициентов корреляции, таким образом

$$\begin{aligned} H_1 &= h_{11} = r_{01}^2 = (0,94^2) = 0,89; & H_2 &= h_{21} = r_{02}^2 = 0,87; \\ H_3 &= h_{31} = r_{03}^2 = 0,47; & H_4 &= h_{41} = r_{04}^2 = 0,02. \end{aligned}$$

Для двухэлементных комбинаций рассчитывают два индивидуальных показателя

$$h_{51} = \frac{r_{01}^2}{1 + |r_{12}|} = \frac{(0,94^2)}{1 + 0,98} = 0,45; \quad h_{52} = \frac{r_{02}^2}{1 + |r_{12}|} = 0,44;$$

$$H_5 = h_{51} + h_{52} = 0,89;$$

$$h_{61} = 0,51; \quad h_{62} = 0,27; \quad H_6 = 0,78;$$

$$h_{71} = 0,85; \quad h_{72} = 0,02; \quad H_7 = 0,86;$$

$$h_{81} = 0,51; \quad h_{82} = 0,28; \quad H_8 = 0,79;$$

$$h_{91} = 0,79; \quad h_{92} = 0,02; \quad H_9 = 0,81;$$

$$h_{10,1} = 0,41; \quad h_{10,2} = 0,02; \quad H_{10} = 0,43.$$

Для трехэлементных комбинаций рассчитывают по три индивидуальных показателя

$$h_{11,1} = \frac{r_{01}^2}{1 + |r_{12}| + |r_{13}|} = 0,33; \quad h_{11,2} = \frac{r_{02}^2}{1 + |r_{12}| + |r_{23}|} = 0,32;$$

$$h_{11,3} = \frac{r_{03}^2}{1 + |r_{13}| + |r_{23}|} = 0,19; \quad H_{11} = h_{11,1} + h_{11,2} + h_{11,3} = 0,84;$$

$$h_{12,1} = 0,44; \quad h_{12,2} = 0,42; \quad h_{12,3} = 0,02; \quad H_{12} = 0,87;$$

$$h_{13,1} = 0,50; \quad h_{13,2} = 0,25; \quad h_{13,3} = 0,02; \quad H_{13} = 0,76;$$

$$h_{14,1} = 0,48; \quad h_{14,2} = 0,25; \quad h_{14,3} = 0,01; \quad H_{14} = 0,75.$$

Рассчитаем показатели для последней комбинации C_{15}

$$h_{15,1} = \frac{r_{01}^2}{1 + |r_{12}| + |r_{13}| + |r_{14}|} = 0,32;$$

$$h_{15,2} = \frac{r_{02}^2}{1 + |r_{12}| + |r_{23}| + |r_{24}|} = 0,31;$$

$$h_{15,3} = \frac{r_{03}^2}{1 + |r_{13}| + |r_{23}| + |r_{34}|} = 0,18;$$

$$h_{15,4} = \frac{r_{04}^2}{1 + |r_{14}| + |r_{24}| + |r_{34}|} = 0,01;$$

$$H_{15} = h_{15,1} + h_{15,2} + h_{15,3} + h_{15,4} = 0,83.$$

Максимальное значение интегрального показателя информационной емкости равно 0,89 и относится к комбинации C_5 , включающей переменные x_1 (общая площадь квартиры) и x_2 (жилая площадь квартиры).

3. Найдем множественные коэффициенты корреляции между y и парами (x_1, x_2) , (x_1, x_3) , (x_2, x_3) .

Корреляционная матрица для переменных y, x_1, x_2 имеет вид

$$W_1 = \begin{pmatrix} 1 & 0,94 & 0,93 \\ 0,94 & 1 & 0,98 \\ 0,93 & 0,98 & 1 \end{pmatrix},$$

следовательно, $R_{y.x_1, x_2} = \sqrt{1 - \frac{0,004}{0,036}} = 0,945$.

Корреляционная матрица для переменных y, x_1, x_3 имеет вид

$$W_2 = \begin{pmatrix} 1 & 0,94 & 0,69 \\ 0,94 & 1 & 0,74 \\ 0,69 & 0,74 & 1 \end{pmatrix},$$

следовательно, $R_{y.x_1, x_3} = \sqrt{1 - \frac{0,048}{0,45}} = 0,94$.

Корреляционная матрица для переменных y, x_2, x_3 имеет вид

$$W_3 = \begin{pmatrix} 1 & 0,93 & 0,69 \\ 0,93 & 1 & 0,71 \\ 0,69 & 0,71 & 1 \end{pmatrix},$$

следовательно, $R_{y.x_2, x_3} = \sqrt{1 - \frac{0,06}{0,5}} = 0,93$.

Наибольшее значение множественного коэффициента корреляции соответствует набору факторов x_1 – общая площадь квартиры; x_2 – жилая площадь квартиры.

4. Рассмотрим комбинацию переменных y и пару (x_1, x_2) . Для проверки гипотезы о равенстве множественного коэффициента

корреляции и выборочного парного коэффициента корреляции составим разность этих коэффициентов. Очевидно, $r_{yx_1}^2 \leq R_{y.x_1, x_2}^2$, так как каждая дополнительная переменная объясняет часть рассеивания зависимой переменной. Тогда проверяя гипотезу $H_0 : R_{y.x_1, x_2}^2 - r_{yx_1}^2 = 0$, можно определить, существенно ли ухудшилось качество описания поведения зависимой переменной. Для этого используют статистику:

$$F = \frac{R_{y.x_1, x_2}^2 - r_{yx_1}^2}{1 - R_{y.x_1, x_2}^2} \cdot \frac{n - p - 1}{k}.$$

Если величина F превосходит критическое $F_{кр} = F(\alpha; k; n - p - 1)$ на требуемом уровне значимости α , то нуль-гипотеза должна быть отклонена. В этом случае одновременное исключение из рассмотрения $k = 1$ объясняющих переменных некорректно, так как $R_{y.x_1, x_2}^2$ существенно превышает $r_{yx_1}^2$.

Рассчитаем частные F -критерии Фишера и оценим целесообразность включения в уравнение одного из факторов после другого.

$$H_0 : R_{y.x_1, x_2}^2 = r_{yx_1}^2 ; H_1 : R_{y.x_1, x_2}^2 \neq r_{yx_1}^2 ;$$

$$F_{набл1} = \frac{0,945 - 0,89}{1 - 0,945} \cdot \frac{15 - 2 - 1}{1} = 11,49 > F_{кр}(0,05; 1; 12) = 4,75,$$

следовательно, приходим к выводу о целесообразности включения в модель фактора x_2 после фактора x_1 .

$$H_0 : R_{y.x_1, x_2}^2 = r_{yx_2}^2 ; H_1 : R_{y.x_1, x_2}^2 \neq r_{yx_2}^2 ;$$

$$F_{набл2} = \frac{0,945 - 0,87}{1 - 0,945} \cdot \frac{15 - 2 - 1}{1} = 16,4 > F_{кр}(0,05; 1; 12) = 4,75,$$

следовательно, приходим к выводу о целесообразности включения в модель фактора x_1 после фактора x_2 .

3. РЕГРЕССИЯ

3.1. ПОСТАНОВКА ЗАДАЧИ РЕГРЕССИИ

Регрессионный анализ заключается в определении аналитической формы связи, в которой изменение результативного признака обусловлено влиянием одного или нескольких факторных признаков, а множество всех прочих факторов, также оказывающих влияние на результативный признак, принимается за постоянные и средние значения.

Регрессия – функциональная зависимость между объясняющими переменными и условным математическим ожиданием (средним значением) зависимой переменной, которая строится с целью прогнозирования этого среднего значения при фиксированных значениях объясняющих переменных.

Цель регрессионного анализа – оценка функциональной зависимости условного среднего значения результативного признака от факторных признаков.

Основной предпосылкой регрессионного анализа является то, что результативный признак подчиняется нормальному закону распределения, а факторные признаки – произвольному закону распределения. При этом предполагается (в отличие от корреляционного анализа) наличие причинно-следственной связи между результатом и факторами.

Уравнение регрессионной связи может быть записано в виде

$$\begin{aligned} Y &= M[Y / x] + \varepsilon = \varphi(x) + \varepsilon, \\ Y &= M[Y / x_1, \dots, x_m] + \varepsilon = \varphi(x_1, \dots, x_m) + \varepsilon, \end{aligned} \quad (3.1)$$

$M[Y/x] = \varphi(x)$ – парная регрессия;

$M[Y/x_1, \dots, x_m] = \varphi(x_1, \dots, x_m)$ – множественная регрессия;

где $\varphi(X) \neq \text{const}$;

X – объясняющая, входная, предсказывающая, экзогенная, неслучайная переменная, фактор, регрессор, факторный признак;

Y – зависимая, объясняемая, выходная, результирующая, эндогенная, случайная переменная, результирующий признак;

ε – случайный фактор (остаток), обусловленный многими

причинами.

В зависимости от вида функции $\varphi(X)$ модели делятся на линейные и нелинейные.

Причины обязательного присутствия случайного фактора:

- 1) невключение в модель всех объясняющих переменных;
- 2) неправильный выбор функциональной формы модели;
- 3) агрегирование переменных (факторы представляют собой комбинацию других переменных);
- 4) ошибки измерений;
- 5) ограниченность статистических данных;
- 6) непредсказуемость человеческого фактора.

Пусть имеется n наблюдений объясняющих переменных и соответствующих им значений результативного признака, тогда эмпирическое уравнение регрессии:

$$\hat{Y} = \beta_0 + \beta_1 X \quad \text{или} \\ \hat{y}_i = \beta_0 + \beta_1 x_i.$$

Самый распространенный метод оценки параметров – метод наименьших квадратов (МНК)

$$b_0, b_1: \sum_{i=1}^n \left(y_i - \underbrace{(b_0 + b_1 x_i)}_{\hat{y}_i} \right)^2 = \sum_{i=1}^n e_i^2 \rightarrow \min.$$

3.2. ПРЕДПОСЫЛКИ ИСПОЛЬЗОВАНИЯ МНК (УСЛОВИЯ ГАУССА – МАРКОВА)

Пусть мы располагаем n парами выборочных наблюдений: $X_1, X_2, \dots, X_n$ и $Y_1, Y_2, \dots, Y_n$.

Для того чтобы регрессионный анализ, основанный на обычном методе наименьших квадратов, давал наилучшие из всех возможных результаты, случайная ошибка должна удовлетворять определенным условиям, известным как условия Гаусса – Маркова.

Понимание важности этих условий отличает компетентного исследователя от некомпетентного. Если условия не выполнены, надо это осознавать. А именно, если возможно, то провести корректирующие действия; если невозможна корректировка, то оценить, как невыполнение условий влияет на результат.

Первое условие Гаусса – Маркова состоит в том, что математическое ожидание случайной ошибки в любом наблюдении должно быть равно нулю:

$$M(\varepsilon_i) = 0, i = 1, \dots, n.$$

Это требование состоит в том, что математическое ожидание случайного члена в любом наблюдении должно быть равно нулю. Иногда случайный член будет положительным, иногда отрицательным, но он не должен иметь систематического смещения ни в одном из двух возможных направлений.

Второе условие Гаусса – Маркова состоит в том, что дисперсия ошибки постоянна для всех наблюдений:

$$D(\varepsilon_i) = \sigma^2 = \text{const}, i = 1, \dots, n.$$

Из данного условия следует: несмотря на то, что при каждом конкретном наблюдении случайное отклонение ε_i может быть различным, не должно быть причин, вызывающих большую ошибку.

Условие независимости дисперсии от номера наблюдения называется гомоскедастичностью (homoscedasticity). Случай непостоянства дисперсии для разных наблюдений называется гетероскедастичностью (heteroscedasticity).

Иногда случайная ошибка будет больше, иногда меньше, однако не должно быть такого, что в одних наблюдениях ошибка систематически больше, чем в других. Эта постоянная дисперсия обозначается σ^2 .

Величина σ^2 неизвестна. Одна из задач регрессионного анализа состоит в ее оценке, точнее, оценке стандартного отклонения случайного члена.

Третье условие Гаусса – Маркова: условие некоррелированности ошибок состоит в том, что предполагается отсутствие систематической связи между значениями случайной ошибки в любых двух наблюдениях:

$$\sigma_{\varepsilon_i \varepsilon_j} = \text{Cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} 0, & i \neq j; \\ \sigma^2, & i = j. \end{cases}$$

Например, если случайная ошибка в одном наблюдении велика и положительна, то это не должно обуславливать систематическую тенденцию к тому, что в следующем наблюдении она будет обязательно мала и отрицательна (или велика и отрицательна, или мала и положительна). Случайные ошибки должны быть абсолютно независимы друг от друга, т. е. ковариация между ними должна быть равна нулю. Это условие часто нарушается, когда данные являются временными рядами. Когда условие некоррелированности ошибок не выполняется, говорят об автокорреляции ошибок.

Четвертое условие Гаусса – Маркова: случайная ошибка должна быть распределена независимо от объясняющих переменных:

$$\sigma_{\varepsilon_i X_i} = \text{Cov}(\varepsilon_i, X_i) = 0.$$

Это условие выполняется, если объясняющая переменная не является случайной в данной модели.

Значение объясняющей переменной X в каждом наблюдении должно считаться экзогенным, полностью определяемым внешними причинами, не учитываемыми в уравнении регрессии.

5-е условие Гаусса – Маркова: регрессионная модель является линейной относительно параметров, корректно специфицирована и содержит аддитивный случайный член

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Значение объясняющей переменной X в каждом наблюдении должно считаться экзогенным, полностью определяемым внешними причинами, не учитываемыми в уравнении регрессии.

Наряду с выполнимостью указанных предпосылок при построении линейных регрессионных моделей обычно делаются еще некоторые предположения, а именно:

– случайное отклонение имеет нормальный закон распределения;

- число наблюдений существенно больше числа объясняющих переменных;
- отсутствуют ошибки спецификации;
- отсутствует линейная взаимосвязь между двумя или несколькими объясняющими переменными.

Теорема Гаусса – Маркова. Если предпосылки 1–5 выполнены, то оценки, полученные по МНК, обладают следующими тремя свойствами.

1. Оценки являются несмещенными, т.е. $M[b_0] = \beta_0$, $M[b_1] = \beta_1$. Это говорит об отсутствии систематической ошибки при определении положения линии регрессии.

2. Оценки состоятельны, т.е. при $n \rightarrow \infty$ $D[b_0] \rightarrow 0$, $D[b_1] \rightarrow 0$. Это означает, что с ростом n надежность оценок возрастает.

3. Оценки эффективны, т.е. они имеют наименьшую дисперсию по сравнению с любыми другими оценками данных параметров, линейными относительно величин y_i .

3.3. ПАРНАЯ РЕГРЕССИЯ

В парной регрессии выбор вида математической функции (3.1) может быть осуществлен тремя методами:

1) *графическим*, который основан на выборе формулы по графическому изображению реальных статистических данных в виде точек (корреляционное поле или диаграмма рассеивания);

2) *аналитическим*, основанным на изучении природы связи исследуемых признаков;

3) *экспериментальным*, который используется при обработке информации на компьютере путем сравнения величины остаточной дисперсии, рассчитанной на разных моделях; чем меньше $D_{ост}$, тем меньше наблюдается влияние прочих факторов, тем лучше уравнение регрессии подходит к исходным данным; если $D_{ост}$ примерно одинакова для нескольких функций, то выбирают более простую, так как она в большей степени поддается интерпретации.

3.3.1. Парная линейная регрессия

Теоретическая парная линейная регрессионная модель:

$$y_i = M[Y / X = x_i] + \varepsilon_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

где β_0, β_1 – теоретические коэффициенты регрессии;

ε_i – случайное отклонение.

В общем виде теоретическую парную линейную регрессионную модель будем представлять так:

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

Задачи линейного регрессионного анализа состоят в том, чтобы по имеющимся статистическим данным (x_i, y_i) , $i = 1, 2, \dots, n$, для переменных X и Y :

- а) получить наилучшие оценки параметров β_0 и β_1 ;
- б) проверить статистические гипотезы о параметрах модели;
- в) проверить адекватность модели данным наблюдений.

По выборке ограниченного объема нельзя точно определить теоретические значения β_0 и β_1 .

Можно лишь построить эмпирическое уравнение регрессии:

$$\hat{y}_i = b_0 + b_1 x_i,$$

где b_0 и b_1 – оценки параметров β_0 и β_1 эмпирические коэффициенты регрессии; $\hat{y}_i$ – оценка условного м. о. $M[Y/X = x_i]$.

В результате имеем:

$$y_i = b_0 + b_1 x_i + e_i,$$

где e_i – оценка теоретического случайного отклонения ε_i .

Оценки b_0 и b_1 отличаются от истинных значений β_0 и β_1 , что приводит к несовпадению эмпирической и теоретической линий регрессии. По различным выборкам из одной и той же генеральной совокупности получают разные значения оценок коэффициентов регрессии.

Задача состоит в нахождении по выборке данных оценок b_0 и b_1 так, чтобы построенная линия регрессии была наилучшей в определенном смысле среди всех других прямых. Решение основано на минимизации:

$$g(y_i, x_i, b_0, b_1) \rightarrow \min, \quad i = \overline{1, n},$$

где g – некоторая функция.

Наиболее распространен метод наименьших квадратов (МНК), реализующий минимизацию суммы квадратов отклонений:

$$\sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2 = \sum_{i=1}^n e_i^2 \rightarrow \min.$$

где $e_i = y_i - \hat{y}_i$.

Основные особенности МНК:

- 1) он наиболее прост с вычислительной точки зрения;
- 2) оценки коэффициентов регрессии по МНК при определенных предпосылках обладают рядом оптимальных свойств.

Пусть по выборке данных (x_i, y_i) , $i = 1, 2, \dots, n$, требуется определить оценки b_0 и b_1 эмпирического уравнения регрессии (рис. 3.1).




Рис. 3.1. Метод наименьших квадратов

В этом случае минимизируется функция:

$$Q(b_0, b_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2 \rightarrow \min.$$

Так как функция $Q(b_0, b_1)$ непрерывна, выпукла и ограничена снизу, то она имеет минимум.

Необходимым условием минимума $Q(b_0, b_1)$ является равенство нулю ее частных производных по неизвестным параметрам b_0 и b_1 .

Приравняем нулю частные производные и затем разделим на n оба уравнения

$$\begin{cases} \frac{\partial Q}{\partial b_0} = -2 \sum (y_i - b_0 - b_1 x_i) = 0, \\ \frac{\partial Q}{\partial b_1} = -2 \sum (y_i - b_0 - b_1 x_i) x_i = 0. \end{cases} \Rightarrow \begin{cases} nb_0 + b_1 \sum x_i = \sum y_i, \\ b_0 \sum x_i + b_1 \sum x_i^2 = \sum x_i y_i. \end{cases}$$

Получаем

$$\Rightarrow \begin{cases} b_0 + b_1 \bar{x} = \bar{y}, \\ b_0 \bar{x} + b_1 \bar{x}^2 = \overline{xy}. \end{cases}$$

Решив последнюю систему уравнений, получим:

$$\Rightarrow \begin{cases} b_1 = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\bar{x}^2 - \bar{x}^2} = \frac{Cov(x, y)}{Var(x)} = r_{xy} \sqrt{\frac{Var(y)}{Var(x)}}, \\ b_0 = \bar{y} - b_1 \bar{x}. \end{cases} \quad (3.2)$$

Выводы

1. Оценки МНК являются функциями от выборки, что позволяет их легко рассчитать.

2. Оценки МНК являются точечными оценками теоретических коэффициентов регрессии.

3. Эмпирическая прямая регрессии обязательно проходит через точку $(\bar{x}, \bar{y})$.

4. Эмпирическое уравнение регрессии построено так, что $\sum e_i = 0$, $\bar{e} = 0$.

5. Случайные отклонения e_i не коррелированы с наблюдаемыми значениями y_i зависимой переменной Y .

6. Случайные отклонения e_i не коррелированы с наблюдаемыми значениями x_i независимой переменной X .

Оценки b_0 и b_1 называют *оценками наименьших квадратов* или *LS-оценками*. При выполнении предпосылок регрессионного анализа имеет место теорема Гаусса – Маркова:

Оценки b_0 и b_1 , полученные по МНК, имеют наименьшую дисперсию в классе всех линейных несмещенных оценок.

Параметр b_1 называется коэффициентом регрессии. Его величина показывает среднее изменение результата с изменением фактора на одну единицу. Возможность четкой экономической интерпретации коэффициента регрессии сделала уравнение парной линейной регрессии достаточно распространенным в эконометрических исследованиях.

Формально b_0 – значение y при $x = 0$. Если x не имеет или не может иметь нулевого значения, то свободный член не имеет смысла. Интерпретировать можно лишь знак при параметре b_0 . Если $b_0 > 0$, то относительное изменение результата происходит медленнее, чем изменение фактора.

Для линейного уравнения парной регрессии при свободном члене равном нулю применение метода наименьших квадратов сводится к минимизации суммы квадратов невязок

$$Q(b_1) = \sum_{i=1}^n (y_i - b_1 x_i)^2.$$

При этом коэффициент регрессии будет равен:

$$b_1 = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} = \frac{\overline{xy}}{\overline{x^2}}. \quad (3.3)$$

Параметр b_1 нельзя использовать для непосредственной оценки влияния факторного признака на результативный признак из-за различия единиц измерения исследуемых показателей. Для этих целей вычисляют коэффициент эластичности E_{xy} и бета-коэффициент β_{xy} .

Стандартизованный коэффициент (иногда используется термин «бета-коэффициент») определяется так:

$$\beta_{xy} = b_1 \frac{\sigma_x}{\sigma_y}. \quad (3.4)$$

Умножение на стандартное отклонение соответствующего регрессора и деление на стандартное отклонение отклика приводят к тому, что стандартизованный коэффициент не зависит от единиц измерения переменных модели. Кроме того, если коэффициенты при двух объясняющих переменных совпадают, стандартизованный коэффициент окажется больше у регрессора с большей дисперсией.

Коэффициент эластичности представляет собой показатель силы связи фактора x с результатом y , показывающий, на сколько процентов изменится значение y при изменении значения фактора на 1 %. Коэффициент эластичности рассчитывается как относительное изменение y на единицу относительного изменения x :

$$E_{xy} = b_1 \frac{\bar{x}}{\bar{y}}. \quad (3.5)$$

3.3.2. Оценка значимости уравнения и коэффициентов регрессии. Коэффициент детерминации

Следующая важная проблема состоит в том, чтобы определить, насколько «хороши» полученные оценки и уравнение регрессии.

Проверить значимость уравнения регрессии – значит, установить, соответствует ли математическая модель, выражающая зависимость между переменными, экспериментальным данным и достаточно ли включенных в уравнение объясняющих переменных (одной или нескольких) для описания зависимой переменной.

Анализ качества уравнения можно произвести на основе дисперсионного анализа. Для любой точки (x_i, y_i) на диаграмме рассеяния можно записать:

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}),$$

где $\hat{y}_i = b_0 + b_1 \cdot x_i$ – ордината точки «наилучшей» прямой.

Возведем обе части последнего представления в квадрат и

просуммируем левые и правые части полученных для каждого i равенства:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}). \quad (3.6)$$

Входящая в левую часть сумма называется **общей суммой квадратов** и имеет аббревиатуру **TSS** (*Total Sum of Squares*):

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2. \quad (3.7)$$

Входящая в правую часть сумма называется **суммой квадратов, объясненной моделью (факторной)** имеет аббревиатуру **ESS** (*Explained Sum of Squares*):

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2. \quad (3.8)$$

Входящая в правую часть сумма называется **остаточной (необъясненной) суммой квадратов** и имеет аббревиатуру **RSS** (*Residual Sum of Squares*):

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2. \quad (3.9)$$

Рассмотрим третью сумму в правой части (3.6):

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n (y_i - \hat{y}_i) \hat{y}_i - \bar{y} \cdot \sum_{i=1}^n e_i = \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)(b_0 + b_1 x_i) = b_0 \cdot \sum_{i=1}^n e_i + b_1 \cdot \sum_{i=1}^n e_i x_i = 0, \end{aligned}$$

так как $\sum_{i=1}^n e_i = 0$ и $\sum_{i=1}^n e_i x_i = 0$ (из предыдущего замечания).

В итоге получим соотношение:

$$TSS = ESS + RSS, \quad (3.10)$$

которое представляет собой разложение полной суммы квадратов на сумму квадратов, объясненную моделью, и остаточную сумму квадратов.

Отметим, что если уравнение (3.10) очень хорошо

соответствует данным, то сумма квадратов остатков в модели должна быть очень маленькой (так как каждый из остатков регрессии близок к нулю), и, следовательно, величина ESS должна быть очень близка к TSS. Иными словами, если уравнение (3.10) хорошо соответствует данным, то дробь ESS/TSS должна быть близка к единице. В крайнем случае, когда уравнение идеально соответствует данным и сумма квадратов остатков равна нулю, эта дробь будет в точности равна единице.

Число степеней свободы называется число независимых варьирующих значений признака.

Для общей суммы квадратов необходимо $(n - 1)$ независимых отклонений, так как по совокупности из n единиц после расчета среднего уровня свободно варьируют лишь $(n - 1)$ отклонение, то

$$D_{\text{общ}} = \frac{\sum (y - \bar{y})^2}{n - 1}.$$

Факторная сумма квадратов при линейной регрессии зависит только от одной константы – коэффициента регрессии b_1 . Поэтому данная сумма имеет одну степень свободы.

$$D_{\text{факт}} = \frac{\sum (\hat{y} - \bar{y})^2}{1}.$$

Подобно равенству (3.10) можно установить равенство между числом степеней свободы соответствующих сумм квадратов

$$n - 1 = 1 + (n - 2),$$

из которого видно, что число степеней свободы остаточной суммы квадратов при линейной регрессии составляет $(n - 2)$. Действительно, две степени свободы теряются при определении двух параметров регрессии из системы нормальных уравнений. Тогда

$$D_{\text{ост}} = \frac{\sum (y - \hat{y})^2}{n - 2}.$$

Сопоставляя факторную и остаточную дисперсии $H_0 : D_{\text{факт}} = D_{\text{ост}}$, получим F -критерий для проверки нулевой гипотезы о существенности статистической связи между y и x

$$F = \frac{D_{\text{факт}}}{D_{\text{ост}}} = \frac{ESS}{1} \cdot \frac{n-2}{RSS}. \quad (3.11)$$

Если $F_{\text{набл}} > F_{\text{кр}}(\alpha; 1; n-2)$, то H_0 отклоняется и делается вывод о существенности превышения $D_{\text{факт}}$ над $D_{\text{ост}}$, т.е. о существенности статистической связи между y и x . Если $F_{\text{набл}} < F_{\text{кр}}$, то гипотеза H_0 не может быть отклонена без риска сделать неправильный вывод о наличии связи между y и x .

Одной из наиболее эффективных оценок адекватности регрессионной модели, мерой качества уравнения регрессии является *коэффициент детерминации*. Он характеризует долю дисперсии результативного признака объясненной регрессией в общей дисперсии результативного признака и рассчитывается по формуле:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} \quad (3.12)$$

или

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Пределы его изменения от 0 до 1. Чем ближе этот коэффициент к единице, тем больше уравнение регрессии объясняет поведение y . Величина F -критерия связана с коэффициентом детерминации формулой:

$$F = \frac{R^2}{1 - R^2} \cdot (n-2). \quad (3.13)$$

При этом нулевая гипотеза $H_0 : R^2 = 0$ (о равенстве коэффициента детерминации нулю) отклоняется, если $F_{\text{набл}} > F_{\text{кр}}(\alpha; 1; n-2)$, и делается вывод о существенности статистической связи между y и x . В противном случае уравнение регрессии считается статистически незначимым. Из (3.13) видно, что показатели F и R^2 равны или не равны нулю одновременно. Если $F = 0$, то $R^2 = 0$, и линия регрессии $y = \bar{y}$ является наилучшей по МНК, и, следовательно, величина y линейно не зависит от x .

Рассмотрим случай линейной регрессии без свободного члена $\hat{y}_i = b_1 \cdot x_i$.

В такой ситуации $\sum_{i=1}^n (y_i - \bar{y})^2 \neq \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$, и поэтому использовать для вычисления коэффициента детерминации выражение (3.12) не имеет смысла.

Преодолеть возникающие затруднения можно, если определить

$$\sum_{i=1}^n y_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i + \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n \hat{y}_i^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i) \hat{y}_i.$$

Так как

$$\sum_{i=1}^n (y_i - \hat{y}_i) \hat{y}_i = \sum_{i=1}^n (y_i - b_1 x_i) b_1 x_i = b_1 \sum_{i=1}^n (y_i - b_1 x_i) x_i = 0,$$

то

$$\sum_{i=1}^n y_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n \hat{y}_i^2.$$

Разделим обе части последнего равенства на $\sum_{i=1}^n y_i^2$, приходим к соотношению

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n y_i^2} = \frac{\sum_{i=1}^n \hat{y}_i^2}{\sum_{i=1}^n y_i^2} \geq 0.$$

В результате для модели без свободного члена коэффициент детерминации вычисляется по формуле:

$$R^2 = 1 - \frac{RSS}{n\bar{y}}, \quad (3.14)$$

в которой используется сумма квадратов нецентрированных значений переменной.

Оценку дисперсии случайных отклонений линейной парной модели получаем из выражения

$$s_e^2 = \frac{\sum_{i=1}^n e_i^2}{n-2},$$

где $e_i = y_i - \hat{y}_i$.

Стандартное отклонение остатков модели s_e показывает, насколько в среднем наблюдаемые значения эндогенной переменной отличаются от теоретических значений этой переменной.

В линейной регрессии значимость уравнения может быть проведена и другим способом, если оценить значимость коэффициента регрессии b_1 . Гипотеза $H_0: b_1 = 0$ проверяется на основе t -статистики, имеющей распределение Стьюдента с $k = n - 2$ степенями свободы и рассчитываемой по формуле

$$t_{\text{набл}} = \frac{b_1 - 0}{s_e} \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{b_1}{s_{b_1}}, \quad (3.15)$$

где s_e – остаточная дисперсия;

$$s_{b_1} = \sqrt{\frac{s_e^2}{\sum (x - \bar{x})^2}} - \text{дисперсия коэффициента регрессии.}$$

Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha; n - 2)$, то гипотеза H_0 отвергается, коэффициент статистически значим, таким образом, существует линейная зависимость между независимым фактором x и зависимой переменной y .

Оценка значимости коэффициента регрессии b_0 (гипотеза $H_0: b_0 = 0$) рассчитывается по формуле

$$t_{\text{набл}} = \frac{b_0}{s_{b_0}}, \quad (3.16)$$

где $s_{b_0} = \sqrt{s_e^2 \cdot \frac{\sum x^2}{n \sum (x - \bar{x})^2}} = s_{b_1} \sqrt{\overline{x^2}}$ – дисперсия коэффициента регрессии b_0 .

Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha; n - 2)$, то гипотеза H_0 отвергается, коэффициент статистически значим. В данном случае вывод о существовании линейной зависимости нельзя сделать.

Замечание

1. Для парной линейной регрессии коэффициент детерминации равен квадрату коэффициента корреляции между переменными:

$$R_{xy}^2 = r_{xy}^2.$$

2. Существует связь между t_b и F : $t_b^2 = F$.

Действительно,

$$t_b^2 = \frac{b^2 \sum (x - \bar{x})^2}{\sum (y - \hat{y}_x)^2 / (n-2)} = \frac{\sum (\hat{y}_x - \bar{y})^2 / 1}{\sum (y - y_x)^2 / (n-2)} = \frac{D_{\text{факт.}}}{D_{\text{ост.}}} = F.$$

Однако высокое значение R^2 может быть близким к единице в силу того, что обе исследуемые величины имеют выраженный временной тренд, не связанный с их причинно-следственной связью. Последнее обстоятельство часто наблюдается при анализе различных экономических показателей, вычисленных без поправки на инфляцию (недефлированные данные).

Правило оценки значимости коэффициентов регрессии без использования таблиц

1. Если $|t_{b_i}| \leq 1$, то коэффициент b_i не может быть признан значимым, так как доверительная вероятность менее 0,7.

2. Если $1 < |t_{b_i}| \leq 2$, то найденная оценка может рассматриваться как относительно (слабо) значимая. При этом доверительная вероятность лежит между 0,7 и 0,95.

3. Если $2 < |t_{b_i}| \leq 3$, то коэффициент значим. Доверительная вероятность лежит между значениями 0,95 и 0,99.

4. Если $|t_{b_i}| > 3$, то это почти полная гарантия значимости коэффициента.

3.3.3. Интервальная оценка функции регрессии и ее параметров

Доверительные интервалы для коэффициентов регрессии

Построим доверительные интервалы для коэффициентов линейной регрессии при заданном уровне значимости α . Для статистически значимых коэффициентов регрессии b_0 и b_1 доверительные интервалы определяются для b_0 :

$$b_0 - s_{b_0} \cdot t_{\text{кр}} \leq \beta_0 \leq b_0 + s_{b_0} \cdot t_{\text{кр}}; \quad (3.17)$$

для b_0 :

$$b_1 - s_{b_1} \cdot t_{\text{кр}} \leq \beta_1 \leq b_1 + s_{b_1} \cdot t_{\text{кр}}. \quad (3.18)$$

Доверительные интервалы с надежностью $(1 - \alpha)$ накрывают истинные значения β_0 и β_1 .

Порядок работы при проверке значимости коэффициента по доверительному интервалу

1. Выбираем уровень значимости α (1 или 5%).
2. Вычисляем число степеней свободы $(n - p - 1)$.
3. По таблицам распределения Стьюдента определяем критическое значение $t_{\text{кр}}(\alpha; n - p - 1)$.
4. Вычисляем границы доверительного интервала.
5. Если точка 0 (ноль) не лежит внутри доверительного интервала, то коэффициент является значимым на уровне значимости α .
6. В противном случае коэффициент не значим (на данном уровне α).

Доверительные области для зависимой переменной

Одной из центральных задач эконометрики является прогнозирование значений зависимой переменной при определенных значениях объясняющих переменных.

Здесь возможны два варианта.

1. Предсказать условное математическое ожидание зависимой переменной при определенных значениях объясняющих переменных (предсказание *среднего значения*).

2. Предсказать некоторое конкретное значение зависимой переменной (предсказание *конкретного значения*).

Рассмотрим предсказание среднего значения зависимой переменной.

Пусть построено уравнение регрессии $\bar{y}(x_i) = b_0 + b_1 x_i$. На его основе необходимо предсказать условное математическое ожидание

$$M[Y | X = x_p] = \beta_0 + \beta_1 x_p$$

переменной Y при $X = x_p$.

Вопрос. Как сильно может уклониться значение $\bar{y}(x_p)$ от $M[Y | X = x_p]$?

Доверительная область для условного математического ожидания $M[Y | X = x_p]$:

$$(y_{\min}; y_{\max}) = (b_0 + b_1 x - t_{kp} \cdot S_{\bar{y}(x_p)}; b_0 + b_1 x + t_{kp} \cdot S_{\bar{y}(x_p)}), \quad (3.19)$$

$$S_{\bar{y}(x_p)}^2 = s_e^2 \left(\frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right).$$

При $x_p = \bar{x}$ она минимальна, а по мере удаления x_p от $\bar{x}$ величина доверительной области увеличивается.

Построенная доверительная область для $M_x[Y]$ определяет местоположение модельной линии регрессии (условного математического ожидания), а не отдельных возможных значений зависимой переменной (рис. 3.2), которые отклоняются от среднего $\bar{x}$.

Оценка дисперсии индивидуальных значений $\hat{y}_p = b_0 + b_1 x_p$ при $x = x_p$ равна

$$S_{\hat{y}_p}^2 = s_e^2 \left(1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right). \quad (3.20)$$

Доверительная область для прогнозов индивидуальных значений имеет вид:

$$b_0 + b_1 x_p - t_{кр} \cdot S_{\hat{y}_p} < y_p^* < b_0 + b_1 x_p + t_{кр} \cdot S_{\hat{y}_p}.$$

Доверительная область для индивидуальных значений y_p^* (рис. 3.2) шире доверительной области для условного математического ожидания $M[Y | X = x_p]$.




Рис. 3.2. Графики доверительных областей для зависимой переменной

Выводы по доверительным областям для зависимой переменной

1. Прогноз значений зависимой переменной Y по уравнению регрессии оправдан, если значение x объясняющей переменной X не выходит за диапазон ее значений по выборке. Причем, чем ближе x_p к $\bar{x}$, тем точнее прогноз (уже доверительный интервал).

2. Использование линии регрессии вне обследованного диапазона значений объясняющей переменной (даже если оно оправдано, исходя из смысла решаемой задачи) может привести к значительным погрешностям.

3.4. НЕЛИНЕЙНАЯ РЕГРЕССИЯ

Нелинейные соотношения гораздо лучше подходят для описания многих экономических процессов, чем линейные. Одним из недостатков линейного регрессионного анализа, как это следует из самого названия, является то, что он может быть применен только к линейным уравнениям, где каждый объясняющий элемент (за исключением свободного члена) записывается как произведение коэффициента и переменной

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2. \quad (3.22)$$

Уравнения вида

$$Y = \beta_0 + \frac{\beta_1}{X}, \quad (3.23)$$

$$Y = \beta_0 X^{\beta_1} \quad (3.24)$$

являются нелинейными. Тем не менее именно зависимости эти считаются приемлемыми для описания кривых Энгеля, характеризующих соотношение между спросом на определенный товар Y и общей суммой дохода X .

Как можно определить параметры β_0 и β_1 в каждом уравнении, имея данные о значениях Y и X ? В действительности в обоих случаях можно в конце концов применить линейный регрессионный анализ.

Прежде всего заметим, что уравнение (3.22) является линейным в двух смыслах. Правая часть его линейна по переменным, если определить их в представленном виде, а не как функции. Следовательно, она состоит из взвешенной суммы переменных, а параметры являются весами. Правая часть также линейна по параметрам, так как она состоит из взвешенной суммы параметров, а переменные в данном случае являются весами.

Для целей линейного регрессионного анализа важное значение имеет только второй тип линейности. Нелинейность по переменным всегда можно обойти путем использования соответствующих определений. Например, предположим, что соотношение имеет вид

$$Y = \beta_0 + \beta_1 X_1^2 + \beta_2 \sqrt{X_2} + \beta_3 \log X_3. \quad (3.25)$$

Если определить

$$Z_1 = X_1^2, \quad Z_2 = \sqrt{X_2}, \quad Z_3 = \log X_3$$

и т.д., то соотношение примет следующий вид:

$$Y = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \beta_3 Z_3.$$

И теперь оно является линейным как по переменным, так и по параметрам. Такой тип преобразований является лишь косметическим, и обычно уравнения регрессии записываются с нелинейными выражениями относительно переменных. Это позволяет избежать лишних обозначений.

В то же время уравнение типа (3.24) является нелинейным как по параметрам, так и по переменным, и его нельзя преобразовать только путем замены определений. Эта функция может быть преобразована в линейную путем использования логарифмов. Уравнение (3.24) можно преобразовать в линейное как

$$\ln Y = \ln \beta_0 + \beta_1 \ln X.$$

Если обозначить $Y' = \ln Y$, $Z = \ln X$ и $\beta_0' = \ln \beta_0$, то уравнение можно переписать в следующем виде

$$Y' = \beta_0' + \beta_1 Z.$$

Процедура оценивания регрессии теперь будет следующей. Сначала вычислим Y' и Z для каждого наблюдения путем логарифмирования исходных значений. Затем оценивается регрессия Y' на Z . Коэффициент при Z будет представлять собой непосредственно оценку β_1 . Постоянный член является оценкой β_0' , т.е. $\ln \beta_0$. Для получения оценки необходимо вычислить $\exp(\beta_0')$.

$$\beta_1 = \frac{\overline{Y'Z} - \bar{Y}' \cdot \bar{Z}}{\overline{Z^2} - \bar{Z}^2}, \quad (3.26)$$

$$\beta_0' = \bar{Y}' - \beta_1 \cdot \bar{Z}.$$

Еще одна широко распространенная функциональная форма представлена уравнением вида

$$Y = \beta_0 e^{\beta_1 X}.$$

Данная функция может быть трансформирована в модель, линейную по параметрам, путем логарифмирования обеих частей:

$$\ln Y = \ln \beta_0 e^{\beta_1 X} = \ln \beta_0 + \ln e^{\beta_1 X} = \ln \beta_0 + \beta_1 X \ln e = \ln \beta_0 + \beta_1 X.$$

Заметим, что только левая часть является логарифмической по переменным, и поэтому сама модель названа полулогарифмической.

Интерпретация коэффициента β_1 как относительного изменения Y на единицу изменения X правомерна лишь для малых β_1 ($< 0,1$). Если β_1 велико, то интерпретация становится несколько более сложной.

Обозначим прирост зависимой переменной как

$$\Delta y = \frac{y_1 - y_0}{y_0} = \frac{y_1}{y_0} - 1 = \frac{\beta_0 e^{\beta_1 x_1}}{\beta_0 e^{\beta_1 x_0}} - 1 = e^{\beta_1 \Delta x} - 1.$$

Таким образом, при изменении X на единицу Y изменится на $(e^{\beta_1} - 1) \cdot 100\%$.

Широкое использование степенной функции связано с тем, что параметр β_1 в ней имеет четкое экономическое истолкование: он является коэффициентом эластичности. (Коэффициент эластичности показывает, на сколько процентов изменится в среднем результат, если фактор изменится на 1%.) Формула для расчета коэффициента эластичности имеет вид:

$$\mathcal{E} = f'(x) \frac{x}{y}.$$

Так как для остальных функций коэффициент эластичности не является постоянной величиной, а зависит от соответствующего значения фактора x , то обычно рассчитывается средний коэффициент эластичности:

$$\mathcal{E} = f'(x) \frac{\bar{x}}{\bar{y}}. \quad (3.27)$$

Формулы для расчета средних коэффициентов эластичности для наиболее часто используемых типов уравнений регрессии приведены в табл. 3.1.

Таблица 3.1

Вид функции, y	Первая производная, y'	Средний коэффициент эластичности, $\bar{\varepsilon}$
$y = a + b \cdot x + \varepsilon$	b	$\frac{b \cdot \bar{x}}{a + b \cdot \bar{x}}$
$y = a + b \cdot x + c \cdot x^2 + \varepsilon$	$b + 2c \cdot x$	$\frac{(b + 2c \cdot \bar{x}) \cdot \bar{x}}{a + b \cdot \bar{x} + c \cdot \bar{x}^2}$
$y = a + \frac{b}{x} + \varepsilon$	$-\frac{b}{x^2}$	$-\frac{b}{a \cdot \bar{x} + b}$
$y = a \cdot x^b \cdot \varepsilon$	$a \cdot b \cdot x^{b-1}$	b
$y = a \cdot b^x \cdot \varepsilon$	$a \cdot \ln b \cdot b^x$	$\bar{x} \cdot \ln b$
$y = a + b \cdot \ln x + \varepsilon$	$\frac{b}{x}$	$\frac{b}{a + b \cdot \ln \bar{x}}$
$y = \frac{a}{1 + b \cdot e^{-c \cdot x + \varepsilon}}$	$\frac{a \cdot b \cdot c \cdot e^{-c \cdot x}}{(1 + b \cdot e^{-c \cdot x})^2}$	$\frac{b \cdot c \cdot \bar{x}}{b + e^{c \cdot \bar{x}}}$
$y = \frac{1}{a + b \cdot x + \varepsilon}$	$-\frac{b}{(a + b \cdot x)^2}$	$-\frac{b \cdot \bar{x}}{a + b \cdot \bar{x}}$

Любое уравнение нелинейной регрессии, как и линейной зависимости, дополняется показателем корреляции, который в данном случае называется индексом корреляции:

$$R = \sqrt{1 - \frac{\sigma_{ост}^2}{\sigma_y^2}}. \quad (3.28)$$

Здесь σ_y^2 – общая дисперсия результативного признака y ; $\sigma_{ост}^2$ – остаточная дисперсия, определяемая по уравнению нелинейной регрессии $\hat{y}_x = f(x)$. Причем они берутся не из преобразованных, а из исходных значениях результативного признака.

Поскольку в расчете индекса корреляции используется соотношение факторной и общей суммы квадратов отклонений, то R^2 имеет тот же смысл, что и коэффициент детерминации. В специальных исследованиях величину R^2 для нелинейных связей называют индексом детерминации. При этом индекс корреляции совпадает с линейным коэффициентом корреляции в случае, когда

преобразование переменных с целью линеаризации уравнения регрессии не проводится с величинами результативного признака. Так обстоит дело с полулогарифмической и полиномиальной регрессиями, а также с равносторонней гиперболой. Индекс детерминации используется для проверки существенности в целом уравнения нелинейной регрессии по F -критерию Фишера:

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - m - 1}{m}, \quad (3.29)$$

где n – число наблюдений; m – число параметров при переменных x .

Индекс детерминации R^2 можно сравнивать с коэффициентом детерминации r^2 для обоснования возможности применения линейной функции. Чем больше кривизна линии регрессии, тем больше разница между R^2 и r^2 . Близость этих показателей означает, что усложнять форму уравнения регрессии не следует и можно использовать линейную функцию. Практически, если величина $(R^2 - r^2)$ не превышает 0,1, то линейная зависимость считается оправданной. В противном случае проводится оценка существенности различия показателей детерминации, вычисленных по одним и тем же данным, через t -критерий Стьюдента:

$$t = \frac{R^2 - r^2}{S_{|R-r|}} \quad (3.30)$$

$$S_{|R-r|} = 2 \cdot \sqrt{\frac{(R^2 - r^2) - (R^2 - r^2)^2 \cdot (2 - (R^2 - r^2))}{n}}.$$

Если $|t_{\text{наб}}| > t_{\text{кр}}(\alpha; n - p - 1)$, то различия между показателями корреляции существенны и замена нелинейной регрессии линейной нецелесообразна.

3.5. ОПРЕДЕЛЕНИЕ МЕРЫ ТОЧНОСТИ МОДЕЛИ

О качестве линейного и нелинейного уравнения регрессии можно судить по:

- 1) средней абсолютной ошибке, которая показывает,

насколько в среднем отклонится фактическое значение от модели

$$\bar{e} = \frac{1}{n} \sum |e_i|;$$

2) средней квадратичной ошибке (чем меньше значение ошибки, тем точнее модель)

$$s = \sqrt{\frac{\sum (e_i - \bar{e})^2}{n-1}};$$

3) средней ошибке аппроксимации – среднее отклонение расчетных значений зависимой переменной от фактических значений y

$$\bar{A} = \frac{1}{n} \sum \left| \frac{y_i - \hat{y}_x}{y_i} \right| \cdot 100\%. \quad (3.31)$$

Допустимый предел значений A – не более 10%. Чем меньше значение A , тем лучше. Значения A в моделях с разным числом наблюдений и одинаковым количеством переменных сравнимы.

Признаки качественной модели

1. Простота модели (из примерно одинаково отражающих реальность моделей выбирается та, которая содержит меньше объясняющих переменных).

2. Единственность (для любых данных коэффициенты модели должны вычисляться однозначно).

3. Максимальное соответствие (модель тем лучше, чем больше скорректированный коэффициент детерминации).

4. Согласованность с теорией (уравнение регрессии должно соответствовать теоретическим предпосылкам).

5. Прогнозные качества (прогнозы, полученные на основе модели, должны подтверждаться реальностью).

3.6. СРАВНЕНИЕ РАЗЛИЧНЫХ МОДЕЛЕЙ

Возможность построения нелинейных моделей как с помощью приведения к линейному виду, так и путем использования нелинейной регрессии значительно повышает универсальность

регрессионного анализа, но и усложняет задачу исследователя. Часто несколько разных нелинейных функций приблизительно соответствуют наблюдениям, если они лежат на некоторой кривой.

При рассмотрении альтернативных моделей с одним и тем же определением зависимой переменной процедура выбора достаточно проста. Наиболее разумным является оценивание регрессии на основе всех вероятных функций, которые можно вообразить, и выбор функции, в наибольшей степени объясняющей изменения зависимой переменной. Если две или более функций подходят примерно одинаково, то следует представить результаты для каждой из них. Если получилось, что линейная функция объясняет 69% дисперсии Y , а гиперболическая функция – 97%, следует без колебаний выбрать последнюю. Если, однако, разные модели используют разные функциональные формы для зависимой переменной, то проблема выбора модели становится более сложной, так как нельзя непосредственно сравнить коэффициенты R^2 или суммы квадратов отклонений. В частности (и это наиболее общий пример для данной проблемы), нельзя сравнить эти статистики для линейного и логарифмического вариантов модели.

Какую модель предпочесть – линейную или же в логарифмах? Для ответа на этот вопрос следует провести сначала содержательный анализ, а потом формальный анализ.

К формальному анализу мы отнесем стандартную процедуру, известную под названием теста Бокса – Кокса (Box, Cox, 1964), а если вы хотите сравнить модели с использованием Y и $\ln Y$ в качестве зависимой переменной, то можно использовать вариант теста, разработанный П. Зарембкой (Zarembka, 1968).

Данный тест предполагает такое преобразование масштаба наблюдений Y , при котором обеспечивалась бы возможность непосредственного сравнения суммы квадратов отклонений в линейной и логарифмической моделях.

Метод Зарембки

1. Вычисляется среднее геометрическое значений Y в выборке. Оно совпадает с экспонентой среднего арифметического $\ln Y$, которое можно рассчитать

$$e^{\frac{1}{n} \sum \ln Y_i} = e^{\frac{1}{n} \ln(Y_1 \times \dots \times Y_n)} = e^{\ln(Y_1 \times \dots \times Y_n)^{1/n}} = (Y_1 \times \dots \times Y_n)^{1/n}.$$

2. Пересчитываются наблюдения Y , они делятся на это значение, т. е.

$$Y_i^* = Y_i / \sqrt[n]{Y_1 Y_2 \dots Y_n}. \quad (3.32)$$

3. Оценивается регрессия для линейной модели с использованием Y^* вместо Y в качестве зависимой переменной и для логарифмической модели с использованием $\ln Y^*$ вместо $\ln Y$; во всех других отношениях модели должны оставаться неизменными. Теперь значения суммы квадратов отклонений для двух регрессий сравнимы, и, следовательно, модель с меньшей суммой квадратов отклонений обеспечивает лучшее соответствие.

$$Y_i^* = \alpha_1 + \beta_1 X_i + \varepsilon_i \quad (RSS_1),$$

$$\ln Y_i^* = \alpha_2 + \beta_2 \ln X_i + \varepsilon_i' \quad (RSS_2).$$

4. Вычисляем χ^2 -статистику для оценки значимости различий

$$\chi^2 = \left(\frac{n}{2} \right) \cdot \left| \ln \frac{RSS_1}{RSS_2} \right|.$$

5. Сравниваем с критическим значением χ^2 -распределения $\chi^2(\alpha, p)$. Эта статистика имеет распределение χ^2 (хи-квадрат) с одной степенью свободы. Различия значимы на уровне значимости α , если

$$\chi^2 > \chi^2(\alpha, p).$$

Идея метода Бокса – Кокса: переменная $\frac{Y^\lambda - 1}{\lambda}$ при $\lambda = 1$ превращается в линейную функцию $Y - 1$; при $\lambda \rightarrow 0$ переходит в логарифм $\frac{Y^\lambda - 1}{\lambda} \rightarrow \ln Y$.

Плавное изменение λ , можно постепенно перейти от линейной регрессии к логарифмической, все время сравнивая качество.

Сравнение различных моделей парной регрессии методом Бокса – Кокса

1. Преобразуют зависимую переменную по методу Зарембки (3.32).

2. Рассчитывают новые переменные (преобразование Бокса – Кокса) при значениях λ от 1 до 0:

$$Y_i^{(B-C)} = \frac{Y_i^{*\lambda} - 1}{\lambda}; \quad X_i^{(B-C)} = \frac{X_i^{\lambda} - 1}{\lambda}.$$

3. Рассчитывают уравнения регрессии для новых переменных при значениях λ от 1 до 0

$$Y_i^{(B-C)} = \alpha + \beta X_i^{(B-C)} + \varepsilon_i.$$

4. Определяют минимальное значение суммы квадратов остатков (RSS).

5. Выбирают одну из крайних регрессий, к которой ближе точка минимума.

3.7. ПРИМЕРЫ РЕШЕНИЯ ТИПОВЫХ ЗАДАЧ

Суть проверки общего качества уравнения регрессии – оценить насколько хорошо эмпирическое уравнение регрессии согласуется со статистическими данными.

Основные показатели качества

1. Коэффициент детерминации R^2 .
2. Значение F -статистики.
3. Коэффициент корреляции r_{xy} .
4. Сумма квадратов остатков (RSS).
5. Стандартная ошибка регрессии S_e .
6. Средняя ошибка аппроксимации.

Пример 3.1. При анализе зависимости объема потребления Y (тыс. р.) домохозяйства от располагаемого дохода X (тыс. р.) отобрана выборка объема $n = 14$, результаты которой приведены в табл. 3.2. Необходимо построить уравнение регрессии, оценить его адекватность и точность, сделать выводы.

Таблица 3.2

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14
x_i	42,8	43,6	44,0	45,2	48,0	48,8	49,2	51,2	54,4	56,0	58,0	60,0	39,2	50,0
y_i	34,0	35,0	36,0	36,7	38,3	39,0	39,7	41,7	44,0	43,3	47,0	48,0	32,0	40,3

Для определения вида зависимости построим корреляционное поле.

Для определения тесноты связи между переменными и построения уравнения регрессии строим вспомогательную таблицу (рис. 3.3).

i	x_i	y_i	x_i^2	y_i^2	$x_i y_i$	$\hat{y}_i$	e_i	e_i^2
1	43	34	1832	1156	1455	34,60	-0,60	0,36
2	44	35	1901	1225	1526	35,22	-0,22	0,05
3	44	36	1936	1296	1584	35,53	0,47	0,22
4	45	37	2043	1347	1659	36,46	0,24	0,06
5	48	38	2304	1467	1838	38,63	-0,33	0,11
6	49	39	2381	1521	1903	39,24	-0,24	0,06
7	49	40	2421	1576	1953	39,55	0,15	0,02
8	51	42	2621	1739	2135	41,10	0,60	0,36
9	54	44	2959	1936	2394	43,58	0,42	0,18
10	56	43	3136	1875	2425	44,82	-1,52	2,30
11	58	47	3364	2209	2726	46,37	0,63	0,40
12	60	48	3600	2304	2880	47,91	0,09	0,01
13	39	32	1537	1024	1254	31,81	0,19	0,03
14	50	40	2500	1624	2015	40,17	0,13	0,02
сумма	690	555	34535	22299	27748	555	0,00	4,17
среднее	49,31	39,64	2467	1593	1982	39,64	0,00	0,30

Рис. 3.3. Расчетная таблица для примера 3.1

Определим тесноту связи между признаками:

$$r = \frac{1982 - 49,3 \cdot 39,6}{\sqrt{(2467 - 49,3^2)(1593 - 39,6^2)}} = 0,99.$$

Так как значение коэффициента близко к единице, то между признаками связь очень тесная, прямая линейная зависимость.

Для проверки гипотезы $H_0: r_{xy} = 0$ при $H_1: r_{xy} \neq 0$ применим формулу (2.9): $t = \frac{0,99}{\sqrt{1 - 0,99^2}} \sqrt{12} = 29.$

Так как $|t_{наб}| > t_{кр}(0,05; 12) = 2,18$, то гипотеза H_0 отвергается, коэффициент корреляции статистически значим.

Построим доверительный интервал по формулам (2.5):

$$2,82 - 1,96 \cdot 0,29 \leq E(Z) \leq 2,82 + 1,96 \cdot 0,29, \\ 2,26 \leq E(Z) \leq 3,89,$$

где $z = 2,82$ – распределение Фишера, $s_z = 0,29$,

$u_{кр(1-\alpha/2)} = 1,96$ – нормированное отклонение. С помощью обратного преобразования Фишера найдем доверительный интервал: $0,978 \leq r_{xy} \leq 0,997$.

По расположению точек на корреляционном поле делаем предположение о линейной зависимости $\hat{y} = b_0 + b_1x$. Согласно (3.2) имеем

$$b_1 = \frac{\overline{yx} - \bar{y} \cdot \bar{x}}{\overline{x^2} - \bar{x}^2} = \frac{1982 - 39,6 \cdot 49,3}{2466,8 - (49,3)^2} = 0,774, \\ b_0 = \bar{y} - b_1 \cdot \bar{x} = 39,6 - 0,775 \cdot 49,3 = 1,48.$$

Уравнение парной линейной регрессии имеет вид

$$\hat{y} = 1,48 + 0,774x.$$

Коэффициент регрессии показывает, что при увеличении дохода на 1 тыс. р., потребление в среднем увеличивается на 0,774 тыс. р.

Коэффициент эластичности равен

$$\varepsilon = 0,774 \cdot \frac{49,3}{39,6} = 0,96.$$

Он показывает, что при увеличении доходов на 1 % потребление в среднем возрастает на 0,96%.

Проведем проверку качества уравнения с помощью дисперсионного анализа и коэффициента детерминации.

Сопоставляя факторную и остаточную дисперсии $H_0 : D_{факт} = D_{ост}$, $H_1 : D_{факт} \neq D_{ост}$ по формуле (3.11), получим

$$F = \frac{292,8}{4,17} \cdot 12 = 841,8.$$

Так как $F_{факт} > F_{кр}(0,05;1;12) = 4,75$, то H_0 отклоняется и $D_{факт}$ существенно превышает $D_{ост}$, т.е. статистическая связь между y и x существует.

Для проверки гипотезы $H_0 : R^2 = 0$, $H_1 : R^2 \neq 0$ применим формулы (3.12) и (3.13):

$$R^2 = 1 - \frac{292,8}{297} = 0,986;$$

$$F = \frac{0,986}{1 - 0,986} \cdot 12 = 841,8.$$

Коэффициент детерминации показывает, что 98,6% различий в расходах объясняется вариацией доходов, а 1,4% – другими, неучтенными факторами.

Так как $F_{факт} > F_{кр}$ ($F_{кр}(0,05;1;12) = 4,75$), то H_0 отклоняется, коэффициент детерминации отличается от нуля, следовательно, уравнение регрессии статистически значимо.

Проверим статистическую значимость коэффициентов регрессии по формулам (3.14) и (3.15).

$$H_0 : \beta_1 = 0 \text{ при } H_1 : \beta_1 \neq 0.$$

Рассчитаем $\sum (x_i - \bar{x})^2 = 489$, тогда

$$s_e^2 = \frac{4,17}{12} = 0,35$$

$$s_{b_1} = \sqrt{\frac{0,35}{489}} = 0,027; \quad t_{наб} = \frac{0,774}{0,027} = 29.$$

Так как $|t_{наб}| > t_{кр}(0,05; 12) = 2,18$, то гипотеза H_0 отвергается, коэффициент статистически значим. Доход существенно влияет на расход.

$$H_0 : \beta_1 = 0 \text{ при } H_1 : \beta_1 \neq 0$$

$$s_{b_0} = s_{b_1} \cdot \sqrt{\sum x^2 / n} = 1,32; \quad t_{наб} = \frac{1,48}{1,32} = 1,11.$$

Так как $|t_{наб}| < t_{кр}(0,05; 12) = 2,18$, то коэффициент статистически не значим.

Для значимого коэффициента регрессии найдем

доверительный интервал по формуле (3.18)

$$0,774 \pm 2,18 \cdot 0,027; 0,716 < b_1 < 0,832.$$

Для расчета коэффициента аппроксимации найдем

$$\sum \left| \frac{e_i}{y_i} \right| = \left| \frac{-0,6}{34} \right| + \dots + \left| \frac{0,13}{40} \right| = 0,15;$$

тогда по формуле (3.31)

$$A = \frac{0,15}{14} = 1\%.$$

Фактические значения доходов от расчетных данных по уравнению регрессии в среднем различаются на 1%. Полученное уравнение можно оценить как хорошее.

Рассчитаем для каждого значения x_i минимальные и максимальные значения $\hat{y}_i$ (рис. 3.4) по формулам (3.19).

i	x_i	y_i	$\hat{y}_i$	s_y	y_{min}	y_{max}
1	43	34	34,60	0,23	34,09	35,11
2	44	35	35,22	0,22	34,74	35,70
3	44	36	35,53	0,21	35,07	35,99
4	45	37	36,46	0,19	36,04	36,88
5	48	38	38,63	0,16	38,27	38,98
6	49	39	39,24	0,16	38,90	39,59
7	49	40	39,55	0,16	39,21	39,90
8	51	42	41,10	0,17	40,74	41,46
9	54	44	43,58	0,21	43,13	44,03
10	56	43	44,82	0,24	44,30	45,34
11	58	47	46,37	0,28	45,75	46,98
12	60	48	47,91	0,33	47,20	48,62
13	39	32	31,81	0,31	31,13	32,50
14	50	40	40,17	0,16	39,83	40,52

Рис. 3.4. Продолжение таблицы примера 3.1

Построим графики зависимостей y_i и $\hat{y}_i$ от x , а также доверительные интервалы для значений $\hat{y}_i$ (рис. 3.5).




Рис. 3.5. Линейная зависимость

Прогнозное значение результативного признака определяется путем подстановки в уравнение регрессии прогнозного или возможного значения факторного признака. Пусть $x_p = 52,5$, тогда прогнозное значение расходов составит $\hat{y}_p = 42,1$. Значит, при доходах в 52,5 тыс. р. расход составит 42,1 тыс. р.

По формулам (3.20) и (3.21) доверительные интервалы составят $40,8 \leq y^* \leq 43,45$. При доходах 52,5 тыс. р. расходы от 40,8 тыс. р. до 43,45 тыс. р.

Предположим, что связь между признаками носит нелинейный характер $Y = \beta_0 X^{\beta_1} \cdot \varepsilon$. Уравнение преобразовываем в линейное как

$$\ln Y = \ln \beta_0 + \beta_1 \ln X.$$

Если обозначить $Y' = \ln Y$, $Z = \ln X$ и $\beta_0' = \ln \beta_0$, то уравнение перепишем в следующем виде

$$Y' = \beta_0' + \beta_1 Z.$$

Составляем вспомогательную таблицу (рис. 3.6) для преобразованных данных.

i	Z_i	Y_i'	Z_i^2	$Y_i'^2$	$Z_i Y_i'$	$\hat{y}_i$	e_i	e_i^2
1	3,67	3,47	13,46	12,01	12,71	31,80	0,20	0,04
2	3,76	3,53	14,11	12,44	13,25	34,60	-0,60	0,36
3	3,78	3,56	14,25	12,64	13,42	35,22	-0,22	0,05
4	3,78	3,58	14,32	12,84	13,56	35,53	0,47	0,22
5	3,81	3,60	14,52	12,98	13,73	36,46	0,24	0,06
6	3,87	3,65	14,99	13,29	14,11	38,63	-0,33	0,11
7	3,89	3,66	15,11	13,42	14,24	39,25	-0,25	0,06
8	3,90	3,68	15,18	13,55	14,34	39,56	0,14	0,02
9	3,91	3,70	15,30	13,66	14,46	40,18	0,12	0,01
10	3,94	3,73	15,49	13,92	14,68	41,11	0,59	0,35
11	4,00	3,78	15,97	14,32	15,12	43,57	0,43	0,18
12	4,03	3,77	16,20	14,20	15,17	44,81	-1,51	2,27
13	4,06	3,85	16,49	14,82	15,63	46,34	0,66	0,43
14	4,09	3,87	16,76	14,99	15,85	47,88	0,12	0,01
сумма	54	51	212	189	200	555	0	4
среднее	3,89	3,67	15,15	13,51	14,31	39,64	0,00	0,30
$\beta_0' =$	-0,07		$\beta_0 =$	0,93				
$\beta_1 =$	0,96							

Рис. 3.6. Вспомогательная таблица для нелинейной модели

Для нахождения параметров регрессии воспользуемся встроенными функциями *Excel* (прил. 1) $\beta_1 = 0,96$, $\beta_0 = e^{-0,07} = 0,93$. В результате искомое уравнение регрессии: $Y = 0,93 x^{0,96}$.

Индекс корреляции $\rho_{xy} = 0,992$ (формула 3.28), индекс детерминации R^2 равен 0,986, который показывает, что 98,6% вариации результативного признака объясняется вариацией признака-фактора, а 1,4% приходится на долю прочих факторов. Средняя ошибка аппроксимации $A = 1\%$ показывает, что линия регрессии хорошо приближает исходные данные.

По формуле 3.29: $F_n = 845 > F_{кр}(0,05; 1; 12) = 4,74$, следовательно, уравнение статистически значимо.

Пример 3.2. Имеются выборочные данные о рыночной стоимости квартир (Y , млн р.) и общей площади квартиры (X , м²) (рис. 3.7).

	A	B	C	D	E	F
1	i	x_i	y_i	$\ln x_i$	$\ln y_i$	$\sqrt{x_i}$
2	1	47,97	3,70	3,87	1,31	6,93
3	2	48,97	3,60	3,89	1,28	7,00
4	3	50,38	3,73	3,92	1,32	7,10
5	4	52,49	3,70	3,96	1,31	7,24
6	5	54,23	4,20	3,99	1,44	7,36
7	6	58,08	4,26	4,06	1,45	7,62
8	7	61,63	4,42	4,12	1,49	7,85
9	8	64,68	5,00	4,17	1,61	8,04
10	9	67,35	4,69	4,21	1,55	8,21
11	10	70,13	5,30	4,25	1,67	8,37
12	11	81,03	5,54	4,39	1,71	9,00
13	12	86,53	5,93	4,46	1,78	9,30
14	13	85,84	5,87	4,45	1,77	9,26
15	14	87,58	6,50	4,47	1,87	9,36
16	15	90,68	6,38	4,51	1,85	9,52
17	16	94,29	6,75	4,55	1,91	9,71
18	17	98,88	7,36	4,59	2,00	9,94
19	18	101,55	7,60	4,62	2,03	10,08
20	19	102,16	7,90	4,63	2,07	10,11
21	20	104,93	8,50	4,65	2,14	10,24

Рис. 3.7. Таблица примера 3.2

На рис. 3.8 представлен график исходных данных.

Предположим, что связь между признаками носит нелинейный характер, и найдем параметры линейной модели следующих нелинейных уравнений:

- 1) $Y = a + b \cdot x + \varepsilon$;
- 2) $Y = a + b \cdot \ln x + \varepsilon$;
- 3) $Y = a + b \cdot \sqrt{x} + \varepsilon$;
- 4) $Y = a \cdot x^b \cdot \varepsilon$.

Для нахождения параметров регрессии воспользуемся встроенными функциями *Excel* («Анализ данных – Регрессия» (прил. 1)) для первых трех моделей.




Рис. 3.8. Исходные данные примера 3.2

Уравнения регрессии записываются с нелинейными выражениями относительно переменных. Для второй и третьей функций достаточно ввести обозначения и функции можно рассматривать, как линейные $z_2 = \ln x$, а $z_3 = \sqrt{x}$. (колонки D и F рис. 3.7). Четвертая функция может быть преобразована в линейную путем использования логарифмов.

$$\ln Y = \ln a + b \cdot \ln X.$$

Если обозначить $Y' = \ln Y$, $Z = \ln X$ и $a' = \ln a$, то уравнение можно переписать в следующем виде

$$Y' = a' + b \cdot Z;$$

$$b = 0,995, a = e^{-2,59} = 0,07; R^2 = 1 - 1,75/44,8 = 0,961.$$

Средняя ошибка аппроксимации будет рассчитана для каждой модели (рис. 3.9)

	A	B	C	D	E	F	G	H	I	J
1	i	x_i	y_i	$\ln x_i$	$\ln y_i$	$\sqrt{x_i}$	A_1	A_2	A_3	A_4
2	1	47,97	3,70	3,87	1,31	6,93	0,06	0,11	0,09	0,05
3	2	48,97	3,60	3,89	1,28	7,00	0,01	0,06	0,04	0,00
21	20	104,93	8,50	4,65	2,14	10,24	0,09	0,12	0,10	0,10
22							4,07%	5,49%	4,70%	3,92%

Рис. 3.9. Ошибка аппроксимации примера 3.2

Сравнение построенных моделей по индексу детерминации и средней ошибке аппроксимации выполним в табл. 3.3.

Таблица 3.3

Модель	Оценки модели	Индекс детерминации, R^2	Средняя ошибка аппроксимации, %
$y = a + b \cdot x$	$y = -0,15 + 0,075 \cdot x$	0,961	4,07
$y = a + b \cdot \ln x$	$y = -17,6 + 5,4 \cdot \ln x$	0,933	5,49
$y = a + b \cdot \sqrt{x}$	$y = -5,5 + 1,29 \cdot \sqrt{x}$	0,949	4,70
$y = a \cdot x^b$	$y = e^{-2,59} \cdot x^{0,995} = 0,07 \cdot x^{0,995}$	0,962	3,92

Наиболее хорошо исходные данные аппроксимирует степенная модель, чуть хуже – линейная. В данном случае, так как индексы детерминации линейной модели и модели степенной отличаются всего на 0,001, то вполне можно обойтись более простой линейной функцией.

Пример 3.3. Выборка состоит из 570 значений и среднее значение переменной $\ln Y = 2,43$. Тогда масштабирующий множитель равен $\exp(2,43) = 11,36$. Сумма квадратов отклонений в регрессии между масштабированным по методу Зарембки Y ($Y_i^* = Y_i / 11,36$) и X равняется 266,7; сумма квадратов в регрессии логарифма того же масштабированного по методу Зарембки Y получилась равной 132,1. Следовательно, тестовая статистика равна:

$$570/2 \cdot \ln(266,7/132,1) = 200,2.$$

Критическое значение χ^2 с одной степенью свободы при 0,1-процентном уровне значимости равно $\chi^2_{\text{кр}} = 10,8$. Следовательно, полулогарифмическая спецификация обеспечивает лучшие оценки.

Замечание. Масштабированные по методу Зарембки регрессии могут использоваться исключительно для принятия решения о том, какую модель предпочесть.

Не следует обращать внимание на их коэффициенты, рассматривая только их суммы квадратов отклонений. Коэффициенты регрессии получают непосредственно из немасштабированного варианта выбранной модели.

Ограниченность простой регрессии:

- никакая единственная переменная за редкими исключениями не в состоянии хорошо «объяснить» изменения зависимой переменной;
- могут существовать несколько одинаково хороших и взаимно противоречивых регрессий;
- линейная форма примитивна.

И тем не менее нет ничего лучше по простоте и ясности объяснения парной линейной связи. При равной объясняющей способности из двух моделей мы всегда выбираем более простую.

Контрольные вопросы

1. Что понимается под парной регрессией?
2. Какие задачи решаются при построении уравнения регрессии?
3. Какие методы применяются для выбора вида модели регрессии?
4. Какие функции чаще всего используются для построения уравнения парной регрессии?
5. Какой вид имеет система нормальных уравнений метода наименьших квадратов в случае линейной регрессии?
6. Какой вид имеет система нормальных уравнений метода наименьших квадратов в случае гиперболической, показательной регрессии?
7. По какой формуле вычисляется линейный коэффициент парной корреляции?
8. Как строится доверительный интервал для линейного коэффициента парной корреляции?
9. Как вычисляется индекс корреляции?
10. Как вычисляется и что показывает индекс детерминации?
11. Как проверяется значимость уравнения регрессии и отдельных коэффициентов?
12. Как строится доверительный интервал прогноза в случае линейной регрессии?

13. Как вычисляются и что показывают коэффициент эластичности, средний коэффициент эластичности?
14. Какие существуют классы нелинейных регрессий?
15. Какие модели относятся к нелинейным относительно включенных в анализ объясняющих переменных?
16. Какой должна быть функция регрессии, чтобы применить к ней МНК?
17. Что означает понятие «линеаризация модели»? Как она может быть произведена?
18. Как рассчитать показатели корреляции и детерминации для нелинейной регрессии?
19. Как определить F -критерий Фишера для нелинейной регрессии?
20. Почему конкретные значения параметров уравнения регрессии называют их оценками?

4. МНОЖЕСТВЕННАЯ РЕГРЕССИЯ

Множественная регрессия широко используется в макроэкономических расчетах и является одним из наиболее распространенных методов в эконометрике. Основная цель множественной регрессии – построить модель с большим числом факторов, определив при этом влияние каждого из них в отдельности, а также совокупное их воздействие на моделируемый показатель.

Модель множественной регрессии описывает, как изменяется в среднем значение зависимой переменной y (результативного признака) при изменении значений объясняющих переменных (факториальных признаков).

По характеру взаимосвязей модели могут быть линейными и нелинейными как по переменным, так и по параметрам.

Для оценки параметров модели методом наименьших квадратов нелинейные по параметрам модели должны быть приведены к линейному виду, часто путем логарифмирования.

Различают виды множественной регрессии:

- 1) классическая линейная регрессия;
- 2) нелинейная регрессия;
- 3) специальные виды переменных.

Множественная регрессия имеет вид:

$$M[Y / x_1, x_2, \dots, x_m] = f(x_1, x_2, \dots, x_m)$$

Уравнение множественной регрессии:

$$Y = f(\beta, X) + \varepsilon,$$

где $X = (x_1, x_2, \dots, x_m)$ – вектор объясняющих переменных;

β – вектор параметров (подлежащих определению);

ε – вектор случайных ошибок (отклонений);

Y – зависимая переменная.

Теоретическое линейное уравнение регрессии имеет вид

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m + \varepsilon$$

или для индивидуальных наблюдений:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_m x_{im} + \varepsilon_i,$$

где $i = 1, 2, \dots, n$; $n \geq m + 1$; $k = n - m - 1$ – число степеней свободы.

Для обеспечения статистической надежности должно выполняться условие: $n > 3(m + 1)$.

Коэффициент регрессии β_j показывает, на какую величину в среднем изменится результативный признак y при увеличении x_j на одну единицу при фиксированном значении остальных факторов.

Параметр β_0 определяет значение y в случае, когда все объясняющие переменные равны нулю. Как и в случае парной регрессии, факторы по своему экономическому содержанию часто не могут принимать нулевых значений, и значение свободного члена не имеет экономического смысла.

Пусть имеется n наблюдений объясняющих переменных и соответствующих им значений результативного признака, тогда Эмпирическое уравнение регрессии:

$$\begin{aligned}\hat{Y} &= b_0 + b_1 X_1 + b_2 X_2 + \dots + b_m X_m \quad \text{или} \\ \hat{y}_i &= b_0 + b_1 x_{i1} + b_2 x_{i2} + \dots + b_m x_{im}.\end{aligned}\tag{4.1}$$

Самый распространенный метод оценки параметров – метод наименьших квадратов (МНК)

$$b_j, j = \overline{0, m}: \sum_{i=1}^n \left(y_i - \underbrace{\left(b_0 + \sum_{j=1}^m b_j x_{ij} \right)}_{\hat{y}_i} \right)^2 = \sum_{i=1}^n e_i^2 \rightarrow \min.$$

4.1. ОПРЕДЕЛЕНИЕ ПАРАМЕТРОВ УРАВНЕНИЯ РЕГРЕССИИ

Для нахождения параметров регрессии применим метод наименьших квадратов (МНК). Поскольку параметры β_j являются неизвестными константами, вместо теоретического уравнения регрессии оценивается эмпирическое уравнение регрессии

$$y = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_m x_m + e.\tag{4.2}$$

Рассмотрим методы расчета параметров множественной линейной регрессии.

Представим данные наблюдений и параметры модели в матричной форме:

$Y = [y_1, y_2, \dots, y_n]^T$ – n -мерный транспонированный вектор – столбец наблюдений зависимой переменной;

$B = [b_0, b_1, b_2, \dots, b_m]^T$ – $(m + 1)$ -мерный транспонированный вектор – столбец параметров уравнения регрессии (4.2);

$e = [e_1, e_2, \dots, e_n]^T$ – n -мерный транспонированный вектор – столбец отклонений выборочных значений y_i .

Значения независимых переменных запишем в виде прямоугольной матрицы размерности $n \times (m + 1)$:

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1m} \\ 1 & x_{21} & x_{22} & \dots & x_{2m} \\ \vdots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nm} \end{bmatrix}.$$

Каждому столбцу этой матрицы отвечает набор из n значений одного из факторов, а первый столбец состоит из единиц, которые соответствуют значениям переменной при свободном члене.

В этих обозначениях эмпирическое уравнение регрессии имеет вид: $Y = XB + e$. Отсюда вектор остатков регрессии равен $e = Y - XB$. Тогда функционал $Q = \sum e_i^2$, который минимизируется по МНК, можно записать как произведение вектора-строки e^T на вектор-столбец e

$$\begin{aligned} Q = e^T e &= (Y - XB)^T (Y - XB) = Y^T Y - B^T X^T Y - Y^T XB + B^T X^T XB = \\ &= Y^T Y - 2B^T X^T Y + B^T X^T XB. \end{aligned}$$

В соответствии с МНК дифференцирование Q по вектору B приводит к выражению

$$\frac{\partial Q}{\partial B} = -2X^T Y + 2(X^T X)B,$$

которое для нахождения экстремума следует приравнять к нулю.

$$X^T X B = X^T Y \Rightarrow B = (X^T X)^{-1} (X^T Y),$$

$$\text{где } X^T X = \begin{bmatrix} n & \sum x_{i1} & \sum x_{i2} & \dots & \sum x_{im} \\ \sum x_{i1} & \sum x_{i1}^2 & \sum x_{i1}x_{i2} & \dots & \sum x_{i1}x_{im} \\ \dots & \dots & \dots & \dots & \dots \\ \sum x_{im} & \sum x_{i1}x_{im} & \dots & \dots & \sum x_{im}^2 \end{bmatrix}, \quad X^T Y = \begin{bmatrix} \sum y_i \\ \sum y_i x_{i1} \\ \dots \\ \sum y_i x_{im} \end{bmatrix}.$$

В результате преобразований получаем выражение для вектора параметров регрессии:

$$B = (X^T X)^{-1} X^T Y, \quad (4.3)$$

где $B = [b_0, b_1, b_2, \dots, b_m]^T$.

Тогда уравнение регрессии имеет вид

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_m x_m.$$

Оценка дисперсии теоретического уравнения определяется по формуле

$$s_e^2 = \frac{\sum e_i^2}{n - m - 1} \quad (4.4)$$

или

$$s_e^2 = \frac{e^T \cdot e}{n - m - 1}. \quad (4.5)$$

Стандартное отклонение остатков модели S_e показывает, насколько в среднем наблюдаемые значения эндогенной переменной отличаются от теоретических значений этой переменной.

Как и для парной регрессии, параметр B нельзя использовать для непосредственной оценки влияния факторного признака на результативный признак из-за различия единиц измерения исследуемых показателей. Для этих целей вычисляют коэффициент эластичности, который показывает, на сколько процентов (от средней) изменится в среднем результативный признак y при увеличении

факторного признака x_j на один процент:

$$\mathcal{E}_j = b_j \frac{\bar{x}_j}{\bar{y}}, \quad j = \overline{1, m}. \quad (4.6)$$

Также можно рассчитать частные коэффициенты эластичности

$$\mathcal{E}_{y x_j} = b_j \frac{x_j}{\hat{y}_{x_1, x_2, \dots, x_{j-1}, x_{j+1}, \dots, x_m}},$$

который показывает на сколько процентов изменяется в среднем результативный признак при изменении фактора x_j на 1% при неизменных факторах, включенных в модель.

Другой вид множественной регрессии – уравнение регрессии в стандартизованном масштабе

$$z_y = \beta_1 z_{x_1} + \beta_2 z_{x_2} + \dots + \beta_m z_{x_m} + \varepsilon, \quad (4.7)$$

где z_y, z_{x_j} – стандартизованные переменные

$$z_y = \frac{y - \bar{y}}{\sigma_y}; \quad z_{x_j} = \frac{x_j - \bar{x}_j}{\sigma_{x_j}}, \quad j = \overline{1, m},$$

для которых среднее значение равно нулю: $\bar{z}_y = \bar{z}_{x_j} = 0$, а среднее

квадратическое отклонение равно единице:

$$\sigma_{z_y} = \sigma_{z_{x_j}} = 1, \quad j = \overline{1, m}.$$

Связь коэффициентов множественной регрессии b_i с оценками стандартизованных коэффициентов описывается соотношением

$$\beta_j = b_j \frac{\sigma_{x_j}}{\sigma_y}. \quad (4.8)$$

Стандартизованные коэффициенты регрессии (или бета-коэффициенты) β_j показывают, на сколько значений стандартных отклонений изменится в среднем результат, если соответствующий фактор x_j изменится на одно стандартное отклонение при неизменном среднем уровне других факторов.

В силу того что все переменные в регрессии (4.7)

центрированы и нормированы, стандартизованные коэффициенты регрессии β_j сравнимы между собой; сопоставляя их друг с другом, можно ранжировать факторы по силе их воздействия на результат.

Применяя МНК к уравнению (4.6), после соответствующих преобразований получим систему нормальных уравнений:

$$\begin{cases} \beta_1 + \beta_2 r_{x_2 x_1} + \dots + \beta_m r_{x_m x_1} = r_{yx_1}, \\ \beta_1 r_{x_1 x_2} + \beta_2 + \dots + \beta_m r_{x_m x_2} = r_{yx_2}, \\ \dots \quad \dots \quad \dots \quad \dots \quad \dots \\ \beta_1 r_{x_1 x_m} + \beta_2 r_{x_2 x_m} + \dots + \beta_m = r_{yx_m}. \end{cases} \quad (4.9)$$

В этой системе r_{yx_j} и $r_{x_i x_j}$ ($j, i = \overline{1, m}$) – элементы расширенной матрицы парных коэффициентов корреляции.

Сравнивая коэффициенты β_j между собой, можно ранжировать факторы по силе их воздействия на результат, а также использовать коэффициенты при отсеве факторов: из модели исключаются факторы с наименьшим значением β_j . В этом основное достоинство стандартизованных коэффициентов регрессии, в отличие от коэффициентов обычной регрессии, которые несравнимы между собой.

Как в парной зависимости коэффициенты регрессии и корреляции связаны между собой, так и во множественной регрессии коэффициенты «чистой» регрессии b_j связаны с β -коэффициентами:

$$b_j = \beta_j \frac{\sigma_y}{\sigma_{x_j}}. \quad (4.10)$$

Это позволяет от уравнения регрессии в стандартизованном масштабе перейти к уравнению регрессии, причем параметр b_0 определяется как

$$b_0 = \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2 - \dots - b_m \bar{x}_m. \quad (4.11)$$

4.1.1. Анализ статистической значимости уравнения регрессии и ее коэффициентов

Построение эмпирического уравнения регрессии – начальный этап эконометрического анализа. Первое же построенное по выборке уравнение регрессии очень редко является удовлетворительным по тем или иным характеристикам. Поэтому следующая важнейшая задача эконометрического анализа – проверка качества уравнения регрессии. В эконометрике принята устоявшаяся схема такой проверки.

Итак, проверка статистического качества оцененного уравнения регрессии проводится по следующим направлениям:

- значимость уравнения регрессии;
- статистическая значимость коэффициентов уравнения регрессии;
- свойства данных, выполнимость которых предполагалась при оценивании уравнения (выполнимость предпосылок МНК – теорема Гаусса – Маркова, параграф 3.2).

Как и в случае парной регрессии, проверка гипотезы о статистической значимости уравнения регрессии осуществляется на основе дисперсионного анализа.

Для проверки нулевой гипотезы $H_0: D_{факт} = D_{ост}$ против альтернативной гипотезы $H_1: D_{факт} > D_{ост}$ применим F -статистику:

$$F = \frac{ESS / m}{RSS / (n - m - 1)}. \quad (4.12)$$

Здесь в числителе – объясненная (факторная) дисперсия в расчете на одну степень свободы (число степеней свободы равно числу факторов, т.е. m). В знаменателе – остаточная дисперсия на одну степень свободы. Её число степеней свободы равно $(n - m - 1)$. Потеря $(m + 1)$ степени свободы связана с необходимостью решения системы $(m + 1)$ линейных уравнений при определении параметров эмпирического уравнения регрессии.

Если $F_{наб} > F_{кр}(\alpha; m; n - m - 1)$, то нуль-гипотеза отклоняется, т. е. факторная дисперсия превышает остаточную, уравнение регрессии является статистически значимым.

Для проверки общего качества уравнения регрессии используется также *коэффициент детерминации* R^2 , который в общем случае рассчитывается по формуле

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2}. \quad (4.13)$$

Он показывает долю общей дисперсии y , объясненную уравнением регрессии. Его значения находятся между нулем и единицей.

Долю дисперсии, объясненную построенной регрессией, в общей дисперсии результативного признака y характеризует коэффициент детерминации R^2 , расчет которого производится по формуле (1.73). Однако коэффициент детерминации множественной регрессии обладает одним недостатком: он неизбежно увеличивается при добавлении в регрессию новой переменной, даже если влияние последней на зависимую переменную (y) незначительно. С целью исправления обозначенного недостатка вычисляют скорректированный (*adjusted*) коэффициент детерминации:

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - m - 1}. \quad (4.14)$$

Анализ статистической значимости коэффициента детерминации проводится на основе проверки гипотезы $H_0: R^2 = 0$ против альтернативной гипотезы $H_1: R^2 > 0$. Для проверки данной гипотезы используется следующая F -статистика:

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - m - 1}{m}. \quad (4.15)$$

Если $F_{наб} > F_{кр}(\alpha; m; n - m - 1)$, то нулевая гипотеза отклоняется, что равносильно статистической значимости R^2 , т.е. $R^2 > 0$.

Наряду со скорректированным коэффициентом детерминации для выбора между несколькими альтернативными моделями часто используют *информационные критерии* Акайке и Шварца, также

«штрафующие» за увеличение количества объясняющих переменных в модели.

Критерий Акайке (AIC):

$$AIC = \ln\left(\frac{RSS_p}{n}\right) + \frac{2p}{n} + 1 + \ln 2\pi, \quad (4.16)$$

где RSS_p – остаточная сумма квадратов, полученная при оценивании коэффициентов модели с p независимыми переменными методом наименьших квадратов.

Из выражения видно, что при фиксированном размере выборки рост критерия обусловлен в основном увеличением числа параметров модели, а не ее ошибкой, т.е. за увеличение числа параметров модель «штрафуется» сильнее, чем за долю необъясненной дисперсии ошибки. Таким образом, задача заключается в том, чтобы выбрать модель с минимальным числом параметров, которые объясняют наибольшую долю дисперсии ошибки.

Критерий Шварца (SC, SIC):

$$SC = \ln\left(\frac{RSS_p}{n}\right) + \frac{p \ln n}{n} + 1 + \ln 2\pi. \quad (4.17)$$

Среди нескольких альтернативных моделей (полной и редуцированных) предпочтение отдается модели с наименьшими значениями AIC и SC .

Наряду с гипотезами о незначимости регрессии в целом или незначительном влиянии определенного фактора на эндогенную переменную часто возникает необходимость проверить статистическую значимость совокупного влияния группы факторов на y , т.е. $H_0 : b_i = b_{i+1} = \dots = b_{i+k-1} = 0$. В более общем случае говорят о проверке линейного ограничения на коэффициенты регрессии: $H_0 : Gb = d$, где G – матрица размером $k \times (m + 1)$; b – вектор коэффициентов $(m + 1) \times 1$; d – вектор $k \times 1$. Для проверки такого типа гипотез необходимо оценить параметры двух регрессий: «короткой» регрессии с ограничениями на параметры $Gb = d$ и «длинной» регрессии без ограничений на параметры.

Тогда проверка гипотезы H_0 осуществляется с помощью критической статистики:

$$F_{набл} = \frac{(R_{UR}^2 - R_R^2) / k}{(1 - R_{UR}^2) / n - m - 1} \sim F_{кр}(\alpha, k, n - m - 1), \quad (4.18)$$

где R_{UR}^2 – коэффициент детерминации «длинной» регрессии;

R_R^2 – коэффициент детерминации «короткой» регрессии.

Кроме коэффициента детерминации R^2 в уравнении множественной регрессии используется показатель множественной корреляции, равный корню квадратному из R^2 :

$$R_{yx_1x_2 \dots x_p} = \sqrt{1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}}. \quad (4.19)$$

Границы его изменения от 0 до 1. Чем ближе его значение к единице, тем теснее связь результативного признака со всем набором исследуемых факторов.

Для линейного уравнения множественной регрессии формула индекса корреляции может быть представлена выражением

$$R_{yx_1x_2 \dots x_p} = \sqrt{\sum \beta_i \cdot r_{yx_i}}, \quad (4.20)$$

где β_j – стандартизованные коэффициенты регрессии, r_{yx_j} – парные коэффициенты корреляции результата с каждым из факторов.

Аналогично парной линейной регрессии оценка статистической значимости коэффициентов регрессии производится с использованием t -критерия Стьюдента

$$t_{b_j} = \frac{b_j}{s_{b_j}}, \quad j = \overline{0, m}. \quad (4.21)$$

Сравнивая наблюдаемое и критическое (табличное) значения t -статистики, принимаем или отвергаем гипотезу H_0 о статистической незначимости коэффициентов регрессии.

Если $|t_{наб}(b_j)| < t_{кр}(\alpha; n - m - 1)$, то H_0 принимается для коэффициента b_j , причем принятие нулевой гипотезы

относительно коэффициента b_j обозначает отсутствие влияния фактора x_j на формирование уровней переменной y . Принятие нулевой гипотезы относительно коэффициента b_0 указывает на плохое качество аппроксимации регрессией в окрестности точки ноль, что на практике чаще всего является несущественной ошибкой, так как наблюдаемые значения лежат далеко от точки ноль.

Величина S_{b_j} называется стандартной ошибкой параметра b_j

$$s_{b_j}^2 = s_e^2 z_{jj}', \quad j = \overline{0, m}. \quad (4.22)$$

Здесь z_{jj}' – диагональные элементы матрицы. Обозначим матрицу $Z^{-1} = (X^T X)^{-1}$.

Если $|t_{наб}(b_j)| > t_{кр}(\alpha; n - m - 1)$, то соответствующий параметр считается статистически значимым, и H_0 отвергается.

Для проверки гипотезы о равенстве коэффициента регрессии некоторому гипотетическому значению β_0 , т.е. $H_0: b_j = \beta_0$, используется t -статистика

$$t_{b_j} = \frac{b_j - \beta_0}{s_{b_j}}. \quad (4.23)$$

Если $|t_{наб}| > t_{кр}(\alpha; n - m - 1)$, то параметр статистически значимо отличается от гипотетического значения.

4.1.2. Доверительные интервалы для функции регрессии и коэффициентов регрессии

Пусть объясняющие переменные принимают значение $X_0^T = (1; x_{10}; x_{20}; \dots; x_{m0})$. По уравнению (4.2) найдем прогнозное значение $\hat{y}_0$. Построим доверительные интервалы.

Доверительный интервал для функции регрессии

$$\hat{y}_0 - s_{\hat{y}} \cdot t_{кр}(\alpha, n - m - 1) \leq E(y) \leq \hat{y}_0 + s_{\hat{y}} \cdot t_{кр}(\alpha, n - m - 1), \quad (4.24)$$

$$\text{где } s_{\hat{y}} = s \sqrt{X_0^T (X^T X)^{-1} X_0}. \quad (4.25)$$

Доверительный интервал для индивидуальных значений зависимой переменной

$$\hat{y}_0 - s_{\hat{y}} \cdot t_{\kappa p}(\alpha, n - m - 1) \leq y^* \leq \hat{y}_0 + s_{\hat{y}} \cdot t_{\kappa p}(\alpha, n - m - 1), \quad (4.26)$$

где

$$s_{\hat{y}_0} = s \sqrt{1 + X_0^T (X^T X)^{-1} X_0}. \quad (4.27)$$

Доверительные интервалы для коэффициентов регрессии

$$b_j - t_{\kappa p}(\alpha; n - m - 1) \cdot s_{b_j} < b_j' < b_j + t_{\kappa p}(\alpha; n - m - 1) \cdot s_{b_j} \quad (4.28)$$

для всех $j = 0, m$.

4.2. ПРИМЕРЫ РЕШЕНИЯ ТИПОВЫХ ЗАДАЧ

Пример 4.1. По некоторым переменным имеются следующие статистические данные: $r_{yx_1} = 0,68$; $r_{yx_2} = 0,93$; $r_{x_1x_2} = 0,54$; $\bar{y} = 18,0$; $\bar{x}_1 = 7$; $\bar{x}_2 = 12$; $\sigma_y = 4$; $\sigma_{x_1} = 2$; $\sigma_{x_2} = 3$.

Построить уравнение регрессии в стандартизованном и натуральном масштабах.

Решение. Решим систему уравнений (4.9), которая в случае двух факторов имеет вид:

$$\begin{cases} \beta_1 + r_{x_1x_2} \beta_2 = r_{yx_1} \\ r_{x_1x_2} \beta_2 + \beta_2 = r_{yx_2} \end{cases} \rightarrow \begin{cases} \beta_1 + 0,54 \cdot \beta_2 = 0,68, \\ 0,54 \cdot \beta_2 + \beta_2 = 0,93. \end{cases}$$

Для множественной регрессии, включающей 2 факторных признака, коэффициенты стандартизированной регрессии могут быть найдены по следующим формулам:

$$\begin{cases} \beta_1 = \frac{r_{yx_1} - r_{yx_2} r_{x_1x_2}}{1 - r_{x_1x_2}^2}, \\ \beta_2 = \frac{r_{yx_2} - r_{yx_1} r_{x_1x_2}}{1 - r_{x_1x_2}^2}. \end{cases}$$

Тогда $\beta_1 = 0,25$; $\beta_2 = 0,79$. Следовательно, уравнение регрессии в стандартизованном масштабе имеет вид $\hat{z}_y = 0,25z_{x_1} + 0,79z_{x_2}$.

Теперь перейдем к уравнению регрессии в натуральном масштабе, для чего используем формулы (4.10) и (4.11):

$$b_1 = 0,25 \cdot \frac{4,0}{2,0} = 0,50; \quad b_2 = 0,79 \cdot \frac{4,0}{3,0} = 1,06;$$

$$b_0 = 18 - 0,5 \cdot 7 - 1,06 \cdot 12 = 1,78.$$

Уравнение регрессии в натуральном масштабе имеет вид:

$$\hat{y} = 1,78 + 0,5x_1 + 1,06x_2.$$

Пример 4.2. На формирование уровней стоимости квартиры (y , тыс. р.), (табл. 4.1), влияние оказывает жилая площадь (x_1 , м²) и площадь кухни (x_2 , м²).

Таблица 4.1

№	y	x_1	x_2	№	y	x_1	x_2
1	1284,6	21,5	12,5	6	1105,0	35,0	13,0
2	870,2	20,0	10,0	7	1381,3	50,0	14,0
3	902,0	19,0	10,0	8	801,2	32,0	11,5
4	1146,5	32,0	10,5	9	1522,5	55,0	15,0
5	1160,3	38,0	11,0	10	1330,0	41,5	19,0

Таким образом, модель принимает вид

$$y_i = b_0 + b_1x_{i1} + b_2x_{i2} + e_i.$$

Используя данные из табл. 4.1, определить:

- 1) оценки параметров уравнения линейной множественной регрессии;
- 2) оценки стандартизованных коэффициентов регрессии;
- 3) оценку дисперсии случайных отклонений;
- 4) стандартные ошибки оценок параметров регрессии;
- 5) статистическую значимость параметров модели;
- 6) средние коэффициенты эластичности;
- 7) коэффициент детерминации и скорректированный коэффициент детерминации;
- 8) значимость уравнения регрессии;
- 9) ошибку аппроксимации;

10) прогнозное значение при жилой площади 45 м² (x_1) и площади кухни 15 м² (x_2).

Решение

1. Для идентификации параметров модели используется матричная формула (4.3)

$$B = (X^T X)^{-1} X^T Y.$$

Причем в рассматриваемом примере вектор параметров B имеет вид

$$B = (b_0, b_1, b_2)^T.$$

Сделаем промежуточные вычисления матричных произведений, а также обращение матрицы.

$$X^T X = \begin{pmatrix} 1 & 1 & \dots & 1 & 1 \\ 21,5 & 20,0 & \dots & 55,0 & 41,5 \\ 12,5 & 10,0 & \dots & 15,0 & 19,0 \end{pmatrix} \begin{pmatrix} 1 & 21,5 & 12,5 \\ 1 & 20,0 & 10,0 \\ \dots & \dots & \dots \\ 1 & 55,0 & 15,0 \\ 1 & 41,5 & 19,0 \end{pmatrix} = \begin{pmatrix} 10 & 344 & 126,5 \\ 344 & 13187,5 & 4549,25 \\ 126,5 & 4549,25 & 1670,75 \end{pmatrix};$$

$$(X^T X)^{-1} = \begin{pmatrix} 10 & 344 & 126,5 \\ 344 & 13187,5 & 4549,25 \\ 126,5 & 4549,25 & 1670,75 \end{pmatrix}^{-1} = \begin{pmatrix} 2,3704 & 0,0013 & -0,1831 \\ 0,0013 & 0,00125 & -0,0035 \\ -0,1831 & -0,0035 & 0,0240 \end{pmatrix};$$

$$X^T Y = \begin{pmatrix} 1 & 1 & \dots & 1 & 1 \\ 21,5 & 20,0 & \dots & 55,0 & 41,5 \\ 12,5 & 10,0 & \dots & 15,0 & 19,0 \end{pmatrix} \begin{pmatrix} 1284,6 \\ 870,2 \\ \dots \\ 1522,5 \\ 1330,0 \end{pmatrix} = \begin{pmatrix} 11503,6 \\ 415251,2 \\ 149605,6 \end{pmatrix}.$$

Теперь рассчитаем вектор оценок параметров модели

$$B = \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 2,3704 & 0,0013 & -0,1831 \\ 0,0013 & 0,00125 & -0,0035 \\ -0,1831 & -0,0035 & 0,0240 \end{pmatrix} \cdot \begin{pmatrix} 11503,6 \\ 415251,2 \\ 149605,6 \end{pmatrix} = \begin{pmatrix} 428,26 \\ 10,10 \\ 29,62 \end{pmatrix}.$$

Запишем модель после оценивания параметров

$$\hat{y} = 428,26 + 10,10x_1 + 29,62x_2.$$

Используя уравнение регрессии, можно оценить влияние каждого из факторов x_1 и x_2 на y . Значение параметра при переменной x_1 ($b_1 = 10,1$) говорит о том, что увеличение жилой площади квартиры на 1 м^2 повлечет за собой увеличение цены квартиры на 10,1 тыс. р. при условии, что значение переменной x_2 останется неизменным. Аналогично значение параметра при переменной x_2 ($b_2 = 29,62$) говорит о том, что увеличение площади кухни квартиры на 1 м^2 повлечет за собой увеличение цены квартиры на 29,62 тыс. р. при условии, что значение переменной x_1 останется неизменным.

2. Для нахождения оценок стандартизованных коэффициентов регрессии по формуле (4.8) определим стандартные отклонения переменных y , x_1 и x_2 (рис. 4.1). Для этого воспользуемся встроенными функциями Excel (прил. 1).

$$\bar{y} = 1150,4; \bar{x}_1 = 34,4; \bar{x}_2 = 12,7; \sigma_y = 225,03; \sigma_{x_1} = 11,54; \sigma_{x_2} = 2,66.$$

Тогда оценки стандартизованных коэффициентов равны

$$\beta_1 = 10,10 \cdot \frac{11,64}{225,03} = 0,522; \quad \beta_2 = 29,62 \cdot \frac{2,66}{225,03} = 0,3496.$$

Получим уравнение регрессии в стандартизованном масштабе

$$\hat{z}_y = 0,522z_{x_1} + 0,3496z_{x_2}.$$

Используя значения стандартизованных коэффициентов, можно ранжировать факторы по силе воздействия на эндогенную переменную: жилая площадь квартиры ($\beta_1 = 0,552$) оказывает более сильное влияние на формирование уровней стоимости квартиры, чем площадь кухни ($\beta_2 = 0,3496$).

3. Рассчитаем вектор теоретических значений эндогенной переменной $\hat{Y}$ и вектор остатков (колонки Е и F рис. 4.1) где

$$\hat{Y} = XB.$$

Тогда $e^T = (268,96; -56,24; \dots; 94,49; -80,15)$.

Оценим дисперсию случайных отклонений

$$e^T e = 268,96^2 + (-56,24)^2 + \dots + (-80,15)^2 = 188164,75; \quad n = 10; \quad m = 2.$$

После подстановки в формулу (4.4) получим

$$s_e^2 = \frac{188164,75}{10 - 2 - 1} = 26880,68;$$

$$s_e = 163,95.$$

Получили, что в среднем расчетные значения цены квартиры по данной модели отличаются от фактических цен на 163,95 тыс. р.

	A	B	C	D	E	F	G	H	I
1	№	y	x ₁	x ₂	y [^]	e	(y-y _{cp}) ²	(y [^] -y _{cp}) ²	e/y
2	1	1284,6	21,5	12,5	1015,6	268,96	18020,38	18149,30	0,21
3	2	870,2	20,0	10,0	926,4	-56,24	78489,63	50139,22	0,06
4	3	902,0	19,0	10,0	916,3	-14,34	61682,69	54763,88	0,02
5	4	1146,5	32,0	10,5	1062,4	84,06	14,90	7730,03	0,07
6	5	1160,3	38,0	11,0	1137,8	22,46	98,80	156,67	0,02
7	6	1105,0	35,0	13,0	1166,8	-61,79	2057,53	269,83	0,06
8	7	1381,3	50,0	14,0	1347,9	33,41	53333,28	39018,32	0,02
9	8	801,2	32,0	11,5	1092,1	-290,86	121912,71	3398,95	0,36
10	9	1522,5	55,0	15,0	1428,0	94,49	138488,18	77086,92	0,06
11	10	1330,0	41,5	19,0	1410,1	-80,15	32270,53	67490,75	0,06
12	Σ	11503,6	344,0	126,5	11503,6	0,0	506368,62	318203,87	
13	среднее	1150,4	34,4	12,7	1150,4	0,0	-	-	0,095
14	σ	225,03	11,64	2,66	178,38	137,17	-	-	

Рис. 4.1. Расчет параметров примера 4.2

4. Вычислим ковариационную матрицу оценок параметров по формуле (4.22). Из матрицы

$$Cov(B) = s_e^2 (X^T X)^{-1} = \begin{pmatrix} 63717,93 & 35,36 & -4920,65 \\ 35,36 & 33,60 & -94,17 \\ -4920,65 & -94,17 & 645,07 \end{pmatrix}.$$

Выбирая диагональные элементы из этой матрицы, получим стандартные ошибки оценок параметров регрессии

$$s_{b_0} = \sqrt{63718,02} = 252,42;$$

$$s_{b_1} = \sqrt{33,60} = 5,80;$$

$$s_{b_2} = \sqrt{64,07} = 25,40.$$

5. Оценка с помощью t -критерия Стьюдента значимости коэффициентов b_1 и b_2 связана с сопоставлением их значений с величиной их стандартных ошибок S_{b_1} и S_{b_2} . Вычислим значения критической статистики для коэффициентов b_1 и b_2 по формуле (4.21)

$$t_{набл}(b_1) = \frac{10,1}{5,8} = 1,74; \quad t_{набл}(b_2) = \frac{29,62}{25,4} = 1,17.$$

Табличное (критическое) значение t -критерия Стьюдента зависит от принятого уровня значимости (в нашем случае $\alpha = 0,05$) и от числа степеней свободы $10 - 2 - 1 = 7$. Получаем $t_{кр}(0,05; 7) = 2,36$.

Поскольку $|t_{набл}(b_1)| < t_{кр}(0,05; 7)$ и $|t_{набл}(b_2)| < t_{кр}(0,05; 7)$, приходим к выводу, что значения коэффициентов b_1 и b_2 статистически незначимы, ненадежны.

6. Для нахождения средних коэффициентов эластичности по формуле (4.6) воспользуемся средними значения переменных (рис. 4.1) $\bar{y} = 1150,4$; $\bar{x}_1 = 34,4$; $\bar{x}_2 = 12,7$. Тогда средние коэффициенты эластичности равны

$$\bar{\epsilon}_{yx_1} = 10,1 \cdot \frac{34,4}{1150,36} = 0,3; \quad \bar{\epsilon}_{yx_2} = 29,62 \cdot \frac{12,65}{1150,36} = 0,33.$$

Следовательно, при увеличении жилой площади квартиры на 1% цена квартиры увеличится в среднем на 0,3%, а при увеличении площади кухни на 1% – на 0,33%.

7. Найдем коэффициент детерминации по формуле (4.13), предварительно рассчитав (3.7)–(3.9)

$$TSS = 506368,62; \quad RSS = 188164,75; \quad ESS = 318203,87.$$

Тогда

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{188164,75}{506368,6} = 0,6284.$$

Следовательно, 62,84% дисперсии цены квартиры объясняется дисперсией жилой площади и площади кухни.

Вычислим значение скорректированного коэффициента детерминации по формуле (4.14):

$$R_{adj}^2 = 1 - (1 - 0,6284) \frac{10 - 1}{10 - 2 - 1} = 0,5222.$$

Скорректированный коэффициент детерминации показывает тесноту связи, которая не зависит от числа факторов в модели и может сравниваться по разным моделям с разным числом факторов.

8. Оценку надежности уравнения регрессии в целом дает F -критерий Фишера, рассчитать который можно двумя способами: с помощью дисперсионного анализа и с помощью коэффициента детерминации, который необходимо дальше сравнить с критическим значением критерия.

А. Проверка с помощью дисперсионного анализа:

$$H_0: D_{\text{факт}} = D_{\text{ост}}; H_1: D_{\text{факт}} > D_{\text{ост}}$$

$$TSS = 506368,62; RSS = 188164,75; ESS = 318203,87.$$

$$\text{По формуле (4.12): } F_{\text{набл.}} = \frac{318203,87 / 2}{188164,75 / 7} = 5,92.$$

Так как $F_{\text{набл}} > F_{\text{кр}}(0,05; 2; 7) = 4,74$, то H_0 отклоняется и уравнение множественной регрессии статистически значимо.

Б. Проверка с помощью коэффициента детерминации:

$$H_0: R^2 = 0; H_1: R^2 > 0.$$

$$\text{По формуле (4.13): } R^2 = 0,6284.$$

Он показывает, что ~63% различий стоимости всех квартир объясняется вариацией жилой площади и площади кухни, а 37% – другими, неучтенными факторами.

$$\text{По формуле (4.15): } F = \frac{0,6284}{1 - 0,6284} \cdot \frac{7}{2} = 5,92.$$

Так как $F_{\text{набл}} > F_{\text{кр}}(0,05; 2; 7) = 4,74$, то H_0 отклоняется, коэффициент детерминации отличается от нуля, следовательно, уравнение регрессии статистически значимо.

В пунктах 6 и 8 получились в некотором роде противоречивые выводы: связь каждого фактора в отдельности с эндогенной переменной незначима, а уравнение в целом значимое.

Это связано с малым объемом выборки и с коррелированностью факторов $r_{x_1 x_2} = 0,64$.

9. Определим ошибку аппроксимации. Для этого найдем

$$\sum \left| \frac{e_i}{y_i} \right| = \left| \frac{268,96}{1284,6} \right| + \dots + \left| \frac{-80,15}{1330} \right| = 0,95;$$

тогда по формуле (3.31)

$$\bar{A} = \frac{0,95}{10} = 0,095 = 9,5\%.$$

Фактические значения стоимости перевозок от расчетных данных по уравнению регрессии в среднем отличаются на 9,5%. Полученное уравнение можно оценить как хорошее.

10. Стоимость квартиры при жилой площади 45 м² (x_1) и площадь кухни 15 м² (x_2), т.е. $x_0^T = (1; 45; 15)$, составит

$$y_0 = 428,26 + 10,10 \cdot 45 + 29,62 \cdot 15 = 1327,02 \text{ тыс. р.}$$

По формулам (4.24)–(4.27) рассчитаем доверительный интервал для среднего и для индивидуального значения. Для этого вычислим $X_0^T (X^T X)^{-1} X_0 = 0,198$, тогда

$$s_{\hat{y}_0} = \sqrt{26880,68 \cdot 0,198} = 73,04;$$

$$s_{\hat{y}_0^*} = \sqrt{26880,68 \cdot (1 + 0,198)} = 179,49.$$

Учитывая $t_{кр}(0,05; 7) = 2,36$, получим доверительный интервал для среднего значения – (1155,31; 1499,72), а для индивидуального значения – (902,60; 1751,43).

4.3. ФИКТИВНЫЕ ПЕРЕМЕННЫЕ В РЕГРЕССИОННЫХ МОДЕЛЯХ

4.3.1. Линейные регрессионные модели с переменной структурой

В регрессионных моделях наряду с количественными переменными часто используются качественные переменные, такие как профессия, пол, образование, климатические условия и т.п.

Чтобы ввести такие переменные в регрессионную модель, им должны быть присвоены те или иные *цифровые метки*, т.е. качественные переменные должны быть преобразованы в количественные.

Такого рода переменные в эконометрике называются *фиктивными* (структурными, или искусственными) переменными, а также индикатором.

Фиктивные переменные отражают два противоположных состояния качественного фактора: фактор действует – фактор не действует. Например: сезон летний – сезон зимний, пол мужской – женский, есть высшее образование – нет высшего образования.

В этом случае фиктивные переменные выражаются в двоичной форме:

$$z = \begin{cases} 0, & \text{не действует,} \\ 1, & \text{действует.} \end{cases}$$

Например, $z = 0$, если потребитель не имеет высшего образования, $z = 1$, если потребитель имеет высшее образование.

Таким образом, кроме моделей, содержащих только количественные переменные x_i , в регрессионном анализе рассматриваются также модели, содержащие лишь качественные переменные (обозначаемые z_i), либо те и другие одновременно.

С помощью большего числа фиктивных переменных можно обрисовать более сложные ситуации. Если качественная переменная имеет k альтернативных значений, то при моделировании используется только $(k - 1)$ фиктивных переменных.

Существуют модели с качественными объясняющими переменными.

Регрессионные модели, содержащие лишь качественные объясняющие переменные, называются *ANOVA-моделями* (моделями дисперсионного анализа).

Например, зависимость начальной заработной платы от образования может быть записана так:

$$y = a + gz + e,$$

где $z = 0$, если претендент на рабочее место не имеет высшего образования, $z = 1$, если имеет. Параметр a определяет среднюю начальную заработную плату при отсутствии высшего образования $\hat{y} = a + g \cdot 0 = a$. Коэффициент g показывает, на какую величину отличаются средние начальные заработные платы при наличии и при отсутствии высшего образования у претендента: $\hat{y} = a + g \cdot 1 = a + g$. Проверая статистическую значимость коэффициента g с помощью t -статистики, можно определить, влияет или нет наличие высшего образования на начальную заработную плату.

ANOVA-модели представляют собой кусочно-постоянные функции. Такие модели в экономике крайне редки. Гораздо чаще встречаются модели, содержащие как количественные, так и качественные переменные. Такие модели называются *ANCOVA-моделями* (моделями ковариационного анализа).

Сначала рассмотрим простую модель заработной платы сотрудника фирмы в зависимости от стажа работы x и пола сотрудника D :

$$y = a + bx + gz + e,$$

где

$$z = \begin{cases} 0, & \text{если сотрудник — женщина,} \\ 1, & \text{если сотрудник — мужчина.} \end{cases}$$

Тогда для женщин ожидаемое значение заработной платы будет $\hat{y} = a + bx$, а для мужчин — $\hat{y} = a + bx + g = (a + g) + bx$. Эти зависимости являются линейными относительно стажа работы x и различаются только величиной свободного члена. Если коэффициент g статистически значим, то можно сделать вывод, что в фирме имеет место дискриминация в заработной плате по

половому признаку. При $g > 0$ она будет в пользу мужчин, при $g < 0$ – в пользу женщин. На рис. 4.2 такие зависимости изображаются параллельными прямыми. Коэффициент g называется дифференциальным свободным членом, так как он показывает, на какую величину изменится свободный член модели при изменении значения фиктивной переменной.




Рис. 4.2. Графики зависимостей заработной платы от пола сотрудника

Влияние качественного фактора может сказываться не только на значении свободного члена, но и на угловом коэффициенте линейной регрессионной модели. Обычно это характерно для временных рядов экономических данных при изменении институциональных условий, введении новых правовых или налоговых ограничений. Тогда зависимость может быть выражена так:

$$y = a + bx + g_1z + g_2zx + e,$$

где

$$z = \begin{cases} 0, & \text{до изменения условий,} \\ 1, & \text{после изменения условий.} \end{cases}$$

В этой ситуации ожидаемое значение зависимой переменной определяется следующим образом:

$$\hat{y} = a + bx, \quad z = 0$$

$$\hat{y} = (a + g_1) + (b + g_2)x, \quad z = 1.$$

Коэффициенты g_1 и g_2 называются соответственно

дифференциальным свободным членом и дифференциальным угловым коэффициентом.

Пример 4.3. Исходные данные по ценам на квартиры представлены в табл. 4.2.

Таблица 4.2

Y	X	Z	Y	X	Z	Y	X	Z	Y	X	Z
6,0	35,0	1	9,3	53,0	1	13,0	71,0	0	12,3	95,0	1
6,3	35,3	1	9,0	55,0	0	8,0	73,0	0	11,8	97,0	0
4,8	36,0	0	7,0	55,1	0	9,8	73,1	1	15,0	97,0	0
5,5	36,0	0	8,1	55,6	0	11,5	74,7	0	21,5	97,5	1
8,0	37,0	1	10,5	58,0	0	14,5	75,0	0	13,5	98,0	0
6,0	37,2	0	7,5	58,0	1	12,0	76,0	1	19,0	101,0	0
5,3	38,0	0	9,8	58,5	0	11,0	79,0	0	17,0	101,4	0
7,1	40,0	1	7,7	58,7	0	11,5	79,0	0	16,3	103,0	1
7,8	40,0	1	10,5	59,6	0	11,5	79,0	0	19,3	105,0	0
8,0	42,0	1	10,8	60,0	0	13,3	79,7	0	15,0	105,0	1
5,5	43,0	0	13,0	60,5	1	14,0	80,0	0	13,7	110,4	1
11,5	45,0	1	10,5	62,0	0	14,0	81,4	0	20,8	111,0	0
6,8	47,5	0	8,5	62,0	1	9,8	84,0	0	19,0	112,0	1
7,3	48,0	0	8,9	63,0	0	12,4	85,0	1	21,4	114,0	1
7,6	49,1	1	8,3	65,0	1	16,5	86,0	0	22,8	115,0	0
7,1	50,0	0	8,5	65,0	1	16,4	90,0	0	15,5	119,8	1
6,7	50,0	0	11,0	67,0	0	19,5	92,0	1	18,5	120,0	0
11,3	53,0	1	11,5	71,0	0	17,0	93,0	0	17,5	121,0	1

По выборочным данным ($n = 72$) исследуется зависимость цены квартир Y на рынке жилья (млн р.) от общей площади X (m^2). Допустим, мы хотим отразить в модели район – центральный или периферийный. Для этого включим в модель фиктивную переменную сдвига Z : $Z = 0$ для периферийных районов, $Z = 1$ для центральных районов

$$y = \beta_0 + \beta_1 x + \beta_2 z + \varepsilon.$$

Построим уравнение регрессии без учета района (рис. 4.3)

$$\hat{y} = 0,014 + 0,161 \cdot x.$$




Рис. 4.3. Пример использования фиктивной переменной

Уравнение регрессии с фиктивной переменной сдвига Z будет иметь вид

$$\hat{y}_{x,z} = -0,075 + 0,161 \cdot x + 0,241 \cdot z = \begin{cases} -0,075 + 0,161 \cdot x, & z = 0, \\ 0,166 + 0,161 \cdot x, & z = 1. \end{cases}$$

Уравнения регрессии (рис. 4.3) для разных районов (по частям выборки) будут соответственно

$$\hat{y}_0 = -1,90 + 0,19 \cdot x, (z = 0, n = 44);$$

$$\hat{y}_1 = 1,92 + 0,14 \cdot x, (z = 1, n = 28).$$


Из полученных уравнений и графиков видно, что одной фиктивной переменной сдвига недостаточно.

Введем дополнительно фиктивную переменную, учитывающую разный наклон данных

$$y = b_0 + b_1x + (a_0 + a_1)z = b_0 + b_1x + b_2z + b_3zx$$

учет разного сдвига

учет разного наклона



Получим уравнение регрессии с учетом разного сдвига Z и наклона ZX , для этого рассчитаем вспомогательную колонку (X умножить на Z) и построим уравнение множественной регрессии от трех переменных

$$\hat{y}_{z,zx} = -1,90 + 0,19 \cdot x + 3,82 \cdot z - 0,05zx$$

или

$$\hat{y}_{z,zx} = \begin{cases} -1,90 + 0,19 \cdot x, & z = 0, \\ 1,92 + 0,14 \cdot x, & z = 1. \end{cases}$$

$$\hat{y}_z = 0,014 + 0,161 \cdot x \rightarrow \hat{y}_{x,z} = \begin{cases} -0,075 + 0,161 \cdot x, & z = 0, \\ 0,166 + 0,161 \cdot x, & z = 1. \end{cases}$$

$$\begin{aligned} \hat{y}_0 &= -1,90 + 0,19 \cdot x \\ \hat{y}_1 &= 1,92 + 0,14 \cdot x \end{aligned} \Leftrightarrow \hat{y}_{z,zx} = \begin{cases} -1,90 + 0,19 \cdot x, & z = 0, \\ 1,92 + 0,14 \cdot x, & z = 1. \end{cases}$$

Получили, что уравнения, построенные с учетом дополнительной фиктивной переменной, которая учитывает разный наклон данных (рис. 4.4), и уравнения, построенные по отдельным выборкам, совпадают.




Рис. 4.4. Пример использования фиктивной переменной, учитывающей разный наклон данных

Показатели регрессионной статистики для моделей без фиктивной переменной и с учетом фиктивной переменной приведены в табл. 4.3 (прил. 1, «Анализ данных – Регрессия»).

Таблица 4.3

ВЫВОД ИТОГОВ	Без фиктивных переменных	С учетом фиктивных переменных
<i>Регрессионная статистика</i>		
Множественный R	0,885	0,896
R-квадрат	0,783	0,802
Нормированный R-квадрат	0,780	0,793
Стандартная ошибка	2,140	2,072
Наблюдения	72	72
Средняя ошибка аппроксимации, %	14,7	12,9

Вывод. Уравнение регрессии с фиктивными переменными позволяет учесть в модели качественные признаки.

А теперь дадим интерпретацию коэффициентов сдвига и наклона

$$y = b_0 + b_1x + b_2z + b_3zx = \begin{cases} b_0 + b_1x, & z = 0, \\ (b_0 + b_2) + (b_1 + b_3)x, & z = 1. \end{cases} \quad (4.29)$$

На одной части выборки регрессия имеет коэффициенты b_0 и b_1 , на другой части выборки они изменяются, соответственно, на величину коэффициентов при фиктивных переменных сдвига и наклона. Значимость коэффициентов при фиктивных переменных определяется с помощью t -статистики.

Использование фиктивных переменных эквивалентно расчету регрессий на отдельных частях выборки.

Статистическая значимость качественных переменных проверяется по t -критерию: исследуем на значимость t -статистику коэффициента при данной фиктивной переменной. Пересчитаем t -статистику в p -значение (табл. 4.4) и сравним с заданной значимостью (5 или 1%) для уравнения с учетом разного сдвига Z и наклона ZX .

Вывод. Район расположения квартиры (за этот параметр отвечает коэффициент b_2 и b_3) ощутимо влияет на ее цену на уровне значимости 1,5% (надежность равна 98,5%).

Таблица 4.4

Коэффициенты	Значения коэффициентов	Стандартная ошибка	t -статистика	p -значение
b_0	-1,90	1,063	-1,791	0,078
b_1	0,19	0,014	13,266	0,000
b_2	3,82	1,515	2,519	0,014
b_3	-0,05	0,020	-2,497	0,015

4.3.2. Тест Чоу на наличие структурного сдвига

Фиктивная переменная разбивает зависимость на две части – до и после внесения изменений в условия её действия (рис. 4.5). Общая зависимость имеет вид кусочно-линейной функции (линия 3), а изменения условий отображаются изменением угла наклона прямой к оси абсцисс (линии 1–2). Здесь исследователь должен принять решение, стоит ли разбивать выборку на части и строить для каждой из них уравнение регрессии (прямые 1 и 2) или ограничиться одной общей линией регрессии (линия 3). Для этого используют *тест Чоу*, который опирается на F -статистику.




Рис. 4.5. Модель изменения институциональных условий при введении новых ограничений

Ситуации, когда возникает потребность в тесте Чоу:

1) есть подозрения, что исходная выборка состоит из двух или более разных подвыборок (например, из-за различия качественной переменной);

2) к имеющейся выборке нужно присоединить дополнительные данные; необходимо выяснить, можно ли считать обе выборки регрессионно однородными.

Суть теста Чоу: проверка гипотезы о совпадении уравнений регрессии для отдельных групп наблюдений (подвыборок).

Когда встречаются наблюдения, которые естественным образом можно разделить на две группы, встает вопрос, строить для этих наблюдений одну линию регрессии или же целесообразно использовать две линии регрессии (рис. 4.6). Пример структурного сдвига: выборка имеет две различных подвыборки. Тест Чоу дает ответ на вопрос: можно ли считать, что две выборки принадлежат одной генеральной совокупности.




Рис. 4.6. Зависимость расходов на обучение в обычных и профессиональных школах Шанхая

Тест Чоу – тест на равенство коэффициентов регрессии в двух выборках. Нулевая гипотеза проверяется с помощью F -статистики для гипотезы о том, что коэффициенты при всех добавленных переменных равны нулю.

Рассмотрим модель множественной регрессии, включающую m параметров. МНК-оценки параметров получим по выборочным данным объемом n . Обозначим: $S_0 = \sum_{i=1}^n e_i^2$ – сумма квадратов остатков для регрессии по всей выборке объемом n . Есть

основание предполагать, что целесообразно общую выборку разбить на две частные выборки объемами n_1 и n_2 ($n_1 + n_2 = n$) и для каждой построить уравнение регрессии, тогда $S_1 = \sum_{i=1}^{n_1} e_i^2$,

$S_2 = \sum_{i=n_1+1}^n e_i^2$ – сумма квадратов остатков для регрессии по ее частям.

Равенство $S_0 = S_1 + S_2$ возможно лишь при совпадении коэффициентов регрессии для всех трёх уравнений. Чем сильнее различие в поведении Y для двух частных регрессий, тем больше S_0 будет превосходить сумму $S_1 + S_2$. Разность $S_0 - (S_1 + S_2)$ является показателем улучшения качества модели при разбиении объема выборки на две части.

Общую выборку целесообразно разбивать на две части только в том случае, если уменьшение дисперсии будет значимо больше оставшейся необъясненной дисперсии при использовании двух регрессий. Анализ выполняется при помощи стандартной процедуры сравнения дисперсий на основе F -статистики. В данном случае статистика в тесте Чоу имеет вид

$$F = \frac{(S_0 - S_1 - S_2) / (m + 1)}{(S_1 + S_2) / (n - 2(m + 1))}. \quad (4.30)$$

Если на заданном уровне значимости $F_{\text{набл}} < F(\alpha; m + 1; n - 2(m + 1))$, то нет смысла разбивать уравнение регрессии на части. В противном случае нулевая гипотеза отвергается, что говорит о том, что целесообразно использовать различные линии регрессии для двух наборов данных.

Если гипотеза о структурной стабильности выборки отклоняется, то исследуется вопрос о причинах структурных различий в подвыборках. Пусть данные в подвыборках описываются двумя уравнениями регрессии

$$\hat{y} = a_1 + b_1 x,$$

$$\hat{y} = a_2 + b_2 x.$$

Тогда возможны следующие варианты:

1) если различия между свободными членами a_1 и a_2 статистически значимы при условии, что различия между параметрами регрессии b_1 и b_2 статистически незначимы, то эти прямые параллельны; при этом наблюдается скачкообразное изменение зависимости в момент x^* при сохранении наклона линии регрессии;

2) если различия между параметрами регрессии b_1 и b_2 статистически значимы при условии, что различия между свободными членами a_1 и a_2 статистически незначимы, то эти прямые пересекают ось ординат в одной точке; в этом случае изменение тенденции связано с изменением среднего прироста динамики, начиная с момента времени x^* при неизменном уровне ряда в момент времени $x = 0$;

3) если различия между свободными членами a_1 , a_2 и параметрами регрессии b_1 , b_2 статистически значимы, то эти прямые различны; в этом случае изменение характера тенденции сопровождается изменением как начального уровня ряда, так и среднего за исследуемый период абсолютного прироста.

Среди моделей с фиктивными переменными наибольшими прогностическими возможностями обладают модели, в которых зависимая переменная y рассматривается как функция ряда экономических факторов x_i и фиктивных переменных z_j . Последние обычно отражают различия в формировании результативного признака по отдельным группам единиц совокупности, т.е. в результате неоднородной структуры пространственного или временного характера.

Использование фиктивных переменных имеет следующие преимущества:

1) интервалы между наблюдениями не обязательно должны быть одинаковыми; в выборке могут быть пропущенные наблюдения;

2) коэффициенты при фиктивных переменных легко интерпретировать, они наглядно представляют структуру динамического процесса;

3) для оценивания модели не приходится выходить за рамки классического метода наименьших квадратов.

Пример 4.4. Исследуем тенденцию изменения заработной платы от стажа работы и пола сотрудника. Вводим фиктивную бинарную переменную для признака «пол»:

$$z = \begin{cases} 0, & \text{если сотрудник – мужчина,} \\ 1, & \text{если сотрудник – женщина.} \end{cases}$$

Можно предположить, что фактор «пол» будет оказывать влияние не только на разницу в заработной плате мужчин и женщин, но и на скорость ее изменения (наклон линии регрессии). Чтобы учесть этот факт, вводим в уравнение фиктивную бинарную переменную для признака «пол», а также переменную для коэффициента наклона – zx . Исходные выборочные данные представлены в табл. 4.5.

Таблица 4.5

i	y	x	z	zx	i	y	x	z	zx
1	8,5	4	1	4	10	12	4	0	0
2	13	5	0	0	11	16	15	1	15
3	9	5	1	5	12	12	10	1	10
4	15	7	0	0	13	22	12	0	0
5	9	7	1	7	14	15	12	1	12
6	9	2	0	0	15	25	15	0	0
7	6	2	1	2	16	18	8	0	0
8	10	3	0	0	17	9,5	8	1	8
9	7	3	1	3	18	20	10	0	0

Решение. Получаем уравнение $y = b_0 + b_1x + b_2z + b_3zx$.

Находим коэффициенты этого уравнения с помощью инструмента «Регрессия» (прил. 1, «Анализ данных – Регрессия») (рис. 4.7)

Коэффициент детерминации уравнения $R^2 = 0,984$, значимость уравнения $F = 283,919$, $F_{кр}(0,05; 3; 14) = 3,34$.

Коэффициенты все статистически значимы (рис. 4.7), t -статистика по абсолютной величине превышает $t_{кр} = 2,145$. Стандартная ошибка $S = 0,75$.

Все параметры модели статистически значимы, и уравнение регрессии статистически значимо.

	Коэффициенты	Стандартная ошибка	t-статистика	p-значение	и.
b0	6,689	0,514	13,009	3,30E-09	
b1	1,270	0,061	20,760	6,48E-12	
b2	-2,079	0,727	-2,859	1,26E-02	
b3	-0,504	0,086	-5,831	4,36E-05	

Рис. 4.7. Расчет статистик для примера 4.4
для уравнения $y = b_0 + b_1x + b_2z + b_3zx$

Вывод. Параметры «стаж» и «пол» оказывают существенное влияние на уровень заработной платы работника, причем не только на ее общее изменение, но и на скорость изменения zx .

Запишем уравнения регрессии отдельно для мужчин и женщин

$$\hat{y}_0 = 6,689 + 1,27x,$$

$$\hat{y}_1 = 4,610 + 0,766x.$$

Получили различие в коэффициентах. На графике рис. 4.8 представлена зависимость заработной платы от стажа работы отдельно для мужчин и женщин.




Рис. 4.8. Зависимость заработной платы работника от стажа работы

Построим уравнение регрессии без учета пола. Получаем уравнение $y = b_0 + b_1x$.

Находим коэффициенты этого уравнения с помощью инструмента «Регрессия» (рис. 4.9)

	Коэффициенты	Стандартная ошибка	t-статистика	p-значение
b0	5,649	1,606	3,518	0,003
b1	1,018	0,191	5,326	0,000

Рис. 4.9. Расчет статистик для примера 4.4
для уравнения $y = b_0 + b_1x$

Коэффициент детерминации уравнения $R^2 = 0,64$, значимость уравнения $F = 28,37$, $F_{кр}(0,05; 1; 16) = 4,49$.

Коэффициенты все статистически значимы (рис. 4.9), t -статистика по абсолютной величине превышает $t_{кр} = 2,12$. Стандартная ошибка $S = 3,33$. $S_0 = 177,5$ – сумма квадратов остатков для полной выборки.

Построим уравнение регрессии отдельно для выборки мужчины ($n_1 = 9$) и для выборки женщины ($n_2 = 9$). Получаем два уравнения $y = b_0 + b_1x$.

Находим коэффициенты этих уравнений с помощью инструмента «Регрессия» (табл. 4.6). Данные запишем через слеш (м/ж).

Таблица 4.6

	Коэффициенты	Стандартная ошибка	t-статистика	p-значение
b_0	6,69/4,61	0,44/0,58	15,13/7,98	0,00/0,00
b_1	1,27/0,77	0,05/0,07	24,15/11,14	0,00/0,00

Коэффициент детерминации уравнения $R^2 = 0,988/0,947$, значимость уравнения $F = 583/124$, $F_{кр}(0,05; 1; 16) = 5,59$.

Коэффициенты все статистически значимы (табл. 9.9), t -статистика по абсолютной величине превышает $t_{кр} = 2,36$. Стандартная ошибка $S = 0,65/0,85$, $S_1 = 1,94$, $S_2 = 5,02$ – сумма квадратов остатков для каждой выборки.

Определим по формуле (4.30) статистику в тесте Чоу

$$F = \frac{(177,5 - 2,94 - 5,02) / (1 + 1)}{(2,94 + 5,02) / (18 - 2(1 + 1))} = 149,09.$$

$F_{\text{набл}} = 149,09 > F_{\text{кр}}(0,05; 2; 14) = 3,74$ нулевая гипотеза отвергается, поэтому целесообразно использовать различные линии регрессии для двух наборов данных.

Контрольные вопросы

1. Что представляет собой фиктивная переменная? Каковы основные причины использования фиктивных переменных в регрессионных моделях?
2. Что представляют собой ANOVA-модели и ANCOVA-модели?
3. В чем суть «ловушки» фиктивных переменных?
4. Чтобы избежать «ловушки», сколько должно быть вводимых фиктивных переменных?
5. В чем суть теста Чоу?

4.4. МУЛЬТИКОЛЛИНЕАРНОСТЬ

Все предыдущие рассуждения и выводы, касающиеся классической множественной регрессии, основывались на предположении, что мы имеем дело с правильной спецификацией модели (в данном случае речь идет о выборе объясняющих переменных). В этой связи возможна мультиколлинеарность факторов.

Термин «коллинеарность» характеризует линейную связь между двумя объясняющими переменными. Мультиколлинеарность означает линейную связь между более чем двумя объясняющими переменными. На практике всегда используется один термин – «мультиколлинеарность».

Указанный термин введен Рагнарсом Фришем.

Различают строгую и нестрогую мультиколлинеарность.

Под строгой мультиколлинеарностью понимают наличие линейной функциональной связи между объясняющими переменными (иногда также и зависимой).

Под нестрогой мультиколлинеарностью понимается наличие сильной линейной корреляционной связи между объясняющими переменными (иногда также и зависимой).

Суть мультиколлинеарности рассмотрим на примере. Пусть

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon \text{ и } x_1 = \alpha_0 + \alpha_1 x_2 \Leftrightarrow x_2 = -\frac{\alpha_0}{\alpha_1} + \frac{1}{\alpha_1} x_1.$$

Тогда $y = (\beta_0 + \beta_1 \alpha_0) + (\beta_2 + \beta_1 \alpha_1) x_2 + \varepsilon \Leftrightarrow y = a + b x_2 + \varepsilon$
или

$$y = (\beta_0 - \beta_1 \frac{\alpha_0}{\alpha_1}) + (\beta_1 + \beta_2 \frac{1}{\alpha_1}) x_1 + \varepsilon \Leftrightarrow y = a_1 + b_1 x_1 + \varepsilon$$

По методу МНК получим a и b , следовательно, для исходных коэффициентов получим систему уравнений

$$\begin{cases} \beta_0 + \beta_1 \cdot \alpha_0 = a, \\ \beta_2 + \beta_1 \cdot \alpha_1 = b \end{cases} \text{ или } \begin{cases} \beta_0 - \beta_1 \frac{\alpha_0}{\alpha_1} = a_1, \\ \beta_1 + \beta_2 \frac{1}{\alpha_1} = b_1. \end{cases}$$

Связь между объясняющими переменными – функциональная.

Строгая мультиколлинеарность не позволяет однозначно определить коэффициенты регрессии и разделить вклады объясняющих переменных x_1 и x_2 в их влиянии на зависимую переменную y .

Причины возникновения мультиколлинеарности:

1) ошибочное включение в уравнение регрессии двух или более линейно зависимых переменных;

2) две (или более) объясняющих переменных, в нормальной ситуации слабо коррелированные, становятся в конкретной выборке сильно коррелированными;

3) в модель включается объясняющая переменная, сильно коррелирующая с зависимой переменной (такая переменная называется доминантной).

Последствия мультиколлинеарности:

1) оценки коэффициентов остаются несмещенными;

2) стандартные ошибки коэффициентов увеличиваются;

3) вычисленные t -статистики занижены;

4) неустойчивость оценок; добавление или исключение малого количества информации (например, только одного наблюдения) может привести к очень сильному изменению оценок коэффициентов; при этом резко уменьшается и точность предсказания по модели;

5) численная неустойчивость процедуры оценивания, вызванная ошибками машинного округления и накоплением этих ошибок;

6) высокая коррелированность переменных лишает смысла их интерпретацию;

7) общее качество уравнения, а также оценки переменных, не связанных мультиколлинеарностью, остаются незатронутыми;

8) чем ближе мультиколлинеарность к строгой (совершенной), тем серьезнее ее последствия.

Внешним признаком наличия мультиколлинеарности служат слишком большие значения элементов матрицы $(X^T X)^{-1}$.

Основной признак мультиколлинеарности – определитель корреляционной матрицы R близок к нулю

$$|R| = \begin{vmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \dots & \dots & \dots & \dots \\ r_{p1} & r_{p2} & \dots & 1 \end{vmatrix} \rightarrow 0.$$

Если бы факторы не коррелировали между собой, то в определителе все внедиагональные элементы равнялись бы нулю, а на диагонали стояли бы единицы. Такой определитель равен единице. Если же, наоборот, между факторами существует полная линейная зависимость и все коэффициенты межфакторной корреляции равны единице, то определитель такой матрицы равен нулю.

Если все объясняющие переменные не коррелированы между собой, то $|R| = 1$, в противном случае $0 \leq |R| < 1$.

Обнаружение мультиколлинеарности. Дополнительные признаки

1. Высокие R^2 и F -статистика, но некоторые (или даже все) коэффициенты незначимы, т.е. имеют низкие t -статистики.
2. Высокие парные коэффициенты корреляции.
3. Высокие частные коэффициенты корреляции.
4. Высокие значения коэффициента VIF («фактор инфляции вариации»).
5. Знаки коэффициентов регрессии противоположны ожидаемым.
6. Добавление или удаление наблюдений из выборки сильно изменяют значения оценок.

Выявление мультиколлинеарности с помощью VIF -теста

Более корректным способом обнаружения мультиколлинеарности считается расчет показателя VIF (Variance Inflation Factor – фактор инфляции вариации)

$$VIF(x_1) = \frac{1}{1 - \sqrt{R_1^2}},$$

$$y_i = \beta_0 + \sum_{j=1}^m \beta_j x_{ij} + \varepsilon_i \Rightarrow x_{i1} = \alpha_0 + \sum_{j=2}^m \alpha_j x_{ij} + \eta_i \rightarrow R_1^2,$$

где R_j^2 – значение множественного коэффициента детерминации, полученное для регрессора x_j как зависимой переменной и остальных независимых переменных.

Значение VIF начинается с 1 и не имеет верхнего предела. Общее эмпирическое правило для интерпретации VIF выглядит следующим образом:

– значение 1 указывает на отсутствие корреляции между данной переменной-предиктором и любыми другими переменными-предикторами в модели;

– значение от 1 до 5 указывает на умеренную корреляцию между данной переменной-предиктором и другими переменными-предикторами в модели, но часто она недостаточно серьезная, чтобы требовать внимания;

– значение больше 5 указывает на потенциально сильную корреляцию между данной переменной-предиктором и другими

переменными-предикторами в модели; в этом случае оценки коэффициентов и p -значения в выходных данных регрессии, вероятно, ненадежны.

Принято, что в случае $VIF > 10$ объясняющие переменные, коррелирующие между собой, считаются мультиколлинеарными.

Методы устранения мультиколлинеарности

- 1) включить более подходящие регрессоры;
- 2) изменить или увеличить выборку;
- 3) увеличить вариацию регрессоров;
- 4) преобразовать мультиколлинеарные переменные:
 - использовать нелинейные формы;
 - использовать агрегаты (линейные комбинации переменных);
 - использовать первые разности вместо самих переменных;
- 5) исключить из модели одну или несколько переменных;
- 6) использовать при оценке коэффициентов метод главных компонент или другие специальные процедуры расчета коэффициентов при плохой обусловленности $(X^T X)$;
- 7) ничего не делать!

Одним из способов устранения мультиколлинеарности является преобразование переменных.

Пусть эмпирическое уравнение регрессии имеет вид

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2,$$

где x_1 и x_2 – коррелированные переменные.

В моделях $\frac{\hat{y}}{x_1} = b'_0 + b'_1 \frac{x_2}{x_1}$ и $\frac{\hat{y}}{x_2} = b''_0 + b''_1 \frac{x_1}{x_2}$ мультиколлинеарность отсутствует.

4.4.1. Тестирование и устранение мультиколлинеарности

Наиболее полным алгоритмом исследования мультиколлинеарности является алгоритм Фаррара – Глобера.

Этот алгоритм содержит три вида статистических критериев проверки наличия мультиколлинеарности:

- 1) всего массива переменных (критерий « χ^2 – хи-квадрат»);
- 2) каждой переменной с другими переменными (F -критерий);
- 3) каждой пары переменных (критерий Стьюдента).

Проверка наличия мультиколлинеарности всего массива переменных (критерий «хи-квадрат»):

- построить корреляционную матрицу R и найти её определитель;
- вычислить наблюдаемое значение статистики Фарара – Глобера по следующей формуле

$$FG = - \left[n - 1 - \frac{1}{6}(2k + 5) \right] \ln(\det[R]), \quad (4.31)$$

где n – количество наблюдений; k – количество факторов (переменных анализа); $\det[R]$ – определитель корреляционной матрицы R .

Для проверки мультиколлинеарности факторов используется гипотеза H_0 : $\det[R] = 1$. Данное распределение имеет приближенное распределение χ^2 (хи-квадрат) с $\nu = 0,5n(n-1)$ степенями свободы. Если $FG > \chi^2_{кр}(\alpha; \nu)$, то гипотеза H_0 отклоняется, мультиколлинеарность считается доказанной.

Проверка наличия мультиколлинеарности каждой переменной с другими переменными (F -критерий):

- вычислить обратную матрицу $C = R^{-1}$;
- вычислить F -критерии

$$F_j = (c_{jj} - 1) \frac{n - k - 1}{k}, \quad (4.32)$$

где c_{jj} – диагональные элементы матрицы C ;

- фактические значения F -критериев сравнить с табличным значением при $\nu_1 = k$ и $\nu_2 = (n - k - 1)$ степенях свободы и уровне значимости α , где k – количество факторов; если $F_j > F_{кр}(\alpha; \nu_1; \nu_2)$, то соответствующая j -я независимая переменная мультиколлинеарна с другими.

Проверка наличия мультиколлинеарности каждой пары переменных (критерий Стьюдента):

– найти частные коэффициенты корреляции по формуле

$$r_{ij()} = \frac{-c_{ij}}{\sqrt{c_{ii} \cdot c_{jj}}}, \quad (4.33)$$

где c_{ij} – элементы матрицы C ; c_{ii} – диагональные элементы матрицы C ;

– вычислить t -статистику; наблюдаемое значение статистики критерия рассчитывается по формуле

$$t_{ij} = \frac{r_{ij} \sqrt{n - l - 2}}{\sqrt{1 - r_{ij}^2}}, \quad (4.34)$$

где r_{ij} – соответственно оценка парного или частного коэффициент корреляции; n – количество наблюдений; l – порядок частного коэффициент корреляции;

– фактические значения критериев t_{ij} сравнить с критическим значением статистики $t_{кр}$ для заданного уровня значимости α и числа степеней свободы $\nu = n - l - 2$; если $|t_{ij}| > t_{кр}(\alpha, \nu)$, то между переменными i и j существует мультиколлинеарность.

4.4.2. Примеры решения задач

Пример 4.5. Исходными данными для анализа являлись данные за 2009 г. по основным показателям баланса компаний-эмитентов отрасли «Связь»¹ (всего 109 компаний).

Объективную картину количественных взаимосвязей финансовых показателей предприятий отрасли можно получить, используя такие данные, как:

– выручка (нетто) от продаж (ВП), дебиторская задолженность (краткосрочная) (ДЗ), запасы готовой продукции и товаров для перепродажи (ЗП), оборотные активы (ОА), основные средства (ОС), прибыль (убыток) от продаж (ПП), чистая прибыль (убыток) (ЧП);

¹ URL: <http://www.fira.ru/>.

это группа активов компании (здесь присутствуют как оборотные², так и внеоборотные³ активы);

– долгосрочные обязательства (ДО), краткосрочные обязательства (КО) – группа пассивов.

Рассмотрим в качестве зависимой переменной y чистую прибыль, а в качестве факторов $X = (x_1, x_2, \dots, x_8)$ показатели, включенные в модель (табл. 4.7).

Таблица 4.7

ЧП	ВП	ДЗ	ДО	ЗП	КО	ОА	ОС	ПП
y	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8

В табл. 4.8 представлена матрица коэффициентов парной корреляции для всех переменных, участвующих в рассмотрении. Матрица получена с помощью инструмента «Корреляция» из пакета «Анализ данных» в Excel.

Визуальный анализ матрицы позволяет установить:

1) переменная y имеет довольно высокие парные корреляции со всеми переменными, кроме переменной x_4 (далее ее не будем рассматривать), что вполне объяснимо, так как предприятия отрасли «Связь» имеют специфическую продукцию;

2) большинство факторных переменных анализа демонстрируют довольно высокие парные корреляции, что обуславливает необходимость проверки факторов на наличие между ними мультиколлинеарности; тем более что одним из условий классической регрессионной модели является предположение о независимости объясняющих переменных.

² К **оборотным активам** относятся активы, которые используются (расходуется) в процессе повседневной хозяйственной деятельности. Например: материальные запасы, дебиторская задолженность, денежные средства и т. д.

³ К **внеоборотным активам** относятся активы, изъятые из хозяйственного оборота, но отражаемые в бухгалтерском учёте. Например: основные средства, нематериальные активы, долгосрочные вложения и т. д.

Таблица 4.8

	y	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
y	1								
x_1	0,85	1							
x_2	0,57	0,70	1						
x_3	0,64	0,62	0,71	1					
x_4	0,13	0,21	0,21	0,19	1				
x_5	0,78	0,87	0,77	0,76	0,26	1			
x_6	0,53	0,63	0,91	0,69	0,22	0,69	1		
x_7	0,72	0,89	0,66	0,63	0,11	0,76	0,56	1	
x_8	0,90	0,94	0,62	0,63	0,11	0,80	0,54	0,85	1

Для выявления мультиколлинеарности факторов выполним тест Фаррара – Глоубера по факторам $x_1, x_2, x_3, x_5, x_6, x_7, x_8$.

Проверка теста Фаррара – Глоубера на мультиколлинеарность факторов включает несколько этапов, реализация которых представлена далее.

Этап 1. Проверка наличия мультиколлинеарности всего массива переменных.

Построим матрицу межфакторных корреляций R (табл. 4.9) и найдем её определитель $\det[R] = 0,0001$ с помощью функции МО-ПРЕД (встроенные функции Excel).

Таблица 4.9

	x_1	x_2	x_3	x_5	x_6	x_7	x_8
x_1	1	0,70	0,62	0,87	0,63	0,89	0,94
x_2	0,70	1	0,71	0,77	0,91	0,66	0,62
x_3	0,62	0,71	1	0,76	0,69	0,63	0,63
x_5	0,87	0,77	0,76	1	0,69	0,76	0,80
x_6	0,63	0,91	0,69	0,69	1	0,56	0,54
x_7	0,89	0,66	0,63	0,76	0,56	1	0,85
x_8	0,94	0,62	0,63	0,80	0,54	0,85	1

Определитель матрицы R стремится к нулю, что позволяет сделать предположение об общей мультиколлинеарности факторов. Подтвердим это предположение оценкой статистики Фаррара – Глоубера.

Вычислим наблюдаемое значение статистики Фаррара – Глоубера по формуле (4.31) для $n = 109$ и $k = 7$

$$FG = - \left[109 - 1 - \frac{1}{6} \cdot (2 \cdot 7 + 5) \right] \cdot \ln(0,0001) = 953,87.$$

Фактическое значение этого критерия FG сравниваем с табличным значением критерия χ^2 с $v = \frac{1}{2} \cdot k \cdot (k - 1) = \frac{1}{2} \cdot 7 \cdot (7 - 1) = 21$, степенью свободы и уровнем значимости $\alpha = 0,05$. Табличное значение $\chi^2 = 32,67$ можно найти с помощью функции ХИ2.ОБР.ПХ (0,05; 21).

Так как $FG > \chi^2$ ($953,87 > 32,67$), гипотеза H_0 отвергается, и доказано, что в массиве объясняющих переменных существует мультиколлинеарность.

Этап 2. Проверка наличия мультиколлинеарности каждой переменной с другими переменными.

Вычислим обратную матрицу R^{-1} с помощью функции Excel МОБР (табл. 4.10).

Таблица 4.10

21,37	1,10	4,33	-7,73	-3,10	-5,52	-10,95
1,10	7,78	0,14	-1,86	-5,67	-1,30	-0,35
4,33	0,14	3,61	-2,85	-1,40	-1,39	-2,21
-7,73	-1,86	-2,85	7,49	1,28	1,63	2,16
-3,10	-5,67	-1,40	1,28	6,55	1,29	1,68
-5,52	-1,30	-1,39	1,63	1,29	5,42	0,28
-10,95	-0,35	-2,21	2,16	1,68	0,28	10,00

Затем вычислим F -критерии (4.32) (табл. 4.11).

Цветом в табл. 4.11 выделены самое большое и самое маленькое значения F -критериев.

Фактические значения F -критериев сравниваются с табличным значением $F_{кр}(0,05; 7; 101) = 2,1$ при уровне значимости $\alpha = 0,05$ и $\nu_1 = 7$ и $\nu_2 = n - k - 1 = 109 - 7 - 1 = 101$ степенях свободы, где k – количество факторов.

Значения F -критерии запишем в табл. 4.11.

Таблица 4.11

F_1	F_2	F_3	F_5	F_6	F_7	F_8
293,97	97,81	37,71	93,62	80,05	63,81	129,86

Так как все значения F -критериев больше табличного, то все исследуемые независимые переменные мультиколлинеарны с другими. Больше других влияет на общую мультиколлинеарность факторов фактор x_1 (ВП), меньше – x_3 фактор (ДО).

Этап 3. Проверка наличия мультиколлинеарности каждой пары переменных.

Вычислим частные коэффициенты корреляции (табл. 4.12) по формуле (4.33).

Матрицу коэффициентов частной корреляции можно получить с помощью программ *VSTAT*, *SPSS*.

Затем вычислим t -критерии по формуле (4.34) (табл. 4.13).

В табл. 4.13 цветом выделены значения t -критерия, которые меньше табличного значения, а в табл. 4.12 – соответствующие им статистически незначимые коэффициенты частной корреляции.

Фактические значения t -критериев сравниваются с табличным значением $t_{кр}(0,05; 101) = 1,98$.

Таблица 4.12

	x_1	x_2	x_3	x_5	x_6	x_7	x_8
x_1							
x_2	-0,09						
x_3	-0,49	-0,03					
x_5	0,61	0,24	0,55				
x_6	0,26	0,79	0,29	-0,18			
x_7	0,51	0,20	0,31	-0,26	-0,22		
x_8	0,75	0,04	0,37	-0,25	-0,21	-0,04	

Значения t -критериев запишем в табл. 4.13.

Таблица 4.13

	x_1	x_2	x_3	x_5	x_6	x_7	x_8
x_1							
x_2	-0,86						
x_3	-5,69	-0,26					
x_5	7,75	2,52	6,59				
x_6	2,73	13,12	3,02	-1,87			
x_7	6,01	2,05	3,32	-2,66	-2,24		
x_8	11,35	0,40	3,97	-2,60	-2,14	-0,38	

Из табл. 4.12–4.13 видно, что две пары факторов x_6 и x_2 , x_8 и x_1 имеют высокую статистически значимую частную корреляцию, т. е. являются мультиколлинеарными. Для того чтобы избавиться от мультиколлинеарности, можно исключить одну из переменных коллинеарной пары. В паре x_8 (ПП) и x_1 (ВП) оставляем x_8 , так как у нее меньше связи с другими факторами; в паре x_6 (ОА) и x_2 (ДЗ) оставим x_6 , во-первых, с экономической точки зрения, а во-вторых, у нее меньше значение F -критерия (табл. 4.11), значит, она меньше влияет на общую мультиколлинеарность факторов.

Таким образом, в результате проверки теста Фаррара – Глоубера остается пять факторов: x_3 , x_5 , x_6 , x_7 , x_8 (ДО, КО, ОА, ОС, ПП).

Завершая процедуры корреляционного анализа, целесообразно посмотреть частные корреляции выбранных факторов с результатом y . В последнем столбце табл. 4.14 представлены значения t -критерия для столбца y .

Из табл. 4.14 видно, что межфакторные частные корреляции слабые, а переменная y (ЧП) имеет высокую и одновременно статистически значимую частную корреляцию только с фактором x_8 (ПП).

Таблица 4.14

	y	x_3	x_5	x_6	x_7	x_8	t -критерий $t_{кр}(0,05; 103) = 1,98$
y							
x_3	0,16						1,62
x_5	0,17	0,34					1,74
x_6	-0,02	0,34	0,28				-0,24
x_7	-0,24	0,12	0,17	0,07			-2,48
x_8	0,71	-0,12	0,15	-0,04	0,59		10,22

Уточнение набора факторов, наиболее подходящих для регрессионного анализа, осуществляется другими методами отбора.

Контрольные вопросы

1. Как вы понимаете линейную зависимость и линейную независимость между m -случайными величинами (между m -векторами)?
2. Что такое строгая мультиколлинеарность? Для каких моделей возникает свойство мультиколлинеарности (нестрогой)?
3. В чем недостаток модели, обладающей свойством мультиколлинеарности?
4. Что следует предпринять, чтобы устранить мультиколлинеарность?
5. Как получить матрицу факторов в стандартизованном виде? Как выражаются элементы этой матрицы?
6. Как определяется корреляционная матрица R_X факторов на основе выборочных данных? Какова её размерность? Имеют ли её элементы размерность? Какие ограничения накладываются на её элементы r_{ii} и r_{ik} ($i \neq k$)?
7. Какие признаки мультиколлинеарности несет в себе корреляционная матрица факторов?
8. Как записать выражение для МНК-оценок параметров модели линейной регрессии в стандартизованном виде? Чем удобна эта форма решения для коэффициентов модели?

9. В чем суть статистической проверки гипотезы о наличии мультиколлинеарности методом Феррара – Глобера?

10. Чем отличаются процедуры тестирования модели на общую мультиколлинеарность и коллинеарность между парами факторов?

4.5. ГЕТЕРОСКЕДАСТИЧНОСТЬ

Гетероскедастичность – это типичная «болезнь» пространственных данных, поэтому лучше по умолчанию исходить из того, что она в модели есть. Тем не менее иногда бывает полезно уметь аккуратно проверить её наличие. Должна быть проведена предварительная работа:

- 1) выяснить, нет ли очевидных ошибок спецификации;
- 2) определить, можно ли содержательно предполагать какой-то вид гетероскедастичности;
- 3) рассмотреть графики остатков:

$$e(Y), e(X_j), \quad j = \overline{1, m}.$$

Для обнаружения гетероскедастичности можно использовать два традиционных подхода: графический анализ данных и формальные статистические тесты: ранговой корреляции Спирмена; Парка; Глейзера; Голдфельда – Квандта; Уайта.

Графический анализ. По оси абсцисс откладываются значения объясняющей переменной x_i (для парной регрессии) или линейная комбинация объясняющих переменных y_i (для множественной регрессии), а по оси ординат – отклонения e_i или e_i^2 , $i = \overline{1, n}$. Если все отклонения e_i или e_i^2 находятся внутри горизонтальной полосы постоянной ширины, то существует гомоскедастичность (рис. 4.10), в противном случае – гетероскедастичность (рис. 4.11)

Тест ранговой корреляции Спирмена. Это тест на гетероскедастичность, устанавливающий, что стандартное отклонение остаточного члена регрессии имеет нестрогую линейную зависимость с объясняющей переменной. Тест основан на вычислении коэффициента ранговой корреляции между абсолютными значениями остатков регрессии e_i и значениями фактора – регрессора x_i .




Рис. 4.10. Гомоскедастичность (разброс остатков вокруг нуля равномерен)




Рис. 4.11. Гетероскедастичность (разброс остатков разброс вокруг нуля зависит от значения регрессора)

При использовании данного теста предполагается, что дисперсии отклонений остатков будут монотонно изменяться (увеличиваться или уменьшаться) с увеличением фактора x .

Поэтому значения e_i и x_i будут коррелированы (возможно, нелинейно!). Рассмотрим алгоритм применения.

1. Рассчитывается уравнение $\hat{y}_i = b_0 + \sum_{j=1}^m b_j x_{ij}$ и вычисляются

остатки $e_i = y_i - \hat{y}_i$, $i = \overline{1, n}$.

2. Рассчитываются абсолютные значения e_i .
3. Значения фактора ранжируются.
4. Вычисляются ранги фактора и абсолютных остатков d_x и d_e .

5. Рассчитывается коэффициент ранговой корреляции Спирмена

$$r_{x,e} = 1 - 6 \cdot \frac{\sum d_i^2}{n \cdot (n^2 - 1)}, \quad (4.35)$$

где d_i – разность между рангами x_i и $|e_i|$ – $d_i = d_x - d_e$; n – число наблюдений.

6. Гипотеза $H_0 : r_{x,e} = 0$ проверяется на основе t -статистики:

$$t = \frac{r_{x,e} \sqrt{n-2}}{\sqrt{1-r_{x,e}^2}}.$$

Если $|t_n| > t_{кр}(\alpha; n-2)$, то гипотеза о равенстве нулю коэффициента корреляции отклоняется и существует гетероскедастичность. В противном случае H_0 принимается, т.е. гомоскедастичность остатков не отклоняется.

В модели множественной регрессии проверка нулевой гипотезы может осуществляться с помощью t -статистики по каждому фактору отдельно.

Тест Парка. Пусть дисперсия $\sigma_1^2 = \sigma^2(e_i)$ является функцией i -го значения x_i объясняющей переменной. Парк предложил следующую функциональную зависимость:

$$\sigma_{e_i}^2 = \sigma^2 x_i^\beta e^{\eta_i} \Rightarrow \ln \sigma_{e_i}^2 = \ln \sigma^2 + \beta \ln x_i + \eta_i. \quad (4.36)$$

Так как $\sigma_{e_i}^2$ неизвестны, то их заменяют оценками квадратов отклонений e_i^2 . Критерий Парка включает следующие этапы:

- 1) строится уравнение $y_i = b_0 + b_1 x_i + e_i$;
- 2) для каждого наблюдения определяется $\ln e_i^2 = \ln(y_i - \hat{y}_i)$;
- 3) строится регрессия $\ln e_i^2 = \alpha + \beta \ln x_i + \eta_i$ (*), где $\alpha = \ln \sigma^2$; в случае множественной регрессии зависимость строится для каждой объясняющей переменной;
- 4) проверяется статистическая значимость коэффициента β уравнения (*) на основе t -статистики $t = \frac{\beta}{s_\beta}$; если коэффициент β

статистически значим, то это означает наличие связи между $\ln e_i^2$ и $\ln x_i$, т.е. гетероскедастичность в статистических данных возможна.

Тест Глейзера. Аналогичен тесту Парка. По данному методу оценивается регрессия зависимых модулей отклонений $|e_i|$ от x_i . При этом зависимость моделируется следующим образом:

$$|e_i| = \alpha + \beta x_i^\gamma + \eta_i. \quad (4.37)$$

Изменяя значения $\gamma = \dots; -1; -0,5; 0,5; 1; \dots$, строят несколько моделей регрессии. Статистическая значимость коэффициентов в каждом конкретном случае фактически означает наличие гетероскедастичности.

Если для нескольких моделей будет получена значимая оценка β , то характер гетероскедастичности определяют по наиболее значимой из них.

Тест Голдфельда – Квандта. В данном случае предполагается, что стандартное отклонение пропорционально значению переменной x_j , т.е.

$$\sigma_i^2 = \sigma^2 x_{ji}^2, \quad i = \overline{1, n}.$$

Предполагается, что остатки имеют нормальное распределение и отсутствует автокорреляция остатков.

Алгоритм применения:

1) все n наблюдений упорядочиваются по величине x_i ;
 2) отбрасывают среднюю треть упорядоченных наблюдений; для первой и последней трети строятся две отдельные регрессии, используя ту же спецификацию модели регрессии;

3) количество наблюдений в этих подвыборках должно быть одинаково; обозначим его l ;

4) берутся суммы квадратов остатков для регрессий по первой трети $RSS_1 = \sum_{i=1}^l e_i^2$ и последней трети $RSS_3 = \sum_{i=n-l+1}^n e_i^2$; рассчитывают их отношение

$$F_{GC} = \frac{RSS_3 / (l - m - 1)}{RSS_1 (l - m - 1)} = \frac{RSS_3}{RSS_1}; \quad (4.38)$$

5) используют F -тест для проверки гомоскедастичности; если статистика F_{GQ} удовлетворяет неравенству

$$F_{GC} > F_{кр}(\alpha; l - m - 1; l - m - 1),$$

то гипотеза гомоскедастичности остатков отвергается на уровне значимости α ;

6) этот же тест может быть использован и при предположении об обратной пропорциональности между дисперсией и значениями объясняющей переменной; в этом случае статистика Фишера принимает вид

$$F_{GC} = \frac{RSS_1}{RSS_3}. \quad (4.39)$$

Все рассмотренные тесты позволяют обнаружить лишь наличие гетероскедастичности, но не позволяют оценить характер зависимости дисперсии ошибок регрессии от значений регрессоров и, следовательно, не представляют способов устранения гетероскедастичности.

Тест Уайта. Предполагается, что дисперсии $\sigma_{e_i}^2$ связаны с объясняющими переменными x_j ($j = 1, m$) в виде:

$$\sigma_{e_i}^2 = f(x_{i1}, x_{i2}, \dots, x_{im}) + \eta_i, \quad i = \overline{1, n},$$

где $f(\cdot)$ – квадратичная функция от аргументов, так как дисперсии $\sigma_{e_i}^2$ неизвестны, то их заменяют оценками квадратов отклонений e_i^2 .

Алгоритм применения (на примере трех переменных)

1. Строится уравнение регрессии:

$$\hat{y}_i = b_0 + b_1 x_{i1} + b_2 x_{i2} + b_3 x_{i3}$$

и вычисляются остатки $e_i = y_i - \hat{y}_i$, $i = \overline{1, n}$.

2. Оценивают вспомогательное уравнение регрессии:

$$e_i^2 = \alpha_0 + \alpha_1 x_{i1} + \alpha_2 x_{i2} + \alpha_3 x_{i3} + \alpha_4 x_{i1}^2 + \alpha_5 x_{i2}^2 + \alpha_6 x_{i3}^2 + \alpha_7 x_{i1} x_{i2} + \alpha_8 x_{i1} x_{i3} + \alpha_9 x_{i2} x_{i3} + \eta_i.$$

3. Определяют из вспомогательного уравнения тестовую статистику

$$U = nR^2. \quad (4.40)$$

4. Проверяют общую значимость уравнения с помощью критерия χ^2 . Если

$$U > \chi^2(\alpha; k),$$

то гипотеза гомоскедастичности отвергается. Число степеней свободы k равно 9.

Тест Уайта более общий, чем тест Голдфельда – Квандта.

Неудобство использования теста Уайта:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2.$$

Если отвергается нулевая гипотеза о наличии гомоскедастичности, то не ясно, что делать дальше.

4.5.1. Устранение гетероскедастичности

При установлении гетероскедастичности возникает необходимость преобразования модели с целью устранения данного недостатка. Вид преобразования зависит от того, известны или нет дисперсии отклонений σ_i^2 .

Если дисперсии отклонений **известны** для каждого наблюдения, применяется метод *взвешенных наименьших квадратов* (ВНК), который состоит в следующем: наблюдения с наименьшими дисперсиями получают наибольшие «веса», а наблюдения с наибольшими дисперсиями – наименьшие «веса». В результате наблюдения с меньшими дисперсиями отклонений будут более значимыми при оценке параметров регрессии, чем наблюдения с большими дисперсиями, при этом повышается вероятность получения более точных оценок.

Гетероскедастичность устраняется, если разделить каждое наблюдаемое значение на соответствующее ему значение дисперсии. Рассмотрим для простоты ВНК на примере парной

регрессии ($\sigma_i = \sqrt{\sigma_i^2}$):

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad \xRightarrow{\cdot \frac{1}{\sigma_i}} \quad \frac{y_i}{\sigma_i} = \beta_0 \frac{1}{\sigma_i} + \beta_1 \frac{x_i}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}. \quad (4.41)$$

После замены получим уравнение регрессии **без свободного члена**, но с **двумя факторами** и с преобразованным отклонением:

$$y_i^* = \frac{y_i}{\sigma_i}; \quad x_i^* = \frac{x_i}{\sigma_i}; \quad z_i = \frac{1}{\sigma_i}; \quad v_i = \frac{\varepsilon_i}{\sigma_i} \Rightarrow y_i^* = \beta_0 z_i + \beta_1 x_i^* + v_i.$$

Для v_i выполняется условие гомоскедастичности, так как

$$M(v_i) = M\left(\frac{\varepsilon_i}{\sigma_i}\right) = \frac{1}{\sigma_i^2} M(\varepsilon_i) = 0,$$

$$\sigma^2(v_i) = M(v_i - M(v_i))^2 = M(v_i^2) = \frac{1}{\sigma_i^2} M(\varepsilon_i^2) = \frac{1}{\sigma_i^2} \sigma_i^2 = 1.$$

Для применения ВНК необходимо знать фактические значения дисперсий отклонений σ_i^2 . На практике такие значения известны крайне редко. Поэтому, чтобы применить ВНК, необходимо сделать реалистические предположения о значениях σ_i^2 . Чаще всего предполагается, что дисперсии отклонений пропорциональны или значениям x_i , или значениям x_i^2 .

Если предположить, что *дисперсии пропорциональны значениям фактора x* , т.е.

$$\sigma_i^2 = \sigma^2 x_i,$$

тогда после деления левой и правой частей (4.41) на $\sqrt{x_i}$:

$$\frac{y_i}{\sqrt{x_i}} = \frac{\beta_0}{\sqrt{x_i}} + \beta_1 \frac{x_i}{\sqrt{x_i}} + \frac{\varepsilon_i}{\sqrt{x_i}}, \text{ или } \frac{y_i}{\sqrt{x_i}} = \beta_0 \frac{1}{\sqrt{x_i}} + \beta_1 \sqrt{x_i} + v_i,$$

которое не имеет свободного члена, но зависит от двух факторов. Здесь для случайных отклонений $v_i = \varepsilon_i / \sqrt{x_i}$ выполняется условие гомоскедастичности:

$$\sigma^2(v_i) = \sigma^2\left(\frac{\varepsilon_i}{\sqrt{x_i}}\right) = \frac{1}{x_i} \sigma^2(\varepsilon_i) = \frac{1}{x_i} \sigma^2 x_i = \sigma^2 = \text{const.}$$

Следовательно, для последней регрессии применим обычный МНК. Оценив коэффициенты a и b , возвращаемся к исходному уравнению регрессии.

Если предположить, что дисперсии σ_i^2 пропорциональны x_i^2 , то соответствующим преобразованием будет деление уравнения регрессии (4.41) на x_i :

$$\frac{y_i}{x_i} = \beta_0 \frac{1}{x_i} + \beta_1 + v_i, \quad (4.42)$$

в котором свободный член β_0 стал коэффициентом, а коэффициент β_1 – свободным членом. Здесь для отклонений v_i также выполняется условие гомоскедастичности. Применяя обычный

МНК в преобразованных переменных $y_i^* = \frac{y_i}{x_i}$; $z_i = \frac{1}{x_i}$, получим

оценки параметров β_0 и β_1 , после чего возвращаемся к исходному уравнению.

Если в уравнении регрессии присутствует несколько объясняющих переменных, вместо конкретной переменной x_j используется исходное уравнение множественной регрессии

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_m x_m,$$

т.е. фактически линейная комбинация факторов. В этом случае получают следующую регрессию:

$$\frac{y_i}{\sqrt{\hat{y}_i}} = b_0 \frac{1}{\sqrt{\hat{y}_i}} + b_1 \frac{x_{i1}}{\sqrt{\hat{y}_i}} + \dots + b_m \frac{x_{im}}{\sqrt{\hat{y}_i}} + \frac{\varepsilon_i}{\sqrt{\hat{y}_i}}.$$

4.5.2. Примеры решения типовых задач

Пример 4.6. С помощью МНК оценена следующая регрессионная зависимость (в скобках приведены стандартные ошибки для каждого коэффициента регрессии):

$$\hat{y} = 604 + 0,194 \cdot x$$

$$(5700) \quad (0,013) \quad R^2 = 0,89$$

Проверим данную модель на гетероскедастичность с помощью теста Спирмена (4.35). Проранжированные отклонения от линии регрессии по абсолютному значению и значения x приведены на рис. 4.12, для этих данных вычислены показатели d_x и d_e .

	A	B	C	D	E	F	G	H	I	J
1	x	Ранг x	$ e $	Ранг $ e $	d_i^2	x	Ранг x	$ e $	Ранг $ e $	d_i^2
2	13746	1	547	2	1	130823	15	14185	23	64
3	14386	2	1130	4	4	135961	16	4176	12	16
4	24646	3	2620	8	25	151266	17	3976	11	36
5	41506	4	1417	5	1	198432	18	4233	14	16
6	44753	5	5955	15	100	232006	19	1025	3	256
7	50919	6	2629	9	9	261386	20	6270	17	9
8	52662	7	6768	19	144	334286	21	16758	24	9
9	71039	8	6264	18	100	380820	22	86952	28	36
10	72608	9	4227	13	16	420788	23	27034	25	4
11	74121	10	3611	10	0	483652	24	14180	22	4
12	87352	11	499	1	100	547203	25	6024	16	81
13	97624	12	2067	6	36	1016286	26	62439	27	1
14	98861	13	10360	20	49	1024609	27	45333	26	1
15	122926	14	10929	21	49	1330998	28	2093	7	441
16									Σ	1608
17										

Рис. 4.12. Таблица исходных данных для примера 4.6 и промежуточные расчеты для теста Спирмена

Построим график зависимости $|e_i|$ от x_i (рис. 4.13). Из графического представления можно сделать предположение о гетероскедастичности.

Сумма d_i^2 составила 1608. Таким образом, коэффициент ранговой корреляции (4.35) составляет

$$r_{x,e} = 1 - 6 \cdot \frac{1608}{28 \cdot (28^2 - 1)} = 0,56.$$

$$t = \frac{r_{x,e} \sqrt{n-2}}{\sqrt{1-r_{x,e}^2}}.$$




Рис. 4.13. График зависимости $|e_i|$ от x_i

Получаем $|t_{\text{набл}}| = 3,45 > t_{\text{кр}}(0,05; 26) = 2,06$, H_0 отвергается, существует гетероскедастичность.

Пример 4.7. По данным примера 4.6 (рис. 4.12) проведем оценку уравнения (4.38) для значений γ от $-1,0$ до $1,5$, тест Глейзера. Результаты представлены в обобщенном виде на рис. 4.14.

γ	β	$s(\beta)$	$t_{\text{набл}}(\beta)$	R^2
-1	-351000000	194000000	1,80927835	0,11
-0,5	-4210000	1710000	2,4619883	0,19
-0,25	560000	210000	2,66666667	0,23
0,25	1640	520	3,15384615	0,28
0,5	36,1	11,08	3,25812274	0,27
1	0,026	0,01	2,6	0,21
1,5	0,0000198	0,0000093	2,12903226	0,15

Рис. 4.14. Показатели моделей для теста Глейзера

Следует отметить, что различные оценки β несравнимы, так как определение объясняющей переменной x^γ в каждом случае разное. Тем не менее уровни R^2 здесь сравнимы в том смысле, что зависимая переменная в каждом случае одна и та же.

Статистически значимые на уровне 1% оценки были получены для двух значений γ (0,25 и 0,5). Показатели критических значений

t -статистики для уровня значимости 1 и 5% – $t_{кр}(0,01;26) = 2,78$, $t_{кр}(0,05;26) = 2,06$.

Наилучшие результаты соответствуют значениям γ , равным 0,25 и 0,5, и, следовательно, стандартное отклонение распределения e возрастает с увеличением x , но не в той же пропорции. Статистическая значимость коэффициентов в каждом конкретном случае фактически означает наличие гетероскедастичности.

Пример 4.8. Государственные расходы на образование в различных странах и ВВП на рис. 4.15. Данные отсортированы по возрастанию ВВП (x). Для теста Голдфелда – Квандта на основе данных с помощью обычного МНК были оценены регрессии сначала по наблюдениям для 11 стран с наименьшим x , а затем – для 11 стран с наибольшим x .

	A	B	C	D	E	F
1	Страна	Расходы (y)	ВВП (x)	Страна	Расходы (y)	ВВП (x)
2	Люксембург	0,34	5,67	Швейцария	5,31	101,70
3	Уругвай	0,22	10,10	С.Аравия	6,40	116,00
4	Сингапур	0,32	11,30	Бельгия	7,15	119,50
5	Ирландия	1,23	18,90	Швеция	11,22	124,20
6	Израиль	1,81	20,90	Австралия	8,66	141,00
7	Венгрия	1,02	22,20	Аргентина	5,56	153,90
8	Н.Зеландия	1,27	23,80	Нидерланды	13,41	169,40
9	Португалия	1,07	24,70	Мексика	5,46	186,30
10	Гонконг	0,67	27,60	Испания	4,79	211,80
11	Чили	1,25	27,60	Бразилия	8,92	249,70
12	Греция	0,75	40,20	Канада	18,90	261,40
13	Финляндия	2,80	51,60	Италия	15,95	395,50
14	Норвегия	4,90	57,70	Англия	29,90	535,00
15	Югославия	3,50	63,00	Франция	33,59	655,30
16	Дания	4,45	66,30	ФРГ	38,62	815,00
17	Турция	1,60	67,00	Япония	61,61	1040,00
18	Австрия	4,26	76,90	США	181,30	2586,00

Рис. 4.15. Исходные данные для примера 4.8

Данные МНК для каждой последовательности занесены в таблицу на рис. 4.16. Первое уравнение для стран с наименьшим x , второе – с наибольшим x .

1		β_0	β_1	RSS	F	R^2
2	1 уравнение	0,44	0,02	1,97	2,07	0,19
3	2 уравнение	-8,63	0,07	379,28	599,36	0,99

Рис. 4.16. Данные МНК для двух видов наблюдений

Отношение $F_{GC} = \frac{RSS_3}{RSS_1} = \frac{379,28}{1,97} = 192,19$. Статистика F_{GQ} удовлетворяет неравенству

$$F_{GC} > F_{кр}(0,05;9;9) = 3,18,$$

следовательно, гипотеза о гомоскедастичности остатков отвергается на уровне значимости 0,05.

Уравнение модели будет $\hat{y} = -2,32 + 0,067 \cdot x$, $R^2 = 0,97$.

Рассмотрим случай устранения гетероскедастичности. Предполагаем, что $\sigma(e_i) = \lambda x_i$, где x_i регрессор, вызывающий гетероскедастичность. Пусть для примера это регрессор x_i . Уравнение делится на значение этого регрессора

$$\frac{y_i}{x_i} = \beta_0 \frac{1}{x_i} + \beta_1 + v_i.$$

Применяя обычный МНК в преобразованных переменных

$$y_i^* = \frac{y_i}{x_i}; \quad z_i = \frac{1}{x_i},$$

получим оценки параметров β_0 и β_1 , после чего возвращаемся к исходному уравнению

$$y_i^* = \beta_0 z_i + \beta_1 + v_i$$

Данные для построения уравнения представлены на рис. 4.17

Страна	y/ВВП	1/ВВП	Страна	y/ВВП	1/ВВП
Люксембург	0,060	0,1764	Швейцария	0,052	0,0098
Уругвай	0,022	0,0990	С.Аравия	0,055	0,0086
Сингапур	0,028	0,0885	Бельгия	0,060	0,0084
Ирландия	0,065	0,0529	Швеция	0,090	0,0081
Израиль	0,087	0,0478	Австралия	0,061	0,0071
Венгрия	0,046	0,0450	Аргентина	0,036	0,0065
Н.Зеландия	0,053	0,0420	Нидерланды	0,079	0,0059
Португалия	0,043	0,0405	Мексика	0,029	0,0054
Гонконг	0,024	0,0362	Испания	0,023	0,0047
Чили	0,045	0,0362	Бразилия	0,036	0,0040
Греция	0,019	0,0249	Канада	0,072	0,0038
Финляндия	0,054	0,0194	Италия	0,040	0,0025
Норвегия	0,085	0,0173	Англия	0,056	0,0019
Югославия	0,056	0,0159	Франция	0,051	0,0015
Дания	0,067	0,0151	ФРГ	0,047	0,0012
Турция	0,024	0,0149	Япония	0,059	0,0010
Австрия	0,055	0,0130	США	0,070	0,0004

Рис. 4.17. Взвешенные исходные данные

Данные для взвешенного МНК представлены на рис. 4.18.

	β_0	β_1	RSS	F	R^2
1 уравнение	0,04	0,05	0,0043	0,11	0,01
2 уравнение	0,06	-2,12	0,0032	0,46	0,05

Рис. 4.18. Данные для взвешенного МНК для двух видов наблюдений

Отношение

$$F_{GC} = \frac{RSS_3}{RSS_1} = \frac{0,0032}{0,0043} = 0,735,$$

а $F_{GC} = \frac{RSS_1}{RSS_3} = \frac{0,0043}{0,0032} = 1,36$. Статистика F_{GQ} удовлетворяет неравенству $F_{GC} < F_{кр}(0,05; 9; 9) = 3,18$. Уравнение модели будет

$$\hat{y} = -0,066 + 0,053 \cdot x, \quad R^2 = 0,94.$$

Тогда гипотеза о гомоскедастичности остатков принимается на уровне значимости 0,05.

Диаграмма рассеяния и графики моделей с гетероскедастичными и гомоскедастичными случайными возмущениями представлены на рис. 4.19.




Рис. 4.19. Графики моделей с гетероскедастичными и гомоскедастичными случайными возмущениями

4.6. АВТОКОРРЕЛЯЦИЯ

4.6.1. Определение автокорреляции

Автокорреляция (последовательная корреляция) – это корреляция между наблюдаемыми показателями во времени (временные ряды) или в пространстве (перекрестные данные).

Автокорреляция остатков характеризуется тем, что не выполняется предпосылка 3⁰ использования МНК:

$$\sigma_{\varepsilon_i \varepsilon_j} = \text{cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} 0, & i \neq j \\ \sigma^2, & i = j \end{cases}$$

Существует деление автокорреляции на *чистую* и *ложную*.

Чистая вызывается зависимостью случайного члена от прошлых значений. Она, в свою очередь, делится на автокорреляцию первого порядка, второго порядка и высших порядков.

Ложная автокорреляция вызывается неправильной спецификацией модели.

Автокоррелированность возмущений можно учесть с помощью так называемых моделей авторегрессии. Простейшей из таких моделей является модель авторегрессионного процесса первого порядка (процесс авторегрессии первого порядка). Такой процесс описывается следующим уравнением

$$e_t = \rho e_{t-1} + v_t, \quad (4.43)$$

где e_t – случайный член рассматриваемого уравнения регрессии; ρ – коэффициент автокорреляции первого порядка; v_t – случайный член, не подверженный автокорреляции. Параметр ρ называется коэффициентом авторегрессии, для него должно выполняться ограничение $|\rho| < 1$, которое является необходимым условием стационарности процесса.

Уравнение $e_t = \rho_1 e_{t-1} + \rho_2 e_{t-2} + v_t$ является моделью авторегрессионного процесса второго порядка, где e_t – случайный член рассматриваемого уравнения регрессии; ρ_1, ρ_2 – коэффициент автокорреляции первого порядка; v_t – случайный член, не подверженный автокорреляции.

Положительная автокорреляция – наиболее важный для экономики случай (рис. 4.20, *а* – положительная; рис. 4.20, *б* – отрицательная). В уравнении (4.43) коэффициент $\rho > 0$; при $\rho < 0$ – отрицательная автокорреляция.

Причины чистой автокорреляции:

1) инерция – трансформация, изменение многих экономических показателей обладает инерционностью;

2) ошибки спецификации модели, заключающиеся в невключении в модель существенных переменных;

3) The Cobweb effect (паутинообразный эффект) – экономические показатели реагируют на изменения экономических условий с запаздыванием (временной лаг);

4) «манипулирование данными», сглаживание данных – усреднение данных по некоторому продолжительному интервалу времени.




Рис. 4.20. Автокорреляция

Последствия автокорреляции:

- 1) хотя оценки МНК коэффициентов регрессии останутся несмещенными, они уже не будут эффективными;
- 2) оценки МНК для стандартных отклонений коэффициентов регрессии будут смещенными, чаще всего вниз, т.е. будут заниженными;
- 3) статистики t и F будут неадекватными; следствием заниженности оценок стандартных отклонений коэффициентов является завышенность t -статистик.

Автокорреляция имеет несколько негативных моментов. Данное явление прежде всего снижает качество эконометрической модели. В некоторых случаях характеристики полученного уравнения регрессии будут завышенными, следовательно, использование таких эконометрических моделей для анализа и прогнозирования экономики даст искаженные результаты.

Методы определения автокорреляции могут быть использованы только после расчета параметров эконометрической модели и отклонений e_i .

Способы выявления автокорреляции первого порядка:

- 1) визуальный (графический);
- 2) с использованием теста серий Вальда – Вольфовица;

3) с использованием статистики Дарбина – Уотсона.

Графический метод. Существует несколько вариантов графического определения автокорреляции. Один из них, указывающий отклонения с моментами t их получения (их порядковыми номерами i), приведен на рис. 4.21. Это так называемые последовательно-временные графики. В этом случае по оси абсцисс обычно откладывают либо время (момент) получения статистических данных, либо порядковый номер наблюдения, а по оси ординат – отклонения (либо оценки отклонений).




Рис. 4.21. Варианты графического определения автокорреляции

Тест серий Вальда – Вольфовица (Wald – Wolfowitz runs test). Серия остатков – набор последовательных остатков одного знака. Если в графике остатков есть длинные серии положительных остатков или длинные серии отрицательных остатков, т.е. число серий мало, то имеет место положительная автокорреляция. Если в графике остатков знаки остатков часто меняются, т.е. число серий велико, то имеет место отрицательная автокорреляция.

По этому методу последовательно определяются знаки отклонений $e_t = y_t - \hat{y}_t$, $t = \overline{1, n}$. Непрерывная последовательность одинаковых знаков называется рядом. Количество знаков в ряду называется длиной ряда. Визуальное распределение знаков свидетельствует о неслучайном характере связей между отклонениями. Если рядов слишком мало по сравнению с количеством наблюдений n , то вполне вероятна положительная автокорреляция. Если же рядов слишком много, то вероятна отрицательная автокорреляция. Для более детального анализа предлагается следующая процедура. Пусть n – объём выборки; n_1 – общее количество знаков «+» при n наблюдениях (количество положительных отклонений);

n_2 – общее количество знаков «–» при n наблюдениях (количество отрицательных отклонений); K – количество рядов. При достаточно большом количестве наблюдений ($n_1 > 10, n_2 > 10$) и отсутствии автокорреляции случайная величина K имеет асимптотически нормальное распределение

$$K \sim N \left(\frac{2n_1n_2}{n_1 + n_2} + 1; \frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)} \right),$$

т.е.

$$M(K) = \frac{2n_1n_2}{n_1 + n_2} + 1, \quad D(K) = \frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)}. \quad (4.44)$$

Тогда, если $M(K) - u_{\alpha/2} \cdot D(K) < K < M(K) + u_{\alpha/2} \cdot D(K)$, то гипотеза об отсутствии автокорреляции не отклоняется. Если $K \leq M(K) - u_{\alpha/2} \cdot D(K)$, то констатируется положительная автокорреляция; в случае $K \geq M(K) + u_{\alpha/2} \cdot D(K)$ признается наличие отрицательной автокорреляции.

Для небольшого числа наблюдений ($n_1 < 20, n_2 < 20$) Ф. Свед и С. Эйзенхарт разработали таблицы критических значений количества рядов при n наблюдениях (прил. 6). Суть таблиц в следующем.

На пересечении строки n_1 и столбца n_2 определяются нижнее K_1 и верхнее K_2 значения при уровне значимости $\alpha = 0,05$.

Если $K_1 < K < K_2$, то говорят об отсутствии автокорреляции. Если $K \leq K_1$, то говорят о положительной автокорреляции остатков. Если $K \geq K_2$, то говорят об отрицательной автокорреляции остатков.

Пример. Последовательно определены знаки отклонений

$$(- - - - -)(+ + + + +)(- - -)(+ + + +)(-),$$

т.е. 5 «–», 7 «+», 3 «–», 4 «+», 1 «–» при 20 наблюдениях. В нашем примере $n = 20, n_1 = 11, n_2 = 9, K = 5$. По таблицам прил. 6 определяем $K_1 = 6, K_2 = 16$. Поскольку $K = 5 < 6 = K_1$, то принимается предположение о наличии положительной автокорреляции при уровне значимости $\alpha = 0,05$.

Критерий Дарбина – Уотсона (Durbin – Watson test). Это наиболее известный критерий обнаружения автокорреляции первого порядка. Статистика Дарбина – Уотсона (DW) приводится во всех специальных компьютерных программах как одна из важнейших характеристик качества регрессионной модели.

По построенному эмпирическому уравнению регрессии определяются значения отклонений e_t . Статистика Дарбина – Уотсона рассчитывается по формуле:

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}. \quad (4.45)$$

При проверке отсутствия автокорреляции случайных отклонений моделей с помощью статистики Дарбина – Уотсона согласно общей схеме проверки гипотез формулируют:

- 1) гипотезу H_0 об отсутствии автокорреляции остатков;
- 2) гипотезы H_1 и H_1^* о наличии положительной или отрицательной автокорреляции в остатках.

По таблице критических точек Дарбина – Уотсона (прил. 5) определяются два числа d_l и d_u для заданного числа наблюдений n , числа факторов модели m и уровня значимости α . Этими значениями числовой промежуток $[0; 4]$ разбивается на пять интервалов (рис. 4.22)

Есть положительная автокорреляция остатков. H_0 отклоняется	Зона неопределенности	Нет оснований отклонять H_0 (автокорреляция остатков отсутствует)	Зона неопределенности	Есть отрицательная автокорреляция остатков. H_0 отклоняется.
0	d_l	d_u	$4 - d_u$	$4 - d_l$
		2		4

Рис. 4.22 Алгоритм проверки гипотезы о наличии автокорреляции остатков

Выдвинутые гипотезы принимаются или отклоняются в зависимости от того, в какой интервал попадет значение критерия DW :

$0 \leq DW \leq d_l$ – положительная автокорреляция;

$d_l < DW < d_u$ – зона неопределенности;

$d_u \leq DW \leq 4 - d_u$ – автокорреляция отсутствует;

$4 - d_u < DW < 4 - d_l$ – зона неопределенности;

$4 - d_l \leq DW \leq 4$ – отрицательная автокорреляция.

Зоны неопределенности возникают в связи с тем, что распределение статистики Дарбина – Уотсона зависит не только от n и m , но также от значений объясняющих переменных x_{ij} ($i = 1, \dots, n$, $j = 1, \dots, m$).

Можно показать, что статистика DW тесно связана с коэффициентом автокорреляции первого порядка:

$$r_{e_{t-1}e_t} = \frac{\sum_{t=2}^n e_{t-1}e_t}{\sqrt{\sum_{t=1}^{n-1} e_t^2 \sum_{t=2}^n e_{t-1}^2}}. \quad (4.46)$$

Связь выражается формулой

$$DW \approx 2(1 - r_{e_{t-1}e_t}). \quad (4.47)$$

Из формулы (4.47) вытекает смысл статистического анализа автокорреляции. Поскольку значения r изменяются от -1 до $+1$, DW изменяется от 0 до 4. Когда автокорреляция отсутствует, коэффициент автокорреляции равен нулю, и статистика DW равна 2; $DW = 0$ соответствует положительной автокорреляции, когда выражение в скобках равно нулю ($r = 1$). При отрицательной автокорреляции ($r = -1$) $DW = 4$, и выражение в скобках равно двум.

Ограничения критерия Дарбина – Уотсона

1. Критерий DW применяется лишь для тех моделей, которые содержат свободный член.
2. Предполагается, что случайные отклонения определяются по итерационной схеме (4.43).
3. Статистические данные должны иметь одинаковую периодичность (исключаются пропуски в наблюдениях).

В случае, когда значение DW -статистики попало в область неопределенности, можно использовать t -критерий для проверки значимости коэффициента корреляции $r_{e_t e_{t-1}}$

$$t_{\text{набл}} = \frac{|r_{e_t e_{t-1}}| \cdot \sqrt{n-2}}{\sqrt{1-r_{e_t e_{t-1}}^2}}$$

сравнивается с $t_{\text{кр}}(\alpha, n-2)$. Если $|t_{\text{набл}}| > t_{\text{кр}}(\alpha, n-2)$, то гипотеза H_0 об отсутствии автокорреляции остатков отклоняется.

4.6.2. Устранение автокорреляции случайных составляющих

Свойства случайных отклонений, в том числе и автокорреляция, в первую очередь зависят от выбора математической модели уравнения регрессии и состава объясняющих переменных. Чаще всего автокорреляция вызывается неправильной спецификацией модели, поэтому необходимо прежде всего скорректировать саму модель. Если все разумные процедуры изменения спецификации модели исчерпаны, а автокорреляция имеет место, то можно предположить, что она обусловлена какими-то внутренними свойствами ряда остатков $\{e_t\}$. В этом случае можно воспользоваться авторегрессионным преобразованием. Обычно наиболее целесообразным и простым преобразованием является *авторегрессионная схема первого порядка AR(1)*. Рассмотрим AR(1) на примере парной регрессии

$$y = a + bx + e,$$

тогда наблюдениям t и $(t-1)$ соответствуют формулы

$$y_t = a + bx_t + e_t, \quad (4.48)$$

$$y_{t-1} = a + bx_{t-1} + e_{t-1}. \quad (4.49)$$

Пусть случайные отклонения подвержены воздействию авторегрессии первого порядка

$$e_t = \rho e_{t-1} + v_t.$$

Вычтем из равенства (4.48) соотношение (4.49), умноженное на ρ :

$$y_t - \rho y_{t-1} = a(1-\rho) + b(x_t - \rho x_{t-1}) + (e_t - \rho e_{t-1}).$$

Сделаем замену переменных

$$y_t^* = y_t - \rho y_{t-1}; \quad x_t^* = x_t - \rho x_{t-1}; \quad a^* = a(1 - \rho).$$

Получим

$$y_t^* = a^* + bx_t^* + v_t.$$

Поскольку случайные отклонения v_t удовлетворяют предпосылкам МНК, оценки a^* и b будут обладать свойствами наилучших линейных несмещенных оценок. По преобразованным значениям всех переменных с помощью обычного МНК вычисляются оценки параметров a^* и b , а затем находят коэффициенты исходной регрессии.

Однако данный способ вычисления преобразованных переменных приводит к потере первого наблюдения, если нет информации о предшествующих наблюдениях. Это уменьшает на единицу число степеней свободы, что при больших выборках не очень существенно, однако при малых выборках приводит к потере эффективности. Проблема потери первого наблюдения преодолевается с помощью поправки Прайса – Винстена

$$x_1^* = \sqrt{1 - \rho^2} \cdot x_1,$$

$$y_1^* = \sqrt{1 - \rho^2} \cdot y_1.$$

Рассмотренное авторегрессионное преобразование может быть обобщено на:

- 1) произвольное число объясняющих переменных;
- 2) преобразования более высоких порядков AR(2), AR(3) и т.д.

Однако на практике значения коэффициента автокорреляции ρ обычно неизвестны и их необходимо оценить. Существует несколько методов оценивания:

- 1) на основе статистики Дарбина – Уотсона;
- 2) метод Кохрана – Оркатта;
- 3) метод Хилдрета – Лу;
- 4) метод первых разностей.

Для преобразования AR(1) важно оценить коэффициент автокорреляции ρ . Это делается несколькими способами. Самое простое – оценить ρ на основе статистики DW

$$\begin{cases} DW \approx 2(1 - r_{e_{t-1}e_t}) \\ \rho = r_{e_{t-1}e_t} \end{cases} \Rightarrow \rho \approx 1 - \frac{DW}{2}, \quad (4.50)$$

Этот метод хорошо работает при большом числе наблюдений.

Итеративная процедура Кохрана – Оркатта (на примере парной регрессии) состоит из нескольких этапов.

1. Определение уравнения регрессии и вектора остатков

$$\hat{y} = b_0 + b_1 x \Rightarrow b_0, b_1, e_i, i = \overline{1, n}. \quad (4.51)$$

2. В качестве приближенного значения ρ берется его МНК-оценка $e_t = \rho^* e_{t-1} + v_t$.

3. Для найденного ρ^* оцениваются коэффициенты α_0, α_1 :

$$y_t - \rho^* y_{t-1} = \alpha_0 (1 - \rho^*) + \alpha_1 (x_t - \rho^* x_{t-1}) + (e_t - \rho^* e_{t-1}) + \eta_t.$$

4. Подставляем $b_0 = \alpha_0 (1 - \rho^*)$, $b_1 = \alpha_1$ в (4.51) и вычисляем

$$e_i, i = \overline{1, n}.$$

5. Возвращаемся к этапу 2.

Критерий остановки: разность между текущей и предыдущей оценками ρ^* стала меньше заданной точности.

Итеративная процедура Хилдрета – Лу (на примере парной регрессии) включает 3 этапа.

1. Определяем уравнение регрессии и вектор остатков

$$\hat{y} = b_0 + b_1 x \Rightarrow b_0, b_1, e_i, i = \overline{1, n}.$$

2. Оцениваем регрессию

$$y_t - \rho^* y_{t-1} = \alpha_0 (1 - \rho^*) + \alpha_1 (x_t - \rho^* x_{t-1}) + (e_t - \rho^* e_{t-1}) + \eta_t$$

для каждого возможного значения $\rho \in [-1; 1]$ с некоторым достаточно малым шагом, например 0,001; 0,01 и т.д.

3. Величина ρ^* , обеспечивающая минимум стандартной ошибки регрессии, принимается в качестве оценки автокорреляции остатков.

Подведем итоги по итеративным процедурам оценивания коэффициента ρ :

- сходимость процедур достаточно хорошая;
- метод Кохрана – Оркатта может попасть в локальный (а не глобальный) минимум;
- время работы процедуры Хилдрета – Лу значительно сокращается при наличии априорной информации об области возможных значений ρ .

Обобщенный метод наименьших квадратов (на примере парной регрессии):

$$\begin{aligned}y_t &= \beta_0 + \beta_1 x_t + e_t \Rightarrow y_t = \beta_0 + \beta_1 x_t + \rho e_{t-1} + v_t \\e_t &= \rho e_{t-1} + v_t \\y_{t-1} &= \beta_0 + \beta_1 x_{t-1} + e_{t-1} \Rightarrow \rho y_{t-1} = \rho \beta_0 + \rho \beta_1 x_{t-1} + \rho e_{t-1}.\end{aligned}$$

Составим разность из полученных уравнений

$$y_t - \rho y_{t-1} = \beta_0 (1 - \rho) + \beta_1 (x_t - \rho x_{t-1}) + \eta_t,$$

тогда

$$y_t = \beta_0 (1 - \rho) + \beta_1 x_t - \rho \beta_1 x_{t-1} + \rho y_{t-1} + \eta_t.$$

Обобщенный МНК представляет собой традиционный МНК с нелинейными ограничениями типа равенств

$$\begin{aligned}y_t &= \beta_0^* + \beta_1^* x_t + \beta_2^* x_{t-1} + \rho y_{t-1} + \eta_t \\ \beta_0^* &= \beta_0 (1 - \rho); \quad \beta_2^* = -\rho \beta_1^*.\end{aligned}$$

Способы решения:

- 1) решать задачу нелинейного программирования;
- 2) двухшаговый МНК Дарбина;
- 3) итеративная процедура расчета.

*Итеративная процедура обобщенного метода
наименьших квадратов*

1. Считается регрессия и находятся остатки.
2. По остаткам находят оценку коэффициента автокорреляции остатков.

3. Оценка коэффициента автокорреляции используется для пересчета данных, и цикл повторяется.

Процесс останавливается, как только обеспечивается достаточная точность (результаты перестают существенно улучшаться).

Не следует применять обобщенный МНК автоматически, поскольку:

- значимый коэффициент DW может указывать просто на ошибочную спецификацию;
- последствия автокорреляции остатков иногда бывают незначительными;
- качество оценок может снизиться из-за уменьшения числа степеней свободы (нужно оценивать дополнительный параметр);
- значительно возрастает трудоемкость расчетов.

4.6.3. Примеры решения типовых задач

Пример 4.9. Определить наличие автокорреляции по данным, приведенным в табл. 4.15, и устранить автокорреляцию, используя модель парной линейной регрессии и авторегрессионную схему первого порядка $AR(1)$ (определение ρ произвести на основе статистики Дарбина – Уотсона).

Таблица 4.15

i	1	2	3	4	5	6	7	8	9	10	11	12	13
X	2,3	3,3	2,4	2,9	2,5	3,1	3,3	2,3	2,5	2,3	2,9	2,5	2,9
Y	2,5	2,1	2,8	2,8	2,9	2,8	2,1	3,6	1,9	2,9	2,1	3,2	2,1
i	14	15	16	17	18	19	20	21	22	23	24	25	
X	2,8	2,3	3	2,8	2,3	3,3	2,8	3,1	3,2	3	2,3	2,3	
Y	2,8	2,1	2,5	2,5	3,4	1,9	2,6	2,4	2,1	2,3	3,1	3	

По МНК находим уравнение регрессии $\hat{y} = 4,73 - 0,79 \cdot x$. Построим график остатков от номера наблюдения (рис. 4.23).




Рис. 4.23. График остатков от номера наблюдения

Проведем проверку по методу серий. Подсчитываем количество знаков «плюс», «минус», $n = 25$, $n_1 = 12$, $n_2 = 13$ и число рядов $K = 18$. Для $\alpha = 0,05$ из статистических таблиц находим $K_1 = 8$ и $K_2 = 19$. Так как значение K попадает в промежуток $8 < K = 18 < 19$, автокорреляция по методу рядов не обнаружена.

Теперь проведем проверку по критерию Дарбина – Уотсона. Рассчитаем вспомогательные суммы и найдем значение

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} = \frac{9,55}{3,44} = 2,77.$$

Для $n = 25$, $m = 1$ (число объясняющих параметров), $\alpha = 0,05$ по статистическим таблицам Дарбина – Уотсона (прил. 5) находим $d_l = 1,29$ и $d_u = 1,45$. Так как $DW > 4 - d_l$, это свидетельствует об отрицательной автокорреляции остатков.

Устранение автокорреляции. Используем авторегрессионную схему первого порядка $AR(1)$. Вместо переменных x , y рассмотрим новые переменные x^* и y^* , значения которых вычисляются по правилу

$$\left\{ \begin{array}{l} x_1^* = \sqrt{1-\rho^2} \cdot x_1, \\ y_1^* = \sqrt{1-\rho^2} \cdot y_1, \\ x_i^* = x_i - \rho x_{i-1}, \quad i = 2, \dots, n, \\ y_i^* = y_i - \rho y_{i-1}, \quad i = 2, \dots, n, \\ \rho \approx 1 - DW / 2. \end{array} \right.$$

Результаты вычислений приведены в табл. 4.16.

Таблица 4.16

i	x	y	$\hat{y}$	e_i	$e_i - e_{i-1}$	x^*	y^*
1	2,3	2,5	2,9	-0,405	—	2,1	2,3
2	3,3	2,1	2,1	-0,023	0,4	4,2	3,1
3	2,4	2,8	2,9	-0,058	0,0	3,6	3,6
4	2,9	2,8	2,5	0,327	0,4	3,8	3,9
5	2,5	2,9	2,7	0,139	-0,2	3,6	3,9
6	3,1	2,8	2,2	0,551	0,4	4,1	3,9
7	3,3	2,1	2,2	-0,055	-0,6	4,5	3,2
8	2,3	3,6	2,9	0,725	0,8	3,6	4,4
9	2,5	1,9	2,8	-0,857	-1,6	3,4	3,3
10	2,3	2,9	2,9	0,001	0,9	3,2	3,7
11	2,9	2,1	2,5	-0,345	-0,3	3,8	3,2
12	2,5	3,2	2,8	0,453	0,8	3,6	4,1
13	2,9	2,1	2,4	-0,349	-0,8	3,9	3,3
14	2,8	2,8	2,6	0,213	0,6	3,9	3,6
15	2,3	2,1	2,9	-0,821	-1,0	3,4	3,2
16	3,0	2,5	2,4	0,172	1,0	3,9	3,4
17	2,8	2,5	2,5	-0,018	-0,2	4,0	3,5
18	2,3	3,4	2,9	0,509	0,5	3,4	4,4
19	3,3	1,9	2,1	-0,209	-0,7	4,2	3,3
20	2,8	2,6	2,5	0,094	0,3	4,1	3,3
21	3,1	2,4	2,3	0,097	0,0	4,2	3,4
22	3,2	2,1	2,2	-0,116	-0,2	4,4	3,0
23	3,0	2,3	2,4	-0,126	0,0	4,2	3,1
24	2,3	3,1	2,9	0,171	0,3	3,4	4,0
25	2,3	3,0	2,9	0,079	-0,1	3,2	4,2
СумМКВ				3,44	9,54		

Итак $a^* = a(1 - \rho)$. Коэффициент

$$\rho \approx 1 - \frac{DW}{2} = 1 - \frac{2,77}{2} = -0,385.$$

С помощью обычного МНК по переменным x^* и y^* оцениваем коэффициенты уравнения $y_t^* = a^* + bx_t^*$. Далее находим

$$a = \frac{a^*}{(1 - \rho)}.$$

Определенные по МНК значения $b = -0,02$; $a^* = 3,61$, тогда $a = \frac{3,61}{(1 - (-0,385))} = 2,60$. Полученное уравнение регрессии

$y = 2,6 - 0,02x$ (сравните с первоначальным уравнением регрессии $\hat{y} = 4,73 - 0,79 \cdot x$).

Проверка нового уравнения регрессии по методу Дарбина – Уотсона показала $DW = 1,59$. Это свидетельствует об устранении автокорреляции остатков первого порядка.

Контрольные вопросы

1. Для какого типа моделей наиболее характерно свойство автокорреляции? Почему?
2. Какой вид имеют типовые графики зависимостей остатков регрессии, для которых характерна положительная и отрицательная автокорреляция (первого порядка).
3. Что можно предпринять для уменьшения автокорреляции?
4. Что такое автокорреляционная функция остатков? Как определяется выборочный коэффициент автокорреляции первого порядка?
5. Что характерно для случайного регрессионного процесса первого порядка. Какие параметры необходимо знать для задания процесса?
6. В чем специфика обобщенного метода наименьших квадратов по сравнению с МНК? Что необходимо знать для применения ОМНК?

7. Как определяется вектор оптимальных ОМНК оценок параметров модели линейной регрессии? При выполнении каких свойств ошибок ОМНК оценки параметров модели превращаются в МНК-оценки?

8. В чем суть итерационной процедуры Кохрейна – Оркотта определения параметра регрессионного процесса первого порядка?

9. Какие параметры используются при проверке гипотезы о наличии автокорреляции методом Дарбина – Уотсона?

10. Как провести процедуру тестирования Дарбина – Уотсона на наличие автокорреляции в модели линейной регрессии.

4.7. СПЕЦИФИКАЦИЯ МОДЕЛИ

Многообразие и сложность экономических процессов определяют многообразие моделей, используемых для экономического анализа. Стандартная схема анализа зависимостей состоит в осуществлении ряда последовательных процедур, таких как:

- подбор начальной модели, осуществляется на основе экономической теории, предыдущих знаний об объекте исследования и его интуиции;
- оценка параметров модели на основе имеющихся статистических данных;
- проведение тестов проверки качества модели;
- при наличии хотя бы одного неудовлетворительного ответа по какому-либо тесту совершенствование с целью устранения выявленного недостатка модели.

При положительных ответах по всем проведенным тестам модель считается качественной.

Тогда она может быть использована для анализа и прогноза объясняемой переменной.

Качество модели зависит и от соблюдения требований, которым должен удовлетворять ряд остатков:

- 1) *математическое ожидание остатков равно нулю*; для проверки этого свойства вычисляют t -критерий:

$$t = \frac{|\bar{e}| - 0}{s_e} \cdot \sqrt{n},$$

где s_e – стандартная ошибка; если $|t_{набл}| > t_{кр}(\alpha, n - 2)$, то модель не адекватна;

2) *дисперсии уровней ряда должны быть одинаковы (гомоскедастичность)*; для проверки этого свойства можно применить тесты Спирмена, Голдфельда – Квандта, Гдейзера;

3) *независимость последовательности остатков (отсутствие автокорреляции)*; для проверки этого свойства можно применить критерии Дарбина – Уотсона и метод рядов;

4) *случайность*; для проверки этого свойства можно использовать критерий поворотных точек (точки локального экстремума); точка считается поворотной, если выполняются следующие условия: $e_{i-1} < e_i > e_{i+1}$ или $e_{i-1} > e_i < e_{i+1}$; далее подсчитывается число поворотных точек p . Если выполняется неравенство $p > p_{кр}$, то модель считается адекватной, где

$$p_{кр} = \left[\frac{2}{3}(n - 2) - 1,96 \sqrt{\frac{16n - 29}{90}} \right];$$

5) *остаточная последовательность распределена по нормальному закону*; проверку можно осуществить с помощью

RS-критерия: $RS = \frac{R}{s_e}$, где $R = e_{max} - e_{min}$ – вариация остатков,

$s_e = \sqrt{\frac{\sum e_i^2}{n - 1}}$ – стандартное отклонение; по таблице (прил. 7)

на заданном уровне значимости α находят $RS_{ниж}$ и $RS_{верх}$; если $RS_{ниж} < RS_{наб} < RS_{верх}$, то гипотеза о нормальности принимается, в противном случае отклоняется.

Правильный выбор вида экономической модели – отправная точка для качественного ее анализа. Однако не следует абсолютизировать полученный результат, поскольку даже качественная модель является подгонкой спецификации модели под имеющийся набор данных. Исследователь должен помнить, что совершенных

моделей не существует. Иногда хорошие с точки зрения диагностических тестов модели обладают весьма низкими прогнозными качествами. В силу постоянно изменяющихся условий протекания экономических процессов не может быть и постоянно качественных моделей.

4.8. ПРОЦЕДУРЫ ПОШАГОВОГО ПОСТРОЕНИЯ МОДЕЛЕЙ

В последовательных процедурах построения эконометрической модели одновременно подбираются объясняющие переменные и оцениваются параметры. При выполнении процедур окончательная форма модели достигается путем поэтапного улучшения предыдущих версий.

Последовательные процедуры построения модели можно подразделить на две группы: процедуры исключения и процедуры селекции. В процедурах исключения в качестве исходной точки рассматривается наиболее универсальная модель, содержащая все потенциальные объясняющие переменные. На очередных шагах количество объясняющих переменных уменьшается вплоть до получения такой версии модели, которая соответствует заданным критериям. Такие процедуры еще называют «сверху вниз».

Цель процедур селекции заключается в построении модели, обладающей необходимыми свойствами, путем продвижения в направлении, обратном процедуре исключения. На первом этапе конструируется модель с одной объясняющей переменной, а на последующих этапах в модель вводятся очередные объясняющие переменные вплоть до получения удовлетворительной версии модели. Такие процедуры называются «снизу вверх».

Важно понимать, что ни одна из пошаговых процедур не гарантирует получения оптимального набора регрессоров по какому-либо критерию.

Рассмотрим *процедуру исключения апостериори*.

На первом шаге строится модель, содержащая все объясняющие переменные:

$$y_t = \alpha_0 + \alpha_1 x_{t1} + \alpha_2 x_{t2} + \dots + \alpha_p x_{tp} + \varepsilon_t.$$

Для каждой потенциальной объясняющей переменной рассчитывается значение t -статистики

$$t_{\text{набл}}(i) = \frac{a_i}{S(a_i)}, \quad i = \overline{0, p}.$$

В множестве $\{t_{\text{набл}}(i), i = \overline{0, p}\}$ выбирают наименьший элемент $t_{\text{набл}}(j)$ и сравнивают с критическим значением $t_{\text{кр}}(\alpha; n - p - 1)$. Если $t_{\text{набл}}(j) < t_{\text{кр}}$, то следует исключить из модели потенциальную объясняющую переменную x_j и затем повторно оценить модель со всеми оставшимися потенциальными объясняющими переменными. Процедура продолжается до тех пор, пока минимальное значение из рассчитанных t -статистик не становится больше соответствующего критического значения t -статистики.

Данная процедура исключает из модели не только несущественные, но и мультиколлинеарные переменные. Оценки моделей с мультиколлинеарными факторами могут иметь неправильные с точки зрения теории знаки, поэтому важно проверить последнюю оцененную модель на свойство коинциденции, т.е. на выполнение условия $\text{sign } a_i = \text{sign } r(y, x_i)$.

Все переменные, для которых это условие не выполняется, необходимо удалить из уравнения. Может оказаться опять, что наименьшее значение из рассчитанных t -статистик становится меньше критического. В этом случае процедуру пошагового исключения необходимо продолжить.

Теперь остановимся на *процедуре пошаговой селекции*.

Шаг 1 – вычисляются коэффициенты корреляции $r(y, x_i)$ между эндогенной переменной y и потенциальными экзогенными переменными $x_1, x_2, \dots, x_p$.

Выбирается переменная x_j , для которой коэффициент корреляции наибольший по модулю, и строится модель

$$y_t = \alpha_0 + \alpha_j x_{tj} + \varepsilon_t, \quad (4.52)$$

а также вспомогательные модели

$$x_{ti} = \beta_0 + \beta_j x_{tj} + \delta_t.$$

Эти модели оцениваются МНК и находятся остатки моделей

$$e_t = y_t - a_0 - a_j x_{tj} \text{ и } \tilde{e}_{ti} = x_{ti} - b_0 - b_j x_{tj}. \quad (4.53)$$

Шаг 2 – рассчитываются коэффициенты корреляции между e_t и $\tilde{e}_{ti}$, или, что то же самое, частные коэффициенты корреляции между переменными y и x_i , исключая влияние x_j . Среди найденных коэффициентов находится наибольший по модулю

$$|r(yx_{tk}|x_{tj})| = \max \{|r(e_t, \tilde{e}_{ti})|\}, \quad i = 1, 2, \dots, p, \text{ и } i \neq j. \quad (4.54)$$

Переменная x_k вводится в модель (7.1), в результате чего формируется новая модель

$$y_t = \alpha_0 + \alpha_j x_{tj} + \alpha_k x_{tk} + \varepsilon_t. \quad (4.55)$$

При оценке параметров модели (4.55) возможны следующие ситуации:

а) коэффициенты при переменных статистически незначимы; тогда факторы x_j и x_k исключают из рассмотрения и переходят к первому шагу нахождения наибольшего коэффициента корреляции;

б) один из двух коэффициентов при переменных статистически незначим; тогда соответствующую переменную исключают из рассмотрения и переходят к шагу 2 (нахождение наибольшего частного коэффициента корреляции);

в) оба коэффициента статистически значимы; тогда находят новые частные коэффициенты между переменными y и x_i , исключая влияние x_j и x_k , определяют наибольшее значение и составляют модель уже с тремя факторами.

Процесс продолжается до момента, когда ни одну потенциальную экзогенную переменную нельзя будет ни ввести в модель, ни исключить из нее.

Примеры решения задач

Пример 4.10. В табл. 4.17 представлены данные по 15 странам мира: качество жизни y (баллы), ВВП на душу населения x_1 (тыс. дол.), личное конечное потребление на душу населения x_2 (тыс. дол.), уровень инфляции x_3 (%), средняя продолжительность

жизни x_4 (лет), индекс человеческого развития x_5 (в долях от 1), доля доходов у 20% богатых x_6 (%), доля неграмотных x_7 (%).

При уровне значимости $\alpha = 0,05$ построить линейную модель с применением процедуры исключения апостериори.

Решение. Модель, содержащая все потенциальные экзогенные переменные и построенная с применением МНК, имеет вид

$$\hat{y} = 35,54 + 0,06x_1 - 0,01x_2 - 0,03x_3 - 0,58x_4 + 22,25x_5 - 0,11x_6 - 0,06x_7.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.18. Значение критической t -статистики Стьюдента для уровня значимости 0,05 и степеней свободы 7 равно $t_{кр}(0,05; 7) = 2,36$.

Таблица 4.17

Страна	y	x_1	x_2	x_3	x_4	x_5	x_6	x_7
Австрия	9,17	20,46	15,99	2,3	76,2	0,925	38,0	2,0
Англия	6,85	17,92	11,98	3,3	76,2	0,916	44,3	1,0
Бразилия	4,30	5,74	2,15	73,8	66,3	0,804	67,5	16,7
Германия	8,64	19,94	16,71	2,0	76,0	0,921	40,3	1,0
Голландия	8,37	18,07	15,17	2,0	77,4	0,936	36,9	2,0
Испания	7,82	14,29	8,73	4,7	77,6	0,930	36,6	5,0
Италия	6,80	18,90	11,57	5,4	77,5	0,912	41,0	3,0
Канада	9,06	22,32	11,51	2,4	77,4	0,950	40,2	2,0
Китай	2,51	2,52	0,22	17,1	68,5	0,594	41,8	26,7
Норвегия	9,28	21,61	16,44	2,5	76,9	0,932	36,7	0,0
Россия	0,82	5,26	1,03	231,0	67,6	0,849	65,3	2,0
США	7,89	26,65	18,79	2,9	76,0	0,937	41,9	0,5
Франция	8,00	19,98	15,74	1,9	76,9	0,930	41,9	1,0
Швейцария	9,00	23,48	25,20	1,8	78,0	0,925	44,8	0,0
Япония	5,43	21,62	24,70	0,0	79,5	0,937	37,5	0,0

Поскольку $\min\{|t_1|, |t_2|, \dots, |t_7|\} = |t_2| = 0,10 < t_{кр}$, переменную x_2 следует исключить из модели.

Можно рассмотреть p -значение и найти максимальное значение $\max\{p_1, p_2, \dots, p_7\} = p_2 = 0,92 > 0,05$ (аналогично, это переменная x_2).

Таблица 4.18

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	35,54	32,64	1,09	0,31
x_1	0,06	0,18	0,35	0,73
x_2	-0,01	0,11	-0,10	0,92
x_3	-0,03	0,02	-1,55	0,17
x_4	-0,58	0,40	-1,44	0,19
x_5	22,25	16,11	1,38	0,21
x_6	-0,11	0,11	-1,03	0,34
x_7	-0,06	0,26	-0,23	0,82

После повторного оценивания модели без переменной x_2 получаем данные, отраженные в табл. 4.19.

Таблица 4.19

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	36,25	29,84	1,21	0,26
x_1	0,05	0,15	0,37	0,72
x_3	-0,03	0,02	-1,66	0,14
x_4	-0,60	0,34	-1,74	0,12
x_5	23,07	13,04	1,77	0,11
x_6	-0,12	0,09	-1,30	0,23
x_7	-0,05	0,23	-0,23	0,83

Значение критической t -статистики Стьюдента для уровня значимости 0,05 и степеней свободы 8 равно $t_{кр}(0,05;8) = 2,3$. Поскольку $\min\{|t_1|, |t_3|, \dots, |t_7|\} = |t_7| = 0,23 < t_{кр}$, переменную x_7 следует исключить из модели.

В результате оценивания модели без переменной x_7 получаем данные приведенные в табл. 4.20.

Значение критической t -статистики Стьюдента для уровня значимости 0,05 и степеней свободы 9 равно $t_{кр}(0,05;9) = 2,26$.

Поскольку $\min\{|t_1|, |t_3|, \dots, |t_6|\} = |t_1| = 0,75 < t_{кр}$, переменную x_1 следует исключить из модели.

Таблица 4.20

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	31,44	19,74	1,59	0,15
x_1	0,08	0,10	0,75	0,47
x_3	-0,03	0,01	-3,00	0,01
x_4	-0,56	0,29	-1,92	0,09
x_5	25,11	8,88	2,83	0,02
x_6	-0,12	0,08	-1,42	0,19

В результате оценивания модели без переменной x_1 получаем данные (табл. 4.21).

Значение критической t -статистики Стьюдента для уровня значимости 0,05 и степеней свободы 10 равно $t_{кр}(0,05;10) = 2,23$. Поскольку $\min\{|t_3|, \dots, |t_6|\} = |t_6| = 1,42 < t_{кр}$, переменную x_6 следует исключить из модели.

Таблица 4.21

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	26,83	18,33	1,46	0,174
x_3	-0,03	0,01	-3,70	0,004
x_4	-0,52	0,28	-1,85	0,094
x_5	28,24	7,66	3,69	0,004
x_6	-0,12	0,08	-1,42	0,186

В результате оценивания модели без переменной x_6 получаем данные (табл. 4.22).

Значение критической t -статистики Стьюдента для уровня значимости 0,05 и степеней свободы 11 равно $t_{кр}(0,05; 11) = 2,20$. Поскольку $\min\{|t_3|, |t_4|, |t_5|\} = |t_4| = 1,14 < t_{кр}$, переменную x_4 следует исключить из модели.

Таблица 4.22

Переменные	Коэффициенты	Стандартная ошибка	<i>t</i> -статистика	<i>p</i> -значение
<i>y</i>	4,57	9,91	0,46	0,654
<i>x</i> ₃	−0,03	0,01	−3,99	0,002
<i>x</i> ₄	−0,21	0,18	−1,14	0,279
<i>x</i> ₅	21,20	6,10	3,48	0,005

В результате оценивания модели без переменной *x*₄ получаем данные (табл. 4.23).

Таблица 4.23

Переменные	Коэффициенты	Стандартная ошибка	<i>t</i> -статистика	<i>p</i> -значение
<i>y</i>	4,57	9,91	0,46	0,654
<i>x</i> ₃	−0,03	0,01	−3,99	0,002
<i>x</i> ₅	21,20	6,10	3,48	0,005

Значение критической *t*-статистики Стьюдента для уровня значимости 0,05 и степеней свободы 11 равно $t_{кр}(0,05;11) = 2,20$. Поскольку значения t_3 и t_5 превышают значение $t_{кр}$, экзогенные переменные *x*₃ и *x*₅ остаются в модели.

Получаем следующее уравнение

$$\hat{y} = 4,57 - 0,03x_3 + 21,20x_5.$$

Таким образом, получили окончательную версию модели: уровень качества жизни зависит от уровня инфляции и индекса человеческого развития.

Пример 4.11. По данным примера 4.10 построить линейную модель, используя процедуру пошаговой селекции ($\alpha = 0,05$).

Решение. Найдем матрицу корреляций R_0 эндогенной переменной *y* с экзогенными переменными *x*_{*i*}.

Коэффициент	<i>x</i> ₁	<i>x</i> ₂	<i>x</i> ₃	<i>x</i> ₄	<i>x</i> ₅	<i>x</i> ₆	<i>x</i> ₇
$R_0^T =$	0,84	0,70	−0,76	0,80	0,71	−0,68	−0,58

Поскольку переменная *x*₁ сильнее всего коррелирована с переменной *y*, она принимается в качестве первой объясняющей

переменной. После оценивания параметров парной (4.52) регрессии модель приобретает вид

$$\hat{y} = 1,72 + 0,3x_1.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.24.

Таблица 4.24

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	1,72	1,00	1,71	0,11104
x_1	0,30	0,05	5,59	0,00009

Далее оцениванием вспомогательные модели переменных x_i ($i = 2, 3, \dots, 7$) на переменную x_1 и получаем

$$\hat{x}_2 = -3,28 + 0,95x_1; \quad \hat{x}_3 = 114,2 - 5,25x_1;$$

$$\hat{x}_4 = 66,50 + 0,50x_1; \quad \hat{x}_5 = 0,71 + 0,01x_1;$$

$$\hat{x}_6 = 58,25 - 0,85x_1; \quad \hat{x}_7 = 18,30 - 0,82x_1.$$

После этого рассчитываем значения рядов остатков по формуле (4.53) (табл. 4.25).

Таблица 4.25

t	e	e_2	e_3	e_4	e_5	e_6	e_7
1	1,27	-0,114	-4,38	-0,62	-0,001	-2,93	0,43
2	-0,28	-1,716	-16,72	0,66	0,016	1,22	-2,65
3	0,85	-0,003	-10,23	-3,10	0,030	14,10	3,09
4	0,90	1,099	-7,41	-0,56	0,000	-1,07	-0,99
5	1,19	1,331	-17,23	1,79	0,034	-6,05	-1,52
6	1,79	-1,526	-34,40	3,89	0,067	-9,55	-1,61
7	-0,63	-3,055	-9,47	1,47	0,002	-1,25	0,16
8	0,60	-6,357	5,50	-0,35	0,004	0,85	1,95
9	0,03	1,119	-83,85	0,72	-0,147	-14,32	10,46
10	1,03	-0,754	1,87	-0,50	-0,006	-3,25	-0,63
11	-2,49	-0,668	144,45	-1,56	0,080	11,50	-12,00
12	-1,88	-3,180	28,75	-3,94	-0,054	6,21	3,99
13	0,25	0,091	-7,30	0,32	0,009	0,56	-0,96
14	0,19	6,234	10,99	-0,34	-0,033	6,43	0,90
15	-2,82	7,497	-0,58	2,10	-0,001	-2,45	-0,62

Коэффициенты корреляции между остатками, которые являются частными коэффициентами корреляции между переменными y и x_i ($i = 2, 3, \dots, 7$), исключая влияние x_1 , приведены в табл. 4.26.

Таблица 4.26

Коэффициент	e_2	e_3	e_4	e_5	e_6	e_7
$r(e, e_i) = r(yx_i x_1) =$	-0,22	-0,54	0,23	0,07	-0,36	0,26

Максимальное по модулю значение коэффициента корреляции соответствует $r(yx_3|x_1)$. Следовательно, следующей объясняющей переменной, включенной в модель, выбирается x_3 . Оцениваем регрессию переменной y на переменные x_1 и x_3 , модель приобретает вид

$$\hat{y} = 3,57 + 0,22x_1 - 0,02x_3.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.27.

Таблица 4.27

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	3,57	1,20	2,96	0,012
x_1	0,22	0,06	3,59	0,004
x_3	-0,02	0,01	-2,24	0,044

На уровне значимости $\alpha = 0,05$ проверяем гипотезу о существенности параметров этой модели. Табличное значение t -статистики Стьюдента при 12 степенях свободы равно $t_{кр}(0,05;12) = 2,18$. Поскольку наблюдаемые значения статистик выше критического значения (по модулю), параметры при переменных x_1 и x_3 признаются существенными.

Построим вспомогательные модели, описывающие зависимости переменных, которые не вошли в модель, от объясняющих переменных x_1 и x_3 . Эти модели имеют вид

$$\hat{x}_2 = -2,64 + 0,92x_1 - 0,006x_3;$$

$$\hat{x}_4 = 68,57 + 0,41x_1 - 0,020x_3;$$

$$\hat{x}_6 = 45,69 - 0,27x_1 + 0,110x_3;$$

$$\hat{x}_5 = 0,65 + 0,013x_1 + 0,0006x_3;$$

$$\hat{x}_7 = 27,05 - 1,220x_1 - 0,0770x_3.$$

Опять рассчитываем значения рядов остатков по формуле (4.53) (табл. 4.28).

Таблица 4.28

t	e	e_2	e_4	e_5	e_6	e_7
1	1,20	-0,14	-0,70	0,001	-2,45	0,10
2	-0,55	-1,81	0,36	0,026	3,06	-3,93
3	0,68	-0,06	-3,28	0,036	15,23	2,31
4	0,78	1,06	-0,69	0,004	-0,25	-1,56
5	0,91	1,23	1,48	0,045	-4,16	-2,84
6	1,23	-1,72	3,27	0,088	-5,77	-4,25
7	-0,78	-3,11	1,30	0,007	-0,21	-0,57
8	0,69	-6,33	-0,26	0,001	0,24	2,37
9	-1,33	0,65	-0,79	-0,097	-5,09	4,04
10	1,06	-0,74	-0,46	-0,007	-3,46	-0,48
11	-0,15	0,15	1,06	-0,006	-4,40	-0,94
12	-1,41	-3,02	-3,42	-0,071	3,05	6,20
13	0,13	0,05	0,19	0,013	1,37	-1,52
14	0,37	6,30	-0,14	-0,039	5,22	1,74
15	-2,83	7,49	2,09	-0,001	-2,38	-0,66

Коэффициенты корреляции между рядами остатков этих моделей и рядом остатков модели $\hat{y} = 3,57 + 0,22x_1 - 0,02x_3$ являются частными коэффициентами корреляции между переменными y и x_i ($i = 2, 4, 5, 6, 7$), исключая влияние x_1 и x_3 . (табл. 4.29).

Таблица 4.29

	e_2	e_4	e_5	e_6	e_7
	$r(yx_2 x_1, x_3)$	$r(yx_4 x_1, x_3)$	$r(yx_5 x_1, x_3)$	$r(yx_6 x_1, x_3)$	$r(yx_7 x_1, x_3)$
$r(e, e_i)$	-0,31	-0,01	0,50	0,04	-0,32

Наибольшее по модулю значение принимает коэффициент корреляции между y и x_5 . Таким образом, следующей переменной, включенной в модель, является x_5 .

Модель, описывающая зависимость переменной y от факторов x_1 , x_3 и x_5 , представляется в виде

$$\hat{y} = -5,02 + 0,04x_1 - 0,02x_3 + 13,27x_5.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.30.

Таблица 4.30

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	-5,02	4,56	-1,10	0,295
x_1	0,04	0,11	0,36	0,728
x_3	-0,02	0,01	-3,14	0,009
x_5	13,27	6,85	1,94	0,079

В представленной модели параметры при x_1 и x_5 оказываются незначимыми, поскольку наблюдаемые значения t -статистики Стьюдента $t_1 = 0,36$ и $t_5 = 1,94$ меньше соответствующего табличного значения $t_{кр}(0,05;11) = 2,2$.

Поэтому переменные x_1 и x_5 исключаются из модели. Параметр при переменной x_3 признается существенным ($t_3 = -3,14$).

Оцениваем линейную регрессию y на x_3

$$\hat{y} = 7,69 - 0,032x_3.$$

Рассчитываем частные коэффициенты корреляции между переменной y и факторами x_i , исключая влияние x_3 . При этом используем ряд остатков последней регрессии и остатки регрессий вида $\hat{x}_i = a_{0i} + a_{1i}x_3$ при $i \neq 3$.

Коэффициент	e_1	e_2	e_4	e_5	e_6	e_7
$r(e, e_i) = r(yx_i x_3) =$	0,72	0,48	0,56	0,8	-0,17	-0,75

Пользуясь правилом наибольшего коэффициента корреляции, в модель опять вводим фактор x_5 . Исключение этого фактора на предыдущем шаге было связано, скорее всего, с проблемой мультиколлинеарности ($r(x_1, x_5) = 0,82$).

Оцениваем регрессию переменной y на переменные x_3 и x_5

$$\hat{y} = -6,19 - 0,026x_3 + 15,37x_5.$$

Значимость параметров этой модели была проверена в примере 4.10. Частные коэффициенты корреляции приведены в табл. 4.31.

Таблица 4.31

	e_1	e_2	e_4	e_6	e_7
	$r(yx_1 x_3, x_5)$	$r(yx_2 x_3, x_5)$	$r(yx_4 x_3, x_5)$	$r(yx_6 x_3, x_5)$	$r(yx_7 x_3, x_5)$
$r(e, e_i)$	0,11	-0,15	-0,32	0,01	0,04

В качестве следующего фактора в модель вводим x_4 . Модель, описывающая зависимость переменной y от факторов x_3 , x_4 и x_5 , представляется в виде

$$\hat{y} = 4,57 - 0,034x_3 - 0,21x_4 + 21,20x_5.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.32.

Таблица 4.32

Переменные	Коэффициенты	Стандартная ошибка	t -статистика	p -значение
y	4,57	9,91	0,46	0,654
x_3	-0,03	0,01	-3,99	0,002
x_4	-0,21	0,18	-1,14	0,279
x_5	21,20	6,10	3,48	0,005

Параметр перед переменной x_4 незначителен ($t_4 = -1,14$ против $t_{кр}(0,05;11) = 2,2$), следовательно, этот фактор исключается из модели. Более ни один фактор в модель не включается, так как $|r(yx_i | x_3, x_5)| < |r(yx_4 | x_3, x_5)|$.

Окончательным вариантом является модель

$$\hat{y} = -6,19 - 0,03x_3 + 15,37x_5.$$

Значения коэффициентов, стандартных ошибок, эмпирических t -статистик Стьюдента и p -значения представлены в табл. 4.33.

На уровне значимости $\alpha = 0,05$ проверяется гипотеза о существенности параметров этой модели. Поскольку наблюдаемые

значения статистик выше критического значения (по модулю), параметры при переменных x_3 и x_5 признаются существенными.

Таблица 4.33

Переменные	Коэффициенты	Стандартная ошибка	t-статистика	p-значение
y	-6,19	3,05	-2,03	0,0650
x_3	-0,03	0,01	-5,14	0,0002
x_5	15,37	3,36	4,58	0,0006

З а м е ч а н и е 1. Из третьей полученной модели

$$\hat{y} = -5,02 + 0,04x_1 - 0,02x_3 + 13,27x_5$$

можно было исключать не два фактора x_1 и x_5 сразу, а только фактор x_1 как создающий проблему мультиколлинеарности. Предпочтение при этом отдаётся фактору, который при достаточно тесной связи с результатом имеет наименее тесную связь с другими факторами. Проанализируем корреляционную матрицу.

W =

	y	x_1	x_2	x_3	x_4	x_5	x_6	x_7
y	1	0,84	0,70	-0,76	0,80	0,71	-0,68	-0,58
x_1	0,84	1	0,89	-0,63	0,88	0,82	-0,63	-0,79
x_2	0,70	0,89	1	-0,59	0,83	0,69	-0,58	-0,70
x_3	-0,76	-0,63	-0,59	1	-0,71	-0,27	0,82	0,12
x_4	0,80	0,88	0,83	-0,71	1	0,76	-0,82	-0,72
x_5	0,71	0,82	0,69	-0,27	0,76	1	-0,34	-0,94
x_6	-0,68	-0,63	-0,58	0,82	-0,82	-0,34	1	0,31
x_7	-0,58	-0,79	-0,70	0,12	-0,72	-0,94	0,31	1

Определим, какую из переменных исключить из уравнения. Для этого сравним $r(x_1, x_3) = -0,63 > r(x_3, x_5) = -0,27$, следовательно, x_1 теснее связан с x_3 , значит, его необходимо удалить из уравнения.

З а м е ч а н и е 2. Большинство статистических пакетов позволяют вычислять частные коэффициенты корреляций без вспомогательных регрессий, что значительно облегчает процедуру.

Алгоритм считается завершённым в том случае, если наибольший частный коэффициент на определенном этапе оказался не значимым.

РЕКОМЕНДУЕМАЯ ЛИТЕРАТУРА

Основная

Анализ данных: учеб. для вузов / В. С. Мхитарян [и др.]. М., 2023.

Кремер И.Ш., Путко Б.А. Эконометрика: учеб. для вузов / М., 2023.

Магнус Я.Р., Катышев П.К., Пересецкий А.А. Эконометрика. Начальный курс: учебник. 9-е изд., перераб. и доп. М., 2021.

Практикум по эконометрике / И.И. Елисеева [и др.]. 2-е изд., перераб. и доп. М., 2007.

Эконометрика: учеб. для вузов / под ред. И.И. Елисеевой. М., 2023.

Дополнительная

Многомерный статистический анализ в экономических задачах: компьютерное моделирование в SPSS / под ред. И.В. Орловой М., 2024.

Орлова И.В., Половников В.А. Экономико-математические методы и модели: компьютерное моделирование: учеб. пособие. М., 2024.

ПРИЛОЖЕНИЯ

СПРАВОЧНЫЕ МАТЕРИАЛЫ ДЛЯ ВЫПОЛНЕНИЯ РАСЧЕТОВ

ФОРМУЛЫ И ФУНКЦИИ MS EXCEL, ИСПОЛЬЗУЕМЫЕ ПРИ КОРРЕЛЯЦИОННОМ АНАЛИЗЕ

Среднее значение – формула для вычислений: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

Функция «СРЗНАЧ» ищет число в указанном диапазоне, которое ближе всего находится к среднему арифметическому значению. Результат этого расчета выводится в отдельную ячейку, где и содержится формула.

Синтаксис: = СРЗНАЧ (число1; число2; ...).

Дисперсия – формула для вычислений: $S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Функция «ДИСП.В» оценивает дисперсию по выборке. Логические значения и текст игнорируются. В функции «ДИСП.В» предполагается, что аргументы являются только выборкой из генеральной совокупности. Если данные представляют всю генеральную совокупность, для вычисления дисперсии следует использовать функцию ДИСПР.

Синтаксис: = ДИСП.В (число1; [число2]; ...).

Стандартное отклонение – формула для вычислений: $S_x = \sqrt{S_x^2}$.

Функция «СТАНДОТКЛОН.В» оценивает стандартное отклонение по выборке. Стандартное отклонение — это мера того, насколько широко разбросаны точки данных относительно их среднего. Функция «СТАНДОТКЛОН.В» предполагает, что аргументы являются только выборкой из генеральной совокупности. Если данные представляют всю генеральную совокупность, то стандартное отклонение следует вычислять с помощью функции «СТАНДОТКЛОН.Г».

Синтаксис: = СТАНДОТКЛОН.В (число1; число2; ...).

Сумма квадратов отклонений – формула для вычислений:

$$\sum_{i=1}^n (x_i - \bar{x})^2.$$

Функция «КВАДРОТКЛ» возвращает сумму квадратов отклонений точек данных от их среднего.

Синтаксис: = КВАДРОТКЛ (число1; число2; . . .) .

Ковариация – это мера того, как изменения одной переменной связаны с изменениями второй переменной, формула для вы-

$$\text{числений: } \text{Cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}.$$

Функция «КОВАРИАЦИЯ.Г» возвращает ковариацию совокупности, т. е. среднее произведений отклонений для каждой пары точек в двух наборах данных.

Синтаксис: = КОВАРИАЦИЯ.Г (массив1; массив2) .

Коэффициент парной корреляции – формула для вычислений:

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Функция «КОРРЕЛ» возвращает коэффициент корреляции двух диапазонов между интервалами ячеек «массив1» и «массив2». Коэффициент корреляции используется для определения взаимосвязи между двумя свойствами.

Синтаксис: = КОРРЕЛ (массив1; массив2) .

Формула для вычислений **t-критерия Стьюдента** для проверки значимости коэффициента парной корреляции:

$$t_{\text{набл}} = \frac{r_{y,x} \sqrt{n-2}}{\sqrt{1-r_{y,x}^2}}.$$

Функция «СТЬЮДЕНТ.ОБР.2Х» возвращает двустороннее обратное t-распределение Стьюдента.

Синтаксис: = СТЬЮДЕНТ.ОБР.2Х (вероятность; степени свободы) .

Функция «РАНГ.СР» в указанную ячейку выдает порядковый номер конкретного числа в выборке по условию, которое указано в отдельном аргументе. Это может быть порядок по возрастанию или по убыванию. Последний установлен по умолчанию, если поле «Порядок» оставить пустым или поставить туда цифру 0.

Синтаксис: = РАНГ.СР (число; массив; порядок) .

F-критерий Фишера для проверки значимости модели регрессии – формула для вычислений: $F_{набл} = \frac{R^2 / k}{(1 - R^2) / (n - k - 1)}$.

Функция «F.ОБР.ПХ» возвращает значение, обратное (правостороннему) F -распределению вероятности, если $p = F.РАСП.ПХ(x;...)$, то $F.ОБР.ПХ(p;...) = x$. $F.ОБР.ПХ(...)$ используется для того, чтобы определить критические значения F -распределения, для этого нужно использовать уровень значимости α как аргумент «вероятность» для $F.ОБР.ПХ(...)$.

Синтаксис: = F.ОБР.ПХ (вероятность; степени_свободы1; степени_свободы2) :

вероятность – обязательный аргумент. Вероятность, связанная с интегральным F -распределением;

степени_свободы1 – обязательный аргумент. Числитель степеней свободы;

степени_свободы2 – обязательный аргумент. Знаменатель степеней свободы;

Функция «ХИ2.ОБР.ПХ» возвращает обратное значение односторонней вероятности распределения хи-квадрат.

Синтаксис: = ХИ2.ОБР.ПХ (вероятность, степени_свободы) .

Функция «ФИШЕР» выполняет возвращение преобразования Фишера для аргументов X , формула для вычисления:

$$z = \frac{1}{2} \ln \frac{1+r}{1-r}.$$

Это преобразование строит функцию, которая имеет нормальное, а не асимметричное распределение. Используется функция «ФИШЕР» для того, чтобы проверить гипотезу с помощью коэффициента корреляции.

Синтаксис: = ФИШЕР (x) .

Пример. Используя данные об активности коммерческих организаций, требуется сделать оценку связи прибыли Y (млн р.) и затрат X (млн р.), используемых для разработки продукции (приведены на рисунке).

	A	B	C	D	E
1	№	X	Y		
2	1	210	95		
3	2	1068	76		
4	3	1005	78		
5	4	610	89		
6	5	768	77		
7	6	799	85		
8	Коэффициент корреляции		-0,9118	<--	=КОРРЕЛ(B2:B7;C2:C7)
9	Расчетное (наблюдаемое) значение t-критерия $t_{\text{набл}}$		4,4421	<--	=ABS(C8)/КОРЕНЬ(1-СТЕПЕНЬ(C8;2))*КОРЕНЬ(6-2)
10	Табличное значение t-критерия $t_{\text{кр}}$		2,7764	<--	=СТЬЮДЕНТ.ОБР.2X(0,05;4)
11	Табличное значение стандартн. норм. распр. z_{α}		1,9600	<--	=НОРМ.СТ.ОБР(1-0,05/2)
12	Значение преобразования Фишера Zr		-1,5383	<--	=ФИШЕР(C8)
13	Левая интервальная оценка для Zr		-2,6699	<--	=C12-C11*КОРЕНЬ(1/(6-3))
14	Правая интервальная оценка для Zr		-0,4068	<--	=C12+C11*КОРЕНЬ(1/(6-3))
15	Левая интервальная оценка для r_{xy}		-0,9905	<--	=ФИШЕРОБР(C13)
16	Правая интервальная оценка для r_{xy}		-0,3857	<--	=ФИШЕРОБР(C14)
17	Стандартное отклонение для r_{xy}		0,2053	<--	=КОРЕНЬ((1-C8^2)/4)

Схема решения таких задач выглядит следующим образом:

- 1) рассчитывается линейный коэффициент корреляции r_{xy} ;
- 2) проверяется значимость линейного коэффициента корреляции на основе t -критерия Стьюдента; при этом выдвигается и проверяется гипотеза о равенстве коэффициента корреляции нулю; при проверке этой гипотезы используется t -статистика; если гипотеза подтверждается, t -статистика имеет распределение Стьюдента; если расчетное значение $t_{\text{набл}} > t_{\text{кр}}$, то гипотеза отвергается, что свидетельствует о значимости линейного коэффициента корреляции, а следовательно, и о статистической существенности зависимости между X и Y ;
- 3) определяется интервальная оценка для статистически значимого линейного коэффициента корреляции;
- 4) определяется интервальная оценка для линейного коэффициента корреляции на основе обратного z -преобразования Фишера;
- 5) рассчитывается стандартная ошибка линейного коэффициента корреляции.


Если значение $t_{\text{набл}} = 4,44 > t_{\text{кр}} = 2,78$, то гипотеза отвергается, что свидетельствует о значимости линейного коэффициента корреляции, а следовательно, и о статистической существенности зависимости между X и Y .

Таким образом, с вероятностью 0,95 линейный коэффициент корреляции заключен в интервале от $(-0,386)$ до $(-0,990)$ со стандартной ошибкой 0,205.

Приведем матрицу коэффициентов парной корреляции.

$$R = \begin{pmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \dots & \dots & \dots & \dots \\ r_{p1} & r_{p2} & \dots & 1 \end{pmatrix}.$$

Обращение к средствам анализа данных. Для вычисления матрицы коэффициентов парной корреляции R следует на вкладке «Данные» открыть пакет «Анализ данных». В списке инструментов анализа выбираем «Корреляция».



В выходном диапазоне (параметры вывода) появляется корреляционная матрица. На пересечении строк и столбцов – коэффициенты корреляции.

N	O	P
	y	x ₁
y	1	
x ₁	0,840	1

НЕКОТОРЫЕ ФОРМУЛЫ И ФУНКЦИИ EXCEL, ИСПОЛЬЗУЕМЫЕ ПРИ РЕГРЕССИОННОМ АНАЛИЗЕ

Коэффициент детерминации $R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	Коэффициент детерминации показывает долю вариации результативного признака, находящегося под воздействием изучаемых факторов, т. е. определяет, какая доля вариации признака Y учтена в модели и обусловлена влиянием на него факторов Чем ближе R^2 к 1, тем выше качество модели
Коэффициент множественной корреляции (индекс корреляции) R $R = \sqrt{1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}} = \sqrt{\frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}}$	Данный коэффициент является универсальным, так как он отражает тесноту связи и точность модели, а также может использоваться при любой форме связи переменных Чем ближе R к 1, тем выше качество модели
t-критерий Стьюдента для оценки значимости параметров модели линейной регрессии $t_{aj} = \hat{a}_j / \sigma_{aj}$	Вычисленное значение t_{aj} сравнивается с критическим значением t-критерия, которое берется из таблицы значений t Стьюдента с учетом заданного уровня значимости и числа степеней свободы $(n - k - 1)$. В Excel критическое значение t-

	критерия можно получить с помощью функции «СТЮДЕНТ.ОБР.2Х (...))»
Средняя относительная ошибка аппроксимации $e_{\text{отн}} = \frac{1}{n} \sum_{i=1}^n \frac{ e_i }{y_i} \cdot 100\%$	Средняя относительная ошибка аппроксимации – оценка уровня точности модели

Оценка влияния отдельных факторов на зависимую переменную на основе модели

Коэффициенты эластичности $\mathcal{E}_j = \hat{a}_j \cdot \frac{\bar{x}_j}{\bar{y}}$	Эластичность показывает: на сколько процентов изменится значение исследуемой величины при изменении соответствующего фактора на 1 %
Бета-коэффициенты $\beta_j = \hat{a}_j \cdot \frac{S_{x_j}}{S_y}$	Бета-коэффициент показывает: на какую часть своего среднеквадратического отклонения (СКО) изменится значение исследуемой переменной при изменении соответствующего фактора на 1 СКО
Дельта коэффициенты $\Delta_j = r_{y,x_j} \cdot \beta_j / R^2$	Дельта-коэффициент показывает среднюю долю влияния соответствующего фактора в совокупном влиянии всех факторов, включенных в модель

Построение интервальных прогнозов по модели регрессии

$\sigma_e \cdot t_\alpha \cdot \sqrt{1 + X_{\text{прогн}}^T \cdot (X^T \cdot X)^{-1} \cdot X_{\text{прогн}}}$ – ошибка прогнозирования, которая позволяет определить доверительный интервал прогноза,


где $\sigma_e = \sqrt{\frac{\sum_{i=1}^n e_i^2}{n - k - 1}}$ – стандартная ошибка модели (СКО).

Ошибка прогнозирования для модели парной регрессии

$$\sigma_e \cdot t_\alpha \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_{\text{прогн}} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

РЕКОМЕНДАЦИИ ПО ВЫПОЛНЕНИЮ И ОФОРМЛЕНИЮ РАСЧЕТОВ В MICROSOFT EXCEL

Использование надстройки «Пакет анализа» («Анализ данных»). При проведении сложного статистического или инженерного анализа можно упростить процесс и сэкономить время, используя надстройку «Пакет анализа» («Анализ данных»). В MS Excel доступ к возможности находится в пункте главного меню «Данные». Приведем фрагмент главного меню MS Excel.




Загрузка надстройки «Анализ данных».

- 1) открыть вкладку «Файл» и выбрать пункт «Параметры»;
- 2) выбрать команду Надстройки, а затем в поле Управление выбрать пункт «Надстройки Excel»;
- 3) нажать кнопку «Перейти»;
- 4) в окне «Доступные надстройки» установить флажок «Пакет анализа» и нажмите кнопку «ОК»;
- 5) после загрузки надстройки «Пакет анализа» в меню во вкладке «Данные» становится доступна команда «Анализ данных».

Для анализа данных с помощью этого пакета следует указать входные данные и выбрать параметры; расчет будет выполнен с помощью подходящей статистической или инженерной макрофункции, а результат будет помещен в выходной диапазон.

Некоторые инструменты позволяют представить результаты анализа в графическом виде.

Для выполнения заданий по эконометрике из «Пакета анализа» необходимо использовать инструменты «Корреляция» и «Регрессия».



Создание парных диаграмм рассеяния. Важнейшим элементом эконометрического исследования является графический анализ исходных данных. В случае множественной регрессии (т.е. когда у нас несколько показателей) необходимо построить парные диаграммы зависимости объясняемой переменной Y от каждой из объясняющих переменных X – диаграммы рассеяния.


В эконометрическом анализе диаграммы, используемые при построении регрессионной модели, имеют тип «Точечная».

У каждой диаграммы должен быть содержательный заголовок, пусть и такой простой «Зависимость объёма продаж транспортного средства от расходов на бензин и индекса потребительских расходов». Оси диаграммы необходимо называть сокращёнными именами соответствующих переменных (включая обязательно единицы измерения). А вот легенды на парной диаграмме рассеяния может и не быть, если на ней не добавлена линия тренда.

Нужно помнить: для того, чтобы Excel правильно определил переменные, объясняемая переменная Y должна быть расположена в правом из выделенных двух столбцов, а объясняющая переменная X – в левом.

Для добавления данных в уже построенную диаграмму надо предварительно внести их в исходную таблицу, а затем выполнить следующие действия:


- 1) щелкнуть правой кнопкой мыши на области диаграммы;
- 2) в раскрывшемся контекстном меню выбрать команду «Выбрать данные»;
- 3) в окне «Выбор источника данных» в поле «Элементы легенды (ряды)» выделить нужный ряд и нажать кнопку «Изменить»;
- 4) в окне «Изменение ряда» указать новые диапазоны данных для значений Y и X ;
- 5) чтобы закончить и вернуться на лист, последовательно нажать кнопку «ОК».



Пример: интерпретация выходных данных регрессии в Excel

При работе с исходными данными из «Пакет анализа» необходимо использовать инструменты «Регрессия».

На рисунке представлен входной набор данных.



На следующем рисунке показаны выходные данные регрессии.

ВЫВОД ИТОГОВ						
<i>Регрессионная статистика</i>						
Множественный R	0,86					
R-квадрат	0,75					
Нормированный R-квадрат	0,72					
Стандартная ошибка	6,83					
Наблюдения	14					
<i>Дисперсионный анализ</i>						
	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Значимость F</i>	
Регрессия	1	1641	1641	35	0,000069	
Остаток	12	559	47			
Итого	13	2200				
	<i>Коэффициенты</i>	<i>Стандартная ошибка</i>	<i>t-статистика</i>	<i>P-Значение</i>	<i>Нижние 95%</i>	<i>Верхние 95%</i>
Y-пересечение	18,40	4,34	4,24	0,00115	8,94	27,86
x	0,34	0,06	5,93	0,00007	0,21	0,46

Проинтерпретируем наиболее важные значения в выводе.

Регрессионная статистика в отчете Excel

Наименование в отчете Excel	Принятые наименования	Формула
Множественный R	Коэффициент множественной корреляции, индекс корреляции	$R = \sqrt{R^2}$
R-квадрат	Коэффициент детерминации, R^2	$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$
Нормированный R-квадрат	Скорректированный R^2	$\bar{R}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$
Стандартная ошибка	Среднеквадратическое отклонение от модели	$\sigma_e = \sqrt{\sum e_i^2 / (n - k - 1)} = \sqrt{ESS / (n - k - 1)}$

Дисперсионный анализ в отчете Excel

Наименование в отчете Excel	df – число степеней свободы	SS – сумма квадратов	MS – дисперсия на одну степень свободы	F – критерий Фишера
Регрессия	k	RSS	$D_{факт}$	$F = D_{факт} / D_{ост}$
Остаток	$n - k - 1$	ESS	$D_{ост}$	–
Итого	$n - 1$	TSS	–	–

Суммы квадратов отклонений для регрессии, остатка и общей рассчитываются по формулам

$$RSS = \sum (\hat{y}_i - \bar{y})^2, \quad ESS = \sum e_i^2, \quad TSS = \sum (y_i - \bar{y})^2.$$

Дисперсии на одну степень свободы рассчитываются по следующим формулам

$$D_{факт} = RSS / k, \quad D_{ост} = ESS / (n - k - 1).$$

В таблице «Регрессионная статистика» приводятся значения:

1) множественный R : представляет собой множественную корреляцию между переменной ответа и двумя переменными-факторами

$$R = \sqrt{R^2};$$

2) R -квадрат: коэффициент детерминации; это доля дисперсии переменной отклика, которая может быть объяснена объясняющими переменными

$$R^2 = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2};$$

3) нормированный R -квадрат: представляет собой значение R -квадрата, скорректированное с учетом количества переменных-факторов в модели; это значение также будет меньше, чем значение для R -квадрат, и «наказывает» модели, которые используют в модели слишком много переменных факторов

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n-1}{n-m-1};$$

4) стандартная ошибка: среднее расстояние, на которое наблюдаемые значения отходят от линии регрессии.

$$\sigma_e = \sqrt{\sum e_i^2 / (n-k-1)} = \sqrt{ESS / (n-k-1)};$$

5) наблюдения: общий размер выборки набора данных, используемого для создания регрессионной модели.

В таблице «Дисперсионный анализ» приведены:

1) столбец « df » – число степеней свободы, равное:

- для строки «Регрессия» $df = k$;
- для строки «Остаток» $df = n - k - 1$;
- для строки «Итого» $df = n - 1$.

2) столбец « SS » – сумма квадратов отклонений, равная:

- для строки «Регрессия» ESS ;
- для строки «Остаток» RSS ;

– для строки «Итого» TSS ;
3) столбец « MS » – это дисперсии, определяемые по формуле $MS = SS/df$:

– для строки «Регрессия» – факторная дисперсия;
– для строки «Остаток» – остаточная дисперсия;
4) столбец « F » – расчетное значение F -критерия, вычисляемое по формуле

$$F = MS(\text{регрессия})/MS(\text{остаток});$$

5) столбец «Значимость F » – значение уровня значимости, соответствующее вычисленной F -статистике (p -значение), показывает, является ли регрессионная модель в целом статистически значимой.

Если p -значение меньше 0,05, то это означает, что независимые переменные вместе имеют статистически значимую связь с зависимой переменной и уравнение статистически значимо в целом.

В следующей таблице указаны:

1) коэффициенты – значения коэффициентов b_i ;
2) стандартная ошибка – стандартные ошибки коэффициентов регрессии S_{b_i} ;

3) t -статистика – расчетные значения t -критерия, вычисляемые по формуле:

$$t\text{-статистика} = \text{коэффициенты} / \text{стандартная ошибка};$$

4) p -значение (значимость t) – это значение уровня значимости, соответствующее вычисленной t -статистике; p -значение = СТЬЮДЕНТ.РАСП (t -статистика, $df(\text{остаток})$); если p -значение меньше стандартного уровня значимости, то соответствующий коэффициент статистически значим;

5) нижние 95% и верхние 95% – нижние и верхние границы 95 %-ных доверительных интервалов для коэффициентов теоретического уравнения линейной регрессии.

ВЫВОД ОСТАТКА		
Наблюдение	Предсказанное y	Остатки
1	36,36	2,64
2	39,41	4,59
3	32,97	-7,97
4	36,70	-6,70
5	45,18	6,82
6	43,48	5,52
7	38,40	-2,40
8	35,68	-11,68
9	30,94	-3,94
10	46,53	1,47
11	39,41	8,59
12	40,09	8,91
13	42,12	-0,12
14	77,71	-5,71

В таблице «Вывод остатка» указаны:

- 1) в столбце «Наблюдение» – номер наблюдения;
- 2) в столбце «Предсказанное y » – расчетные значения зависимой переменной;
- 3) в столбце «Остатки e » – разница между наблюдаемыми и расчетными значениями зависимой переменной.

Пр и м е р . Имеются данные по потребительским расходам на душу населения (тыс. р., y) и денежным доходам на душу населения (тыс. р., x).

x	53	62	43	54	79	74	59	51	37	83	62	64	70	175
y	39	44	25	30	52	49	36	24	27	48	48	49	42	72

Используя результаты работы пакета анализа Excel («Регрессия»), проанализируем зависимость расходов y от величины дохода.

Результаты регрессионного анализа принято записывать в виде:

$$y = 18,4 + 0,34x, \quad R^2 = 0,75,$$

$$(4,34) \quad (0,06)$$

где в скобках указаны стандартные ошибки коэффициентов регрессии.

Коэффициенты регрессии $a = 18,4$ и $b = 0,34$. Направление связи между y и x определяет знак коэффициента регрессии $b = 0,34$, т.е. связь является прямой и положительной. Коэффициент $b = 0,34$ показывает, что при увеличении дохода на 1 тыс. р. расходы увеличиваются на 0,34 тыс. р.

Оценим значимость коэффициентов полученной модели. Значимость коэффициентов (a , b) проверяется по t -тесту:

$$p\text{-значение } (a) = 0,00115 < 0,01 < 0,05,$$

$$p\text{-значение } (b) = 0,00007 < 0,01 < 0,05,$$

следовательно, коэффициенты (a , b) значимы при 1 %-ном уровне, а тем более при 5 %-ном уровне значимости. Таким образом, коэффициенты регрессии значимы и модель адекватна исходным данным.

Результаты оценивания регрессии совместимы не только с полученными значениями коэффициентов регрессии, но и с некоторым их множеством (доверительным интервалом). С вероятностью 95 % доверительные интервалы для коэффициентов есть (8,94; 27,86) для a и (0,21; 0,46) для b .

Качество модели оценивается коэффициентом детерминации R^2 .

Величина $R^2 = 0,746$ означает, что фактором дохода можно объяснить 74,6 % вариации (разброса) расходов.

Значимость R^2 проверяется по F -тесту:

$$\text{значимость } F = 0,000069 < 0,01 < 0,05,$$

следовательно, R^2 значим при 1 %-ном уровне, а тем более при 5 %-ном уровне значимости.

В случае парной линейной регрессии коэффициент корреляции можно определить как $r_{y,x} = \sqrt{R^2} = 0,86$. Полученное значение коэффициента корреляции свидетельствует, что связь между расходами и доходом очень тесная.

Приложение 2

КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ СТЬЮДЕНТА

Число степеней свободы k	Уровень значимости α (двусторонняя критическая область)		
	0,10	0,05	0,01
1	6,31	12,7	63,7
2	2,92	4,30	9,92
3	2,35	3,18	5,84
4	2,13	2,78	4,00
5	2,01	2,57	4,03
6	1,94	2,45	3,71
7	1,89	2,36	3,50
8	1,86	2,31	3,36
10	1,81	2,23	3,17
12	1,78	2,18	3,05
14	1,76	2,14	2,98
16	1,75	2,12	2,92
18	1,73	2,10	2,88
20	1,73	2,09	2,85
22	1,72	2,07	2,82
24	1,71	2,06	2,80
26	1,71	2,06	2,78
28	1,70	2,05	2,76
30	1,70	2,04	2,75
40	1,68	2,02	2,70
60	1,07	2,00	2,66
120	1,66	1,98	2,62
Число степеней свободы k	0,05	0,025	0,005
	Уровень значимости α (односторонняя критическая область)		

Приложение 3

**КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ
ФИШЕРА – СНЕДЕКОРА**

**(k_1 – число степеней свободы большей дисперсии,
 k_2 – число степеней свободы меньшей дисперсии)**

Зна- чения	Уровень значимости $\alpha = 0,01$									
	k_1									
k_2	3	4	5	6	7	8	9	10	11	12
3	29,46	28,71	28,24	27,91	27,67	27,49	27,34	27,23	27,13	27,05
4	16,69	15,98	15,52	15,21	14,96	14,80	14,66	14,54	14,45	14,37
5	12,06	11,39	10,97	10,67	10,45	10,27	10,15	10,05	9,96	9,89
6	9,78	9,15	8,75	8,47	8,26	8,10	7,98	7,87	7,79	7,72
7	8,45	7,85	7,46	7,19	7,00	6,84	6,71	6,62	6,54	6,47
8	7,59	7,01	6,63	6,37	6,19	6,03	5,91	5,82	5,74	5,67
9	6,99	6,42	6,06	5,80	5,62	5,47	5,35	5,26	5,18	5,11
10	6,55	5,99	5,64	5,39	5,21	5,06	4,95	4,85	4,78	4,71
11	6,22	5,67	5,32	5,07	4,88	4,72	4,63	4,54	4,46	4,40
12	5,95	5,41	5,06	4,82	4,65	4,50	4,39	4,30	4,22	4,16
13	5,74	5,20	4,86	4,62	4,44	4,30	4,19	4,10	4,02	3,96
14	5,56	5,03	4,69	4,46	4,28	4,14	4,03	3,94	3,86	3,80
15	5,42	4,89	4,56	4,32	4,14	4,00	3,89	3,80	3,73	3,67
16	5,29	4,77	4,44	4,20	4,03	3,89	3,78	3,69	3,61	3,55
17	5,18	4,67	4,44	4,10	3,93	3,79	3,68	3,59	3,52	3,45

Значения	Уровень значимости $\alpha = 0,05$									
	k_1									
k_2	3	4	5	6	7	8	9	10	11	12
3	9,28	9,12	9,01	8,94	8,88	8,84	8,81	8,78	8,76	8,74
4	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,93	5,91
5	5,41	5,19	5,05	4,95	4,88	4,82	4,78	4,74	4,70	4,68
6	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,03	4,00
7	4,3	4,1	3,9	3,8	3,7	3,7	3,6	3,6	3,6	3,5
8	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,34	3,31	3,28
9	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,13	3,10	3,07
10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,97	2,94	2,91
11	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,86	2,82	2,79
12	3,49	3,26	3,11	3,00	2,92	2,85	2,80	2,76	2,72	2,69
13	3,41	3,18	3,02	2,92	2,84	2,77	2,72	2,67	2,63	2,60
14	3,34	3,11	2,96	2,85	2,77	2,70	2,65	2,60	2,56	2,53
15	3,29	3,06	2,90	2,79	2,70	2,64	2,59	2,55	2,51	2,48
16	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,45	2,42
17	3,20	2,96	2,81	2,70	2,62	2,55	2,50	2,45	2,41	2,38

Приложение 4

КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ χ^2

Число степеней свободы k	Уровень значимости α					
	0,01	0,025	0,05	0,95	0,975	0,99
3	11,3	9,4	7,8	0,35	0,22	0,12
4	13,3	11,1	9,5	0,71	0,48	0,30
5	15,1	12,8	11,1	1,15	0,83	0,55
6	16,8	14,4	12,6	1,64	1,24	0,87
7	18,5	16,0	14,1	2,17	1,69	1,24
8	20,1	17,5	15,5	2,73	2,18	1,65
9	21,7	19,0	16,9	3,33	2,70	2,09
10	23,2	20,5	18,3	3,94	3,25	2,56
11	24,7	21,9	19,7	4,57	3,82	3,05
12	26,2	23,3	21,0	5,23	4,40	3,57
13	27,7	24,7	22,4	5,89	5,01	4,11
14	29,1	26,1	23,7	6,57	5,63	4,66
15	30,6	27,5	25,0	7,26	6,26	5,23
16	32,0	28,8	26,3	7,96	6,91	5,81
17	33,4	30,2	27,6	8,67	7,56	6,41
18	34,8	31,5	28,9	9,39	8,23	7,01
19	36,2	32,9	30,1	10,1	8,91	7,63
20	37,6	34,2	31,4	10,9	9,59	8,26
21	38,9	35,5	32,7	11,6	10,3	8,90
22	40,3	36,8	33,9	12,3	11,0	9,54
23	41,6	38,1	35,2	13,1	11,7	10,2
24	43,0	39,4	36,4	13,8	12,4	10,9
26	45,6	41,9	38,9	15,4	13,8	12,2
28	48,3	44,5	41,3	16,9	15,3	13,6
30	50,9	47,0	43,8	18,5	16,8	15,0

Приложение 5

РАСПРЕДЕЛЕНИЕ ДАРБИНА – УОТСОНА

**Критические точки d_l и d_u при уровне значимости $\alpha = 0,05$
(n – объем выборки, m – число объясняющих переменных
в уравнении регрессии)**

n	$m = 1$		$m = 2$		$m = 3$		$m = 4$		$m = 5$	
	d_l	d_u	d_l	d_u	d_l	d_u	d_l	d_u	d_l	d_u
15	1,08	1,36	0,95	1,54	0,82	1,75	0,69	1,97	0,56	2,21
16	1,10	1,37	0,98	1,54	0,86	1,73	0,74	1,93	0,62	2,15
17	1,13	1,38	1,02	1,54	0,90	1,71	0,78	1,90	0,67	2,10
18	1,16	1,39	1,05	1,53	0,93	1,69	0,82	1,87	0,71	2,06
19	1,18	1,40	1,08	1,53	0,97	1,68	0,85	1,85	0,75	2,02
20	1,20	1,41	1,10	1,54	1,00	1,68	0,90	1,83	0,79	1,99
21	1,22	1,42	1,13	1,54	1,03	1,67	0,93	1,81	0,83	1,96
22	1,24	1,43	1,15	1,54	1,05	1,66	0,96	1,80	0,86	1,94
23	1,26	1,44	1,17	1,54	1,08	1,66	0,99	1,79	0,90	1,92
24	1,27	1,45	1,19	1,55	1,10	1,66	1,01	1,78	0,93	1,99
25	1,29	1,45	1,21	1,55	1,12	1,66	1,04	1,77	0,95	1,89
26	1,30	1,46	1,22	1,55	1,14	1,65	1,06	1,76	0,98	1,88
27	1,32	1,47	1,24	1,56	1,16	1,65	1,08	1,76	1,01	1,86
28	1,33	1,48	1,26	1,56	1,18	1,65	1,10	1,75	1,03	1,85
29	1,34	1,48	1,27	1,56	1,20	1,65	1,12	1,74	1,05	1,84
30	1,35	1,49	1,28	1,57	1,21	1,65	1,14	1,74	1,07	1,83
35	1,40	1,52	1,34	1,58	1,28	1,65	1,22	1,73	1,16	1,80
40	1,44	1,54	1,39	1,60	1,34	1,66	1,29	1,72	1,23	1,79
45	1,48	1,57	1,43	1,62	1,38	1,67	1,34	1,72	1,29	1,78
50	1,50	1,59	1,46	1,63	1,42	1,67	1,38	1,72	1,34	1,77
55	1,53	1,60	1,49	1,64	1,45	1,68	1,41	1,72	1,38	1,77
60	1,55	1,62	1,51	1,65	1,58	1,69	1,44	1,73	1,41	1,77
65	1,57	1,63	1,54	1,66	1,50	1,70	1,47	1,73	1,44	1,77
70	1,58	1,64	1,55	1,67	1,52	1,70	1,49	1,74	1,46	1,77
75	1,60	1,65	1,57	1,68	1,54	1,71	1,51	1,74	1,49	1,77
80	1,61	1,66	1,59	1,69	1,56	1,72	1,53	1,74	1,51	1,77
90	1,63	1,68	1,61	1,70	1,59	1,73	1,57	1,75	1,54	1,78
100	1,65	1,69	1,63	1,72	1,61	1,74	1,59	1,76	1,57	1,78
150	1,75	1,71	1,69	1,77	1,68	1,79	1,67	1,80	1,64	1,83

Приложение 6

**КРИТИЧЕСКИЕ ЗНАЧЕНИЯ КОЛИЧЕСТВА РЯДОВ
ДЛЯ ОПРЕДЕЛЕНИЯ НАЛИЧИЯ АВТОКОРРЕЛЯЦИИ
ПО МЕТОДУ РЯДОВ ($\alpha = 0,05$)**

Нижняя граница K_1

	n_2																		
n_1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
2											2	2	2	2	2	2	2	2	2
3					2	2	2	2	2	2	2	2	2	3	3	3	3	3	3
4				2	2	2	3	3	3	3	3	3	3	3	4	4	4	4	4
5			2	2	3	3	3	3	3	4	4	4	4	4	4	4	5	5	5
6		2	2	3	3	3	3	4	4	4	4	5	5	5	5	5	5	6	6
7		2	2	3	3	3	4	4	5	5	5	5	5	6	6	6	6	6	6
8		2	3	3	3	4	4	5	5	5	6	6	6	6	6	7	7	7	7
9		2	3	3	4	4	5	5	5	6	6	6	7	7	7	7	8	8	8
10		2	3	3	4	5	5	5	6	6	7	7	7	7	8	8	8	8	9
11		2	3	4	4	5	5	6	6	7	7	7	8	8	8	9	9	9	9
12	2	2	3	4	4	5	6	6	7	7	7	8	8	8	9	9	9	10	10
13	2	2	3	4	5	5	6	6	7	7	8	8	9	9	9	10	10	10	10
14	2	2	3	4	5	5	6	6	7	7	8	8	9	9	10	10	10	11	11
15	2	3	3	4	5	6	6	7	7	8	8	9	9	10	10	11	11	11	12
16	2	3	4	4	5	6	6	7	8	8	9	9	10	10	11	11	11	12	12
17	2	3	4	4	5	6	7	7	8	9	9	10	10	11	11	11	12	12	13
18	2	3	4	5	5	6	7	8	8	9	9	10	10	11	11	12	12	13	13
19	2	3	4	5	6	6	7	8	8	9	10	10	11	11	12	12	13	13	13
20	2	3	4	5	6	6	7	8	9	9	10	10	11	12	12	13	13	13	14

Верхняя граница K_2

	n_2																			
n_1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	
4				9	9															
5			9	10	10	11	11													
6			9	10	11	12	12	13	13	13	13									
7				11	12	13	13	14	14	14	14	15	15	15						
8				11	12	13	14	14	15	15	16	16	16	16	17	17	17	17	17	
9					13	14	14	15	16	16	16	17	17	18	18	18	18	18	18	
10					13	14	15	16	16	17	17	18	18	18	19	19	19	20	20	
11					13	14	15	16	17	17	18	19	19	19	20	20	20	21	21	
12					13	14	16	16	17	18	19	19	20	20	21	21	21	22	22	
13						15	16	17	18	19	19	20	20	21	21	22	22	23	23	
14						15	16	17	18	19	20	20	21	22	22	23	23	23	24	
15						15	16	18	18	19	20	21	22	22	23	23	24	24	25	
16							17	18	19	20	21	21	22	23	23	24	25	25	25	
17							17	18	19	20	21	22	23	23	24	25	25	26	26	
18							17	18	19	20	21	22	23	24	25	25	26	26	27	
19							17	18	20	21	22	23	23	24	25	26	26	27	27	
20							17	18	20	21	22	23	24	25	25	26	27	27	28	

Пример: пусть при $n = 20$ будет 11 знаков «+» ($= n_1$) и 9 знаков «-» ($= n_2$). Тогда при $\alpha = 0,05$ нижняя граница $K_1 = 6$, верхняя граница $K_2 = 16$. Если $K_{\text{набл}} \leq 6$ или $K_{\text{набл}} \geq 16$, то гипотеза об отсутствии автокорреляции должна быть отклонена.

Приложение 7

КРИТИЧЕСКИЕ ГРАНИЦЫ ОТНОШЕНИЯ R/S

п	Нижние границы			Верхние границы		
	Вероятность ошибки					
	0,01	0,05	0,1	0,1	0,05	0,01
3	1,737	1,758	1,782	1,997	1,999	2,000
4	1,87	1,98	2,04	2,409	2,429	2,445
5	2,02	2,15	2,22	2,712	2,753	2,803
6	2,15	2,28	2,37	2,949	3,012	3,095
7	2,26	2,40	2,49	3,143	3,222	3,338
8	2,35	2,50	2,59	3,308	3,399	3,543
9	2,44	2,59	2,68	3,449	3,552	3,720
10	2,51	2,67	2,76	3,57	3,685	3,875
11	2,58	2,74	2,84	3,68	3,80	4,012
12	2,64	2,80	2,90	3,78	3,91	4,134
13	2,70	2,86	2,96	3,87	4,00	4,244
14	2,75	2,92	3,02	3,95	4,09	4,34
15	2,80	2,97	3,07	4,02	4,17	4,44
16	2,84	3,01	3,12	4,09	4,24	4,52
17	2,88	3,06	3,17	4,15	4,31	4,60
18	2,92	3,10	3,21	4,21	4,37	4,67
19	2,96	3,14	3,25	4,27	4,43	4,74
20	2,99	3,18	3,29	4,32	4,49	4,80

ОГЛАВЛЕНИЕ

Введение	3
1. Предмет эконометрики	4
1.1. Типы данных и методы их исследования	5
2. Корреляционный анализ.....	11
2.1. Корреляционный анализ взаимосвязи количественных признаков.....	13
2.2. Метод анализа корреляционной матрицы.....	20
2.3. Метод показателей информационной емкости	21
2.4. Примеры решения типовых задач	22
3. Регрессия.....	36
3.1. Постановка задачи регрессии.....	36
3.2. Предпосылки использования МНК (условия Гаусса – Маркова).....	37
3.3. Парная регрессия.....	40
3.3.1. Парная линейная регрессия	41
3.3.2. Оценка значимости уравнения и коэффициентов регрессии. Коэффициент детерминации.....	45
3.3.3. Интервальная оценка функции регрессии и ее параметров.....	52
3.4. Нелинейная регрессия	55
3.5. Определение меры точности модели.....	59
3.6. Сравнение различных моделей.....	60
3.7. Примеры решения типовых задач.....	63
4. Множественная регрессия.....	75
4.1. Определение параметров уравнения регрессии.....	76
4.1.1. Анализ статистической значимости уравнения регрессии и ее коэффициентов.....	81
4.1.2. Доверительные интервалы для функции регрессии и коэффициентов регрессии	85
4.2. Примеры решения типовых задач.....	86
4.3. Фиктивные переменные в регрессионных моделях.....	94
4.3.1. Линейные регрессионные модели с переменной структурой.....	94
4.3.2. Тест Чоу на наличие структурного сдвига.....	101
4.4. Мультиколлинеарность.....	108

4.4.1. Тестирование и устранение мультиколлинеарности.....	112
4.4.2. Примеры решения задач.....	114
4.5. Гетероскедастичность.....	121
4.5.1. Устранение гетероскедастичности.....	126
4.5.2. Примеры решения типовых задач	129
4.6. Автокорреляция	134
4.6.1. Определение автокорреляции	134
4.6.2. Устранение автокорреляции случайных составляющих.....	141
4.6.3. Примеры решения типовых задач.....	145
4.7. Спецификация модели	149
4.8. Процедуры пошагового построения моделей	151
Рекомендуемая литература	164
Приложения.....	165

Учебное издание

Акиньшина Вера Александровна
Калайдина Галина Вениаминовна

ВВЕДЕНИЕ В ЭКОНОМЕТРИКУ

Учебное пособие

Подписано в печать 30.11.2023. Выход в свет 30.11.2023.

Печать цифровая. Формат 60×84 1/16.

Уч.-изд. л. 12,7. Тираж 500 экз.

Заказ № 5084

Кубанский государственный университет
350040, г. Краснодар, ул. Ставропольская, 149.

Издательско-полиграфический центр
Кубанского государственного университета
350040, г. Краснодар, ул. Ставропольская, 149.